

Caculations..

1. $V = \{ \text{cat, dog, eats, fish, likes} \}$

2. $c(D_1) = [1, 0, 1, 1, 0]$

$c(D_2) = [0, 1, 1, 1, 0]$

$c(D_3) = [1, 0, 0, 1, 1]$

2. TP: $tf(\text{cat}, D_1) = \frac{c(\text{cat}, D_1)}{\sum_{t \in V} c(t, D_1)} = \frac{1}{3}$

$tf(\text{eats}, D_1) = \frac{c(\text{eats}, D_1)}{\text{total words in } D_1} = \frac{1}{3}$

$tf(\text{fish}, D_1) = \frac{c(\text{fish}, D_1)}{\text{total words in } D_1} = \frac{1}{3}$

$tf(\text{dog}, D_1) = \frac{0}{3} = 0$

$tf(\text{likes}, D_1) = \frac{0}{3} = 0$

$\Rightarrow \sum_{t \in V} tf(t, D_1) = \frac{1}{3} + 0 + \frac{1}{3} + \frac{1}{3} + 0 = \frac{2}{3}$
 $= 1 \cdot (\text{time } 1)$

3. Paco: $idf(t) = \log\left(\frac{V}{idf(t)}\right)$

$\Rightarrow idf(\text{cat}) = \ln\left(\frac{5}{2}\right)$

$idf(\text{dog}) = \ln\left(\frac{5}{1}\right)$

$idf(\text{eats}) = \ln\left(\frac{5}{2}\right)$

$idf(\text{fish}) = \ln\left(\frac{5}{3}\right) = 0$

$idf(\text{likes}) = \ln\left(\frac{5}{1}\right) = \ln(5)$

Term có idf thấp nhất là fish ($idf(\text{fish}) = 0$). Do từ fish xuất hiện trong tất cả các văn bản về mặt ý nghĩa thông tin nó không giúp phân biệt hay xếp hạng đặc trưng tài liệu.

4. Có: $tf \cdot idf(t, d) = tf(t, d) \times idf(t)$

$tf \cdot idf(\text{cat}, D_1) = \frac{1}{3} \times \ln(1.5) \approx 0.1352$

$$\text{tf-idf}(\text{cats}, D_1) = \frac{1}{3} \times \ln(1.5) \approx 0.1351$$

$$\text{tf-idf}(\text{fish}, D_1) = \frac{1}{3} \times 0 = 0.0.$$

- Vì tf-idf đo lường mức độ quan trọng và tính đặc trưng riêng biệt của một từ đối với văn bản so với toàn bộ kho dữ liệu. Nếu 1 từ có mặt ở tất cả các tài liệu thì việc một tài liệu chứa từ này hoàn toàn không cung cấp thông tin phân biệt nào giữa tài liệu này với tài liệu khác.

$$5. \cos(x, y) = \frac{x^T y}{\|x\|_2 \|y\|_2} = \frac{1 \times 1 + 1 \times 1 + 1 \times 0}{\sqrt{1^2 + 1^2 + 1^2} \cdot \sqrt{1^2 + 1^2 + 0^2}} = \frac{2}{\sqrt{6}} \approx 0.816$$

+ Cosine similarity không đến mức tập số chiều giống nhau với 'chưa cho tổng số chiều', đo góc như hình học θ giữa 2 vector trong không gian vector đa chiều bằng khoảng

6.
 1. D1 có similarity cao nhất.
 2. D3 có similarity thấp nhất
 3. Hai từ "medical" và "image" có giá trị IDF thấp
 4. Thứ tự ranking không thay đổi?

Part Part C: Prediction

1. Có khoảng 100 - 150.000 unique terms.
2. TF-IDF sẽ là sparse sparse
3. - π_i là zero khoảng 98 - 99%
3. không nhất thiết là các documents gần nghĩa nhất với query người dùng vì TF-IDF + cosine similarity chỉ yếu dựa trên sự trùng khớp và tổng số của các term.

Learning Check.

1. Vì không gian vector có số chiều bằng toàn bộ & kích thước từ vựng toàn cục V . trong khi một văn bản thực tế chỉ chứa từ 100-350 từ vựng duy nhất.
2. Một từ xuất hiện ở mọi nơi không mang giá trị phân biệt để phân loại hay xếp hạng tài liệu
3. Nếu từ đó không xuất hiện trong tài liệu d .
 $\Rightarrow tf(t,d)=0$ thì trọng số $tfidf$ của nó trong tài liệu d vẫn bằng chính xác 0.0.
4. No cosine similarity đo góc giữa 2 vector thay vì khoảng cách Euclid.
5. Tiền xử lý (lower casing, xóa dấu câu, tách từ, bỏ $\dots$) làm thay đổi trực tiếp từ vựng V , tần số $tf(t,d)$, $df(t)$. Nếu loại bỏ 1 từ quan trọng $\Rightarrow$ similarity giảm. Ngược lại chuẩn hóa đúng về cùng 1 trạng thái sẽ khiến các tài liệu có từ lặp match cao hơn
6. query "medical image classification". Hệ thống đưa một tài liệu về "tài chuẩn phân loại mô tả xây dựng RPS" lên top 1 vì chứa từ ~~Classification~~ (từ hiếm có IDF cao)
7. Gợi ý về nhu cầu sử dụng Dense Semantic Embedding
vd: word2vect, fastText.
cho phép tính toán độ tương đồng giữa các khái niệm

Reflection.

16.