Lab 04: Text Classification

Vũ Tiến Đạt: 23000111.

5. Representation.

- Không. Hai classifier giống nhau nhưng dùng representation khác nhau thường không cho kết quả giống nhau. Classifier chỉ học trên không gian đặc trưng mà representation tạo ra, nên representation quyết định thông tin nào classifier có thể nhìn thấy.

6. Bài tập tính toán

Bài 1. Binary Classification

Ta có. $z = w^T x + b = 0,5 \cdot 1 + (0,2) \cdot 2 + 0,4 \cdot 0 + 0,1$

$= 0,5 - 0,4 + 0,1 = 0,2$

$\Rightarrow z = 0,2.$

$P(y=1|x) = \sigma(0,2) = \frac{1}{1+e^{-0,2}} \approx 0,5498.$

Bài 2: Prediction threshold.

a. Với $T = 0,5$

+) Do $P(y=1|x) = 0,72 > 0,5 = a$ T

$\Rightarrow$ model dự đoán class 1. $(y=1)$

$\rightarrow$ Với $T = 0,8$:

Do $P(y=1|x) = 0,72 < 0,8$

$\Rightarrow$ model dự đoán class 0. $(y=0)$

b. Threshold ảnh hưởng tới precision và recall thế nào?

+) $\text{precision} = \frac{TP}{TP+FP}$, +) $\text{Recall} = \frac{TP}{TP+FN}$.

+) Khi tăng threshold $\Rightarrow$ model khó dự đoán "1" hơn.

nên FP giảm, precision tăng.

FN tăng, nên recall giảm.

+) Giảm threshold $\Rightarrow$ model dễ dự đoán "1" hơn

- bắt được nhiều mẫu thật hơn, recall tăng.

+) FP tăng nên precision giảm

with CamScanner

Bai 3 - Confusion matrix

+) precision = $\frac{TP}{TP+FP} = \frac{80}{80+10} = \frac{8}{9}$

+) recall = $\frac{TP}{TP+FN} = \frac{80}{80+20} = \frac{8}{10} = \frac{4}{5}$.

+) $F_1 = \frac{2PR}{P+R} = \frac{2 \cdot \frac{8}{9} \cdot \frac{4}{5}}{\frac{8}{9} + \frac{4}{5}} = \frac{1,4222}{1,6889} = 0,8421$

+) Nếu đây là bài toán phát hiện spam, false positive nghĩa là nếu mình dự báo phát hiện spam là (positive) tức email bình thường nhưng model dự đoán sai là spam (bắt nhầm)

+) Nếu là false negative nghĩa là ~~nhưng~~ phát hiện spam là đúng và mode dự đoán ~~đúng~~ là ~~spam~~ bình thường sai

Bài 4: Accuracy thấp (bỏ sót)

Model này ~~là chưa tốt~~ không thực sự tốt vì accuracy chỉ phản ánh.

Cần lập confusion matrix để xem thêm recall và precision, F_1

	Predicted Positive	Predicted Negative
Actual Positive	TP = 0	FN = 50
Actual Negative	FP = 0	TN = 950.

Do model dự đoán mọi mẫu là negative, nên không có mẫu nào được dự đoán là positive

+) Recall = $\frac{TP}{TP+FN} = \frac{0}{0+50} = 0$.

+) Precision = $\frac{TP}{TP+FP} = \frac{0}{0+0} = \infty$.

+) $F_1 = 0$.

=> không nên chỉ nhìn vào accuracy để đánh giá mô hình

with CamScanner

10. Prediction trước experiment

- Prediction 1. TF-IDF + logistic Regression có khả năng hoạt động tốt

Reason. TF-IDF nhấn mạnh các từ hiếm đặc trưng cho văn bản, còn logistic Regresson là mô hình tuyến tính hợp với dữ liệu thưa

Confidence: cao

- Prediction 2. Không. Không chắc chắn. Nhưng trường hợp TF-IDF bằng hoặc tốt hơn

Reason: Với dataset nhỏ thì word2vec embedding kém chất lượng. TF-IDF giữ được trọng số từ.

Confidence: cao

- Prediction 3: Không chắc chắn.

Reason: Thêm từ vựng ban đầu giúp có thêm từ để phân biệt Nếu ptử hiếm, xuất hiện ở rất ít văn bản, mang ít thông tin => khiến mô hình overfit

Confidence: cao

- Prediction 4: Bỏ stopwords thì peryomance k chắc chắn tăng. tuỳ vào bài toán

Reason. Với TF-IDF, stopwords vốn đã bị giảm nhỏ trọng số. nên bỏ đi thg ít thay đổi. còn words2vec, nếu bỏ nhầm => giảm hiệu quả

Confidence: cao

- Prediction 5. Có, tuỳ dữ liệu, bài toán.

Reason: Accuracy đếm mọi mẫu đúng nên lớp đa số chi phối kết quả.

F1 tập trung vào precision và recall của lớp nên phản ánh khả năng với lớp thiểu số.

VD. Bài 4: Accuracy cao, nhưng F1 = 0

Confidence: cao

with CamScanner

11. Cho Dataset chia thành 3 nhóm:

+) Cân bằng: IMDB, Yelp, SNLI ...

+) Khá cân bằng: SST2, 20_New

+) Mất cân bằng: SMS_Spam

13. Core implementation

Pipline: Raw text. → TF-IDF. → logistic Regression.
Vector diễn văn bản thành số. Dự đoán xác suất cho từng nhãn

→ Prediction → Evaluation
Dự đoán Đánh giá

$z = w^T x + b$. Tính điểm số tuyến tính giữa vector TF IDF

x: vector TF IDF

w: vector trọng số mà mô hình học được

b: bias.

$P(y=1|x) = \sigma(z)$: chuyển điểm số z thành xác suất $\in [0,1]$

$\sigma(z) = \frac{1}{1+e^{-z}}$ (hàm sigmoid)

16. Tại sao 2 representation tạo ra kết quả khác nhau?

	TF-IDF	W2V
Bản chất vector	Thưa, số chiều lớn	Dense, số chiều thấp
Thông tin lưu giữ	giữ tần suất và trọng số từ	lưu giữ nghĩa ẩn đồng giữa các từ.
Độ nhạy với từ khoá	Cao	giảm. do tính trung bình vector

VD: trong bài toán phân loại các thể loại bình luận phim có từ vựng đặc trưng thể hiện thái độ quyết định TF-IDF

www.camscanner

gán trọng số cho từng từ khoá này
w2v mất đi mức độ -do phép trung bình trên vùng dài

17. E4 - word order.
Representation này ko hiểu được vai trò của "not" do w2v biểu diễn vùng theo dạng $\bar{x} = \frac{1}{n}\sum_{n=1}^{n} \vec{w_i}$ và vector của từ "not" chỉ đóng vai trò của 1 thành phần cộng được thêm vào trung bình và không có cơ chế phủ định hay đảo chiều => cosine vẫn cao => mô hình dự đoán sai

18. E5 - ngram
Bigram có thể giúp classification nhưng đồng thời làm pipeline feature space lớn hơn là bởi vì bigram bắt được các cụm từ liên kề mang sắc thái tiêu cực hoặc chứa từ phủ định như "not good"
=> cụm từ thành đặc trưng, giải quyết điểm yếu mất thứ tự từ của unigram
Bên cạnh đó số lượng cặp từ liên tiếp $V \times V$ là cực kỳ lớn => ma trận đặc trưng thưa hơn rất nhiều

20. confusion matrix
class negative bị nhầm nhiều nhất ở cả 3 mô hình

Model	số lần đoán sai	positive
A	268	229
B	383	354
C	263	235.

false positive chiếm nhiều hơn FN ở cả 3 model
=> xu hướng over-predicting positive => dễ bị đánh lừa bởi 1 vài từ mang tính khen ngợi

with CamScanner

22. Các feature có ý nghĩa với bài toán sentiment analysis

Nhóm positive ($w_i >> 0$) tập trung vào các từ khen ngợi như great (3.45), excellent (3.314)

Nhóm negative ($w_i << 0$) bao gồm các từ phê bình như worst, waste (-7.575) → kéo log xuống

→ mô hình tuyến tính

21. Phân tích Analysis:

Text	True	Predicted	p	Lỗi	Phân tích
0	positive	positive	0,992	phân loại đúng	Vẫn chứa các từ khen cảm mạnh với trọng số TF-IDF cao. Không có yếu tố gây nhiễu
1	positive	positive	0,85	phân loại đúng	Có phủ định nhẹ (may not the greatest nhưng các từ tích cực cấp đỏ
2	negative	negative	0,996	Phân loại đúng	Mở đầu khen nhưng về sau phê bình gay gắt (clunky, sick-pa
3	negative	positive	0,57	Câu hỏi tu từ mang nghĩa phủ định	Mặc dù có từ mang nghĩa tích cực nhưng có cấu trúc phản tình phản cảm.
4	negative	positive	0,879	Ý kết thúc phản	Đoạn đầu khen, đoạn sau chê dùng từ ghép. Mô hình k° hiểu liên từ "but"
5	positive	negative	0,409	Domain specific lexical	một số từ phim hài mang nghĩa khen nhưng mô hình hiểu là chê.

Scanned with CamScanner