23000111 - Vũ Tiến Đạt

1. Bối cảnh:

- Hạn chế của mô hình (BOW, TF-IDF + Logistic Regression):
  *) Coi văn bản là một túi từ độc lập
  +) vector biểu diễn làm mất trật tự từ và phạm vi phủ định

RNN LSTM: xử lý tuần tự các bước thời gian. Trong đó h_t đóng vai trò là bộ nhớ và biểu diễn của từ hiện tại tại x_t

$$h_t = f(W_{hh} h_{t-1} + W_{xh} x_t + b_h).$$

- Khi RNN gặp sequence dài ⇒ gặp hiện tượng vanishing gradient
  mất thì nhớ làm xa, chỉ nhớ được vài từ gần nhất.

6. Bài tập tính toán

B1: Tacó: $W_{xh} \cdot x_t = \begin{bmatrix} 0,5 & 0,2 \\ 0,1 & 0,4 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0,5.1+0,2.0 \\ 0,1.1+0,4.0 \end{bmatrix} = \begin{bmatrix} 0,5 \\ 0,1 \end{bmatrix}$

$$W_{hh} \cdot h_{t-1} = \begin{bmatrix} 0,3 & 0,1 \\ 0,2 & 0,5 \end{bmatrix} \begin{bmatrix} 0,5 \\ 0,2 \end{bmatrix} = \begin{bmatrix} 0,17 \\ 0,20 \end{bmatrix}$$

$$\Rightarrow a_t = W_{xh} \cdot x_t + W_{hh} \cdot h_{t-1} + b_h = \begin{bmatrix} 0,85 \\ 0,1 \end{bmatrix} + \begin{bmatrix} 0,17 \\ 0,20 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0,67 \\ 0,30 \end{bmatrix}$$

$$h = \tanh(a_t) = \begin{bmatrix} \tanh(0,67) \\ \tanh(0,30) \end{bmatrix} = \begin{bmatrix} \frac{e^{0,67} - e^{-0,67}}{e^{0,67} + e^{-0,67}} \\ \frac{e^{0,3} - e^{-0,3}}{e^{0,3} + e^{-0,3}} \end{bmatrix} \approx \begin{bmatrix} 0,5850 \\ 0,2913 \end{bmatrix}$$

$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$

B2: Tại bước đọc "like": $a_4 = W_{xh} x_{like} + W_{hh} h_3 + b_h$

Thông tin "not" nằm trong h_3, từ "like" đặt trong bối cảnh ~~xuất~~ đã xuất hiện từ "not" ngay trước đó.

Còn đối với W2V: từ not và like được nhìn vào 1 tổng cộng trong số, like và not là 1 vector độc lập nên k° phân biệt được cấu trúc cú pháp

B3:
- Average word 2 vec: không thể phân biệt được vì công thức cũng là trung bình cộng vector $\vec{v} = \frac{1}{3}(x_1 + x_2 + x_3)$, phép cộng có tính chất giao hoán => 2 vector cho ra cùng 1 kết quả dự đoán
- RNN: phân biệt rõ ràng: $h_t = \tanh(W_{xh} x_t + W_{hh} h_{t-1} + b)$. bảo toàn được thứ tự xuất hiện trong câu.

B9. Vanishing gradient.
- Đạo hàm của hàm mất mát qua BPTT.

$$\frac{\partial h_T}{\partial h_t} = \prod_{k=t+1}^{T} \frac{\partial h_k}{\partial h_{k-1}}.$$

Khi sequence càng dài, truyền phản hồi lỗi: lỗi xảy ra tại bước cuối T còn phản hồi về từ khoảng tại bước $t=1$, nhưng vì khoảng cách $\frac{\partial h_T}{\partial h_t} \approx 0$, gradient sẽ không nhận được bất kỳ đóng góp nào từ các time step xa.

10. Prediction.
- Prediction 1: RNN + Embedding xử lý word order, trực tiếp tốt hơn
Reason: TF-IDF là mô hình túi từ có tính chất giao hoán nó không thể xử lý → câu trước câu như hoán vị, túi từ. RNN xử lý tuần tự: phụ giao hoán giữ trọn vẹn cấu trúc
Confidence: high.

- Prediction 2: LSTM vượt trội hơn.
Reason: LSTM sở hữu addi free cell state đóng vai trò như gradient highway truyền thẳng tín hiệu qua thời gian khi $f_t \approx 1$. Còn RNN bị triệt tiêu gradient do tích Jacobian
Confidence: high.

- Prediction 3: Thời gian training tăng tuyến tính 3-4 lần. vanishing gradient trong RNN trở nên trầm trọng
Reason: Do RNN bị triệt tiêu gradient do tích Jacobian
confidence: high

- Prediction 4: Độ chính xác phân loại sug gram.
  Reason: IMDb review s có độ dài trung bình 150-250 tokens. Cắt ngắn làm mất tín hiệu sentiment quan trọng
  Confidence: high

- Prediction 5: Không chắc chắn.
  Reason: Tiền dữ liệu rất ngắn. RNN không bị vanishing gradient; LSTM có tham số gấp 4 lần RNN ⇒ overfitting trên dữ liệu nhỏ
  Confidence: high

11.
- Việc lựa chọn max_lenght dựa trên ~~nội~~ kiến trúc mô hình và bảo toàn thông tin ngữ nghĩa
- Chọn max_length bao phủ trọn vẹn 70% - 85% số tài liệu trong tập dữ liệu

13.

Max length	% tokens retained	Training time	Accuracy	F1
50	21,75%	2.79	72.6%	72.25
100	41,98%	4,13s	78,14%	78,0
200	69,04%	8,08s	79,26%	79,2

- Tăng max_length không phải lúc nào cũng cải thiện performance khi tăng max_length, các văn ngắn phải thêm pad gây ra hiện tượng noise → overfitting
- Khi max_length nhỏ, loại các thông tin ở văn dài có thể bị mất, làm đứt các cặp từ liên kết, điều kiện

15.

Model	Representation	Accuracy	Precision	Recall	Training
Logistic Regression	TF-IDF	89,98	90,80	90,09	13,86s
RNN	Embedding	61,37	58,35	60,17	4,06s

- Có RNN có sử dụng thông tin mà TF-IDF không sử dụng

Scanned with CamScanner

vd: "dog bites man" với "man bites dog"

17.

Có: $C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t$

$= (0,9 \times 0,8) + (0,2 \times 0,5) = 0,82$.

- khi forget gần 1 model có xu hướng giữ lại hầu hết thông tin của từ quá khứ.
- khi forget gần 0 .. mode có xu hướng xoá bỏ / loại bỏ thông tin cũ.

24. Error analysis.

STT	mẫu	text	Ground Truth	dự đoán	Phân loại nguyên nhân
1.	đúng	I love this movie. and recommend it	Positive	Positive	Một số từ ngữ khích cực?
2	đúng	I thought the film would be terrible given the bad press, but it turned out to be surprisingly engaging	Positive	Positive	Mô hình nhận diện từ "but"
3	đúng	waste of time and money. The plot was completely nonsensical	Negative	negative	các từ phủ định forget đúng
4	Sai	This movie had stunning cinematography, ... Unfortunately, the writing was utterly ...	negative	positive	Toàn bộ 100 từ đầu khen ngợi sau đó chốt hạ cuối
5	Sai	oh yeah, what a brilliant idea ...	negative	positive	Người dùng dùng các từ trích dẫn để chê nhưng nội dung tệ
6	Sai	The director intentionally created an unsettling, ...	positive	negative	Dùng các từ tích cực nhưng mục đích khen ngợi