Lab06 - Vũ Tiến Đạt - 23000111. 01.

- sequence modeling: dữ liệu chuỗi có thứ tự

6. attention score: $S_i = q^T \cdot k_i$.

+) đo lường mức độ liên quan hoặc tương đồng giữa phần tử này với phần tử khác trong chuỗi dữ liệu.

chuẩn hoá -> softmax attention weights

$$\alpha_i = \frac{\exp(s_i)}{\sum_j \exp(s_j)}$$

$$\sum \alpha_i = 1.$$

+) $\sum_{j=1}^{3} \exp(s_j) = e^2 + e^1 + e^0 \approx 11,1074.$

+) $\alpha_1 = \frac{e^2}{11,1074} \approx 0,6652$

$\alpha_2 = \frac{e^1}{11,1074} \approx 0,2447$

$\alpha_3 = \frac{e^0}{11,1074} \approx 0,09$

$\Rightarrow \alpha = [\alpha_1, \alpha_2, \alpha_3] = [0,6652, 0,2447, 0,0900]$

Token nhận attention lớn nhất là token 3 vị trí i = 1.

7. Context vector.

1. Query: tìm kiếm → dot(k) → score. → attention weights
(tích vô hướng). softmax. chuẩn hoá.

Key - value. $S = q^T k_i$ → Attention weights

↓ Trích dẫn ↓ nội dung $= \text{dot}(q_0, k_i)$

8. Bài tập tính toán

Bài 1: Attention scores

Token 1: $S_1 = q_0^T k_1 = [1,2] \begin{bmatrix} 1 \\ 0 \end{bmatrix} = 1.$

Token 2. $S_2 = q_0^T k_2 = [1,2] \begin{bmatrix} 0 \\ 1 \end{bmatrix} = 2$

Token 3 $S_3 = q^T k_3 = [1,2] \begin{bmatrix} 1 \\ 1 \end{bmatrix} = 3$

Scanned with CamScanner

9. Bài 2: - Softmax:

$$\alpha_1 = \text{softmax}(s_1) = \frac{e^1}{e^3+e^2+e^1} \approx 0,09$$

$$\alpha_2 = \text{softmax}(s_2) = \frac{e^2}{e^3+e^2+e^1} \approx 0,2447$$

$$\alpha_3 = \text{softmax}(s_3) = \frac{e^3}{e^3+e^2+e^1} \approx 0,6652.$$

- phần tử có score lớn nhất nhân weigh lớn nhất vì tính đồng biến của hàm số mũ e^x, hàm e^x tăng trưởng theo cấp số nhân

10. Bài 3. - context vector

$$C = 0,1 \cdot v_1 + 0,2\, v_2 + 0,7 v_3$$

$$= 0,1\begin{bmatrix}1\\0\end{bmatrix} + 0,2\begin{bmatrix}0\\1\end{bmatrix} + 0,7\begin{bmatrix}2\\2\end{bmatrix} = \begin{bmatrix}1,5\\1,6\end{bmatrix}$$

value đóng góp nhiều nhất vào context vector là 0,7.

11. Bài 4:

+) $s_1 = q^T \cdot k_1 = 1$, $s_2 = q^T k_2 = 1.0 + 0.1 = 0$, $s_3 = q^T k_3 = 1.1 + 0.1 = 1.$

$\Rightarrow s = [1, 0, 1]$

+) $\alpha = \text{softmax}(s) = \left[\frac{e^1}{e^1+e^0+e^1}, \frac{e^0}{e^1+e^0+e^1}, \frac{e^1}{e^1+e^0+e^1}\right]$.

$\approx [0,4223, 0,1554, 0,4223]$

$$C = 0,4223\, v_1 + 0,1554\, v_2 + 0,4223\, v_3$$

$$= 0,4223\begin{bmatrix}1\\0\end{bmatrix} + 0,1554\begin{bmatrix}0\\2\end{bmatrix} + 0,4223\begin{bmatrix}2\\1\end{bmatrix} = .$$

12. Prediction.

Prediction 1: Một key có dot product lớn hơn các key khác, attention weigh của nó sẽ lớn hơn các attention weight khác và đóng góp nhiều vào context vector

Reason: vì hàm softmax đồng biến nên khi dot product cao → attention weight cao

Confidence: high

→ Prediction 2: Nếu tất cả scores giống nhau thì attention weights sẽ bằng nhau. do attention weigh ~~là~~ bo

Reason: do attention weights là hàm số dạng bên $\frac{e^{s_i}}{\sum_i e^{s_i}}$;

~~Cofi~~ Confidence: high.

- Prediction 3: Một score lớn hơn rất nhiều thì attention sẽ tập trung theo phân phối nhọn lệch hẳn về s3.

Reason: attention weigh tính theo hàm softmax là hàm số dạng bên

confidence: high.

- Prediction 4: Nếu sequence tăng từ 10 token → 1000 tokens chi phí tính attention sẽ ~~tăng gấp nguyên~~ tăng lên rất nhanh. khi tính $\sum \exp(s_i)$, attention matrix 1000 x 1000

Reason: Mỗi token cần tính attention score với tất cả token trong sequence.

confidence: high

- Prediction 5: Attention không chắc là luôn chọn đúng token mà con người cho là quan trọng nhất

Reason: attention weigh t cao không đồng nghĩa với việc token đó quan trọng với con người.

vd: The movie was not good. ~~nhưng tôi not~~ 65%

confidence: high.

13. Scaled dot-product attention

- Trong các mô hình thực tế chiều dài vector dk thường rất lớn. khi dot (tích vô hướng) là tổng của hàng triệu phép nhân.

=) Điểm ~~số~~ score bị đẩy lên rất lớn. => mất tính cân bằng

=) Chuẩn hóa đem chia QK^T cho chính số chiều $\sqrt{dk}$ dk

=) giúp softmax luôn nằm vào vùng có đạo hàm lớn nhất mô hình nhanh và ổn định

- scalle phương sai về (0, 1)

14. Bài tập - Scaling.

Ta có: $\sqrt{d_k} = \sqrt{4} = 2$.

$\Rightarrow \frac{QK^T}{\sqrt{d_k}} = \frac{[4, 2, 0]}{2} = [2, 1, 0]$

$\alpha_{scaled} = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right) = \left[\frac{e^2}{e^2+e^1+e^0}, \frac{e^1}{e^2+e^1+e^0}, \frac{e^0}{e^2+e^1+e^0}\right]$

$= [0,6652, 0,2447, 0,09]$.

$\Rightarrow \alpha_{scaled} = [0,6652, 0,2447, 0,09]$

$\alpha_{unscaled} = softmax(QK^T) = \left[\frac{e^4}{e^4+e^2+e^0}, \frac{e^2}{e^4+e^2+e^0}, \frac{e^0}{e^4+e^2+e^0}\right]$

$= [0,8668, 0,1173, 0,0159]$.

$\Rightarrow$

TH	scores	α_1	α_2	α_3	Mức độ tập trung
un scaling	[4,2,0]	86,68	11,73	1,59	phân bố nhọn tập trung vào điểm có score cao
có scaling	[2,1,0]	66,52	24,47	9,00	phân bố đều hơn không bị tập trung vào 1 điểm

- Scaling làm giảm độ nhọn của softmax, giúp phân bố đều hơn. mềm mại, các phần tử có điểm thấp có cơ hội đóng góp thông tin vào context

15. Temperature.

- softmax có thêm tham số T: $\alpha_i = softmax\left(\frac{s}{T}\right)_i = \frac{\exp(s_i/T)}{\sum_j \exp(s_i/T)}$

$T \to 0 \Rightarrow$ khoảng cách giữa score bị tăng gấp bội., phân phối trở lên nhọn token có score cao nhận gần như 100% trọng số

$T \to \infty \to$ phân phối trở nên bẹt phẳng, trọng số đều nhận trọng số bằng nhau.

- 2 vector scores $S = [2, 1, 0]$, $S = [1, 2, 3]$ cho cùng phân phối vì có độ lệch như nhau. Entropy thấp, mức độ tập trung nhọn Entropy cao, mức độ tập trung dàn trải.

+) $S = [2, 1, 0]$, Entropy: $H(p) = -\sum_{i=1} p_i \ln(p_i)$ 05

Temperature	max weigh	Entropy	nhận xét.
0,5	0,8668	0,4411.	- phân phối tập trung (nhọn). Token cao chiếm áp đảo
1	0,6652	0,8324	- phân phối ở mức cân bằng, các token cao vẫn giữ được độ chú ý nhất định
2	0,5065	1,0202	- phân phối phẳng dần. Sự chênh lệch giữa các token bị thu hẹp đáng kể?

17. Numerical stability

Theo quy tắc: $e^{a-b} = \frac{e^a}{e^b} = e^a \cdot e^{-b}$.

$$\text{softmax}(x_i - \max(x)) = \frac{e^{x_i - \max(x)}}{\sum_j e^{x_j - \max(x)}} = \frac{e^{x_i} \cdot e^{-\max(x)}}{e^{-\max(x)} \cdot \sum_j e^{x_j}}$$

$$= \frac{e^{x_i}}{\sum_j e^{x_j}} = \text{softmax}(x_i).$$

=) Trừ $\max(x)$ không làm thay đổi? Softmax.

21. Bài tập self-attention.

Giả sử embeding matrix: $X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 2 \end{bmatrix}$ I like cats., $dk = 2$

$W_Q = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$, $W_K = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$, $W_V = \begin{bmatrix} 1 & 2 \\ 2 & 0 \end{bmatrix}$

Bước 1: $Q = X \cdot W_Q = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 2 \end{bmatrix}$, $K = X \cdot W_K = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 0 & 2 \end{bmatrix}$

$$V = X \cdot W_V = \begin{bmatrix} 1 & 2 \\ 3 & 2 \\ 4 & 0 \end{bmatrix}$$

=) $Q \cdot K^T = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 \\ 2 & 3 & 2 \\ 2 & 4 & 4 \end{bmatrix}$

=) $\text{Attention} = \text{softmax}\left(\frac{QK^T}{\sqrt{dk}}\right) \cdot V$ (*)

$$S = \frac{QK^T}{\sqrt{dk}} = \begin{bmatrix} 0,7071 & 0,7071 & 0,000 \\ 1,4142 & 2,1213 & 1,4142 \\ 1,4142 & 2,8284 & 2,8284 \end{bmatrix} \Rightarrow \text{softmax}(S) = \begin{bmatrix} 0,4011 & 0,4011 & 0,1978 \\ 0,2483 & 0,5035 & 0,2483 \\ 0,1084 & 0,4458 & 0,4458 \end{bmatrix}$$

Scanned with CamScanner

-) $C = \alpha \cdot \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) \cdot V = \begin{bmatrix} 0,4011 & 0,4011 & 0,1978 \\ 0,2483 & 0,5035 & 0,2483 \\ 0,1084 & 0,4458 & 0,4458 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 2 \\ 4 & 0 \end{bmatrix}$

$= \begin{bmatrix} 2,3956 & 1,6044 \\ 2,7517 & 1,5035 \\ 3,2290 & 1,1084 \end{bmatrix}$ (I) (like) (cats)

27: Error analysis

Mẫu	Câu kiểm tra	nhãn đúng	dự đoán	P	Loại	Tỉnh trạng Attention pattern
C_1	I do not like this movie	Neg	Neg	96,8%	Negation	Tập trung nhọn vào not like
C_2	I thought it would be bad, but actually excellent	Pos	Pos	94,2	long range	Nhìn thẳng qua liên từ tới excellent
C_3	Acting was surprisingly natural and touched my heart	Pos	Pos	91,8%	ambiguous	gom cân đối 2 biểu cảm tích cực
I_1	oh brilliant another two hours wasted on pointless CGI	Neg	pos	78,4	sarcasm	Bị áp đảo bởi từ brilliant
I_2	Not that I didn't appreciate, but fell flat	Neg	pos	82?	negation + syntax	bị hút bão
I_3	The plot was full of red herrings that led nowhere	Neg	pos	54,1	rare word	Attention phân bố phẳng lì không tập trung

Scanned with CamScanner

28. Reflection

3.1. Attention giải quyết

+) Xoá bỏ nút thắt cổ chai thông tin

+) Khắc phục triệt để khoảng cách dẫn gradient

+) Mở khoá năng lực tính song song

3.2. Attention tạo ra vấn đề mới

1. Bùng nổ chi phí tính toán và bộ nhớ

2. Đánh mất nhận thức thứ tự tự nhiên

3. Hiện tượng quá tự tin hoặc phán toán sai lệch