1. Bối cảnh

- Lớp attention cơ chế là 1 phép "trộn thông tin có trọng số" giữa các từ. Attention tính QK^T và tổng trọng số ΣαV hoàn toàn đối xứng
=> ⓕ thêm 1 vector mã hóa vị trí trực tiếp vào mỗi Embedding ngay ở đầu vào. Một câu có n từ tăng cảm xúc, một bộ (Q, K, V) duy nhất thường bị quá tải

8. Multi-Head Attention).

$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V)$

Sau đó: $MultiHead(Q, K, V) = concat(head_1, ... head_h)W^O$

6. Cho $X = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & 1 & 0 & 0 \end{bmatrix}$, $W^Q = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$

$W^K = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \\ 0 & 1 \end{bmatrix}$, $W^V = \begin{bmatrix} 1 & 0 \\ 0 & 2 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$

Bước 1: $Q = XW^Q = \begin{bmatrix} 2 & 0 \\ 0 & 2 \\ 1 & 1 \end{bmatrix}$, $K = X.W^K = \begin{bmatrix} 1 & 0 \\ 0 & 2 \\ 1 & 1 \end{bmatrix}$

$V = X.W^V = \begin{bmatrix} 2 & 0 \\ 0 & 3 \\ 1 & 2 \end{bmatrix}$

Bước 2: Tính $S = \frac{QK^T}{\sqrt{d_k}} = \frac{QK^T}{\sqrt{2}} = \begin{bmatrix} \frac{2}{\sqrt{2}} & 0 & \frac{2}{\sqrt{2}} \\ 0 & \frac{4}{\sqrt{2}} & \frac{2}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{2}{\sqrt{2}} & \frac{2}{\sqrt{2}} \end{bmatrix}$

=> $A = Softmax(S) = \begin{bmatrix} 0,4458 & 0,1084 & 0,4458 \\ 0,0454 & 0,7679 & 0,1867 \\ 0,1978 & 0,4011 & 0,4011 \end{bmatrix}$

$Z = A.V = \begin{bmatrix} 1,3374 & 1,2168 \\ 0,2775 & 2,6771 \\ 0,7967 & 2,0056 \end{bmatrix}$

7. Bài tập - Multi-head

Cần Concatenation trước khi áp dụng W^O là:
+) khôi phục đúng số chiều gốc, bảo toàn kích thước để cộng Residual.
+) Giữ nguyên vẹn các đặc trưng.

Ví dụ $head_1 = \begin{bmatrix} 1.3 & 1.2 \\ 0.3 & 2.7 \\ 0.8 & 2.0 \end{bmatrix}$, $head_2 = \begin{bmatrix} 0.5 & 1.0 \\ 1.8 & 0.4 \\ 0.2 & 1.5 \end{bmatrix}$

$$concat(head_1, head_2) = \begin{bmatrix} 1.3 & 1.2 & 0.5 & 1.0 \\ 0.3 & 2.7 & 1.8 & 0.4 \\ 0.8 & 2.0 & 0.2 & 1.5 \end{bmatrix}$$

8. Prediction.

a. Prediction 1: Một transformer có thể xử lý các token song song hơn RNN.
Reason: +) RNN phụ thuộc tuần tự bắt buộc $h_t = f(h_{t-1}, x_t)$.
+) Transformer đệ quy bằng phép nhân ma trận toàn cục QKT.
Độ tin cậy: high. (Confidence).

b. Prediction 2: Nếu bỏ positional encoding, Transformer không biết thứ tự token nữa.
Reason: phép tính vô hướng Self-Attention: $q_i^T k_i$ và tổng trong số Ci có tính chất hoán vị
Confidence: high

c. Prediction 3: Transformer không thể phân biệt được
Reason: K có positional encoding tập hợp các vector đầu vào cho cả 2 câu là giống nhau
Confidence: high.

d. Prediction 4: Không nhất thiết học cùng 1 attention pattern.
Reason: Mỗi head có thể mang một bộ ma trận chiếu riêng biệt được khởi tạo ngẫu nhiên (W_i^Q, W_i^K, W_i^V).
Confidence: high

e. Prediction 5: Tăng số attentions heads không chắn làm tăng accuracy
Reason: Kiến trúc transformer tổng số chiều được giữ cố định - khi tăng head, số chiều giảm.

f. Prediction 6: Transformer không chắc nhanh hơn RNN trên mọi sequence length
Reason: Chuỗi ngắn: RNN nhanh hơn
Confidence: high

$X = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix}$, $W_{q_2} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 1 & 1 \\ 1 & 1 & 0 \end{bmatrix}$, $W_{k_2} = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}$ ②

$W_{v_2} = \begin{bmatrix} 0 & 1 & 1 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \\ 1 & 0 & 1 \end{bmatrix}$, $d_k = 3$.

$Q_2 = X \cdot W_{q_2} = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \end{bmatrix}$, $V_2 = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \end{bmatrix}$

$K_2 = X W_{k_2} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}$

$S = \frac{Q_2 K_2^T}{\sqrt{3}} = \frac{\begin{bmatrix} 0 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}}{\sqrt{3}} = \frac{\begin{bmatrix} 0 & 0 & 0 \\ 2 & 1 & 1 \\ 2 & 1 & 1 \end{bmatrix}}{\sqrt{3}}$

$= \begin{bmatrix} 0 & 0 & 0 \\ \frac{2}{\sqrt{3}} & \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{3}} & \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} \end{bmatrix}$

$\Rightarrow A = \text{softmax}(S) = \begin{bmatrix} \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \\ 0,4711 & 0,2645 & 0,2645 \\ 0,4711 & 0,2645 & 0,2645 \end{bmatrix}$

Scanned with CamScanner

~~pos = 0, 1, 2~~

10. Positional Encoding.

pos = 0, 1, 2

$$X' = X + P.E = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} + \begin{bmatrix} PE(0,0) & PE(0,1) & PE(0,2) & PE(0,3) & PE(0,4) \\ PE(1,0) & PE(1,1) & PE(1,2) & PE(1,3) & PE(1,4) \\ PE(2,0) & PE(2,1) & PE(2,2) & PE(2,3) & PE(2,4) \end{bmatrix}$$

$$= \begin{bmatrix} 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} + \begin{bmatrix} 0 & 1 & 0 & 1 & 0 \\ 0,841 & 0,505 & 0,001 & 0,999 & 6,308.10^{-6} \\ 0,909 & -0,416 & 0,002 & 0,999 & 1,261.10^{-5} \end{bmatrix} = \begin{bmatrix} 0 & 2 & 0 & 1 & 0 \\ 1,841 & 1,505 & 0,001 & 0,999 & 6,308.10^{-6} \\ 0,909 & -0,416 & 0,002 & 0,999 & 1,0013 \end{bmatrix}$$

17:

$$z_1 = W_1 x + b_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} + \begin{bmatrix} 0 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$h = \text{Relu}(z_1) = \text{Relu}\left(\begin{bmatrix} 1 \\ 1 \end{bmatrix}\right) = \begin{bmatrix} \max(0,1) \\ \max(0,1) \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Giả sử $W_2 = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}, b_2 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$

$$\Rightarrow y = W_2 h + b_2 = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$$

15. Việc sử dụng x + f(x) thay vì chỉ dùng f(x) giúp giải quyết triệt để vấn đề.

26. Error analysis.

Mẫu	Hiện tượng	Nhãn thực	Dự đoán	Xác suất	Giả Cơ chế
C_1	contrast	Pos	Pos	91,2%	Head 2 làm làm nổi bật mối quan hệ chính sau lớp tự bắt.
e_2	negation	Neg	Neg	93,8%	Kết hợp PE + Attention đã chiếu vector cảm xúc
C_3	long sequence	Pos	Pos	95,1%	Kết nối tầm xa (1) nhưng bị suy hao như RNN.
I_1	sarcasm	Neg	Pos	84,5%	Đoạn chê nằm ngoài phạm vi của số 128 token

I_2	ambigous sentiment	Neg	Pos	53,4%	Hai cực đối nghịch triệt tiêu khi mean pooling
I_3	rareword noise	Neg	Pos	58,2%	Mất thông tin từ vựng hiếm, nhiễu bởi tập "total"

27. Reflection.

TF-IDF

↓

limitation: Biểu diễn thưa (space), số chiều không lớn bằng kích thước từ điển (V) các từ đồng nghĩa hoàn toàn trực giao

word2vec / Avg Embedding.

giải quyết: nén thành vector dặc, nắm bắt dc tg đồng ngữ nghĩa

limitation: Biểu diễn tĩnh - ~~tác~~ làm mất hoàn toàn thứ tự từ

↓

RNN / LSTM / GRU.

- giải quyết: Giữ thứ tự chuỗi và trạng thái ẩn → ~~tích~~ lưu theo thời gian
- limitation: Tính toán tuần tự từng bước, mất thật có? chai thông tin nén ~~vào câu~~ cả câu vào h.T. Suy hao thông tin tầm xa

↓

Attention Mechanism.

- giải quyết: Cho phép tg tác trực tiếp, xoá bỏ mất thật có? tạo chai nhỏ nén cả câu vào h_T và suy hao thông tin tầm xa
- limitation: chỉ có 1 góc nhìn đơn lẻ thiếu phép biến đổi phi tuyến sâu cho từng vị trí.

↓

Transformer Architecture

- giải quyết: Kết hợp positional Encoding, Multi-head Attention. FFN và Residual + layer Norm

Remaining limitation:

1. Chi phí tính toán và bộ nhớ tăng bậc 2 theo độ dài chuỗi T.
2. Đòi hỏi lượng dữ liệu lớn → cần pretrain nặng