LAB 09 — Named Entity Recognition and Information Extraction

Môn học: Xử lý ngôn ngữ tự nhiên và ứng dụng | **Học kỳ:** Học kỳ I - 2026

Giảng viên / TA: Phạm Ngọc Hải ▪ **Hạn nộp:** 23:59 - 18/11/2026

Chủ đề: From Sequence Classification to Token Classification

---

1. Vai trò của LAB 09

LAB 08 kết thúc với:

```
Text
  ↓
Tokenizer
  ↓
Pretrained Transformer
  ↓
[CLS]
  ↓
Sequence Classification
  ↓
One label
```

LAB 09 thay đổi đầu ra:

```
Text
  ↓
Tokenizer
  ↓
Pretrained Transformer
  ↓
Contextual representation
  ↓
One prediction / token
  ↓
Named Entity Recognition
```

Ví dụ:

```
Barack Obama visited Paris.
```

Thay vì dự đoán:

```
POLITICS
```

model phải xác định:

```
Barack    → B-PER
Obama     → I-PER
visited   → O
Paris     → B-LOC
.         → O
```

Đây là bước chuyển:

Sequence Classification → Token Classification

---

2. Learning Outcomes

Sau LAB 09, sinh viên có thể:

1. Phân biệt sequence classification và token classification.
2. Giải thích bài toán Named Entity Recognition (NER).
3. Hiểu BIO tagging.
4. Chuyển annotation entity thành token labels.
5. Hiểu vấn đề alignment giữa:
   - word,
   - subword token,
   - label.
6. Sử dụng pretrained Transformer cho token classification.
7. Fine-tune model trên CoNLL-2003.
8. Tính và giải thích precision, recall, F1 cho NER.
9. Phân biệt token-level metrics và entity-level metrics.
10. Phân tích lỗi NER.
11. Nhận diện lỗi do:
    - tokenization,
    - context,
    - entity boundary,
    - rare entity,
    - domain shift.
12. Sử dụng NER như một bước đầu của Information Extraction.

---

3. Dataset

CoNLL-2003

Dataset chính:

CoNLL-2003 Named Entity Recognition

Các entity chính:

```
PER  → Person
ORG  → Organization
LOC  → Location
MISC → Miscellaneous
```

Ngoài ra:

```
O → Outside any entity
```

Ví dụ:

```
Barack Obama visited Paris.
```

có thể được biểu diễn:

```
Barack   B-PER
Obama    I-PER
visited  O
Paris    B-LOC
.        O
```

---

4. Sequence Classification vs Token Classification

Sequence Classification

LAB 08:

$$X \to y$$

Ví dụ:

```
"This movie is excellent."
            ↓
         POSITIVE
```

Một sequence có một label.

Token Classification

LAB 09:

$$X = (x_1, \dots, x_T)$$

và:

$$Y = (y_1, \dots, y_T)$$

Mỗi token có một label:

```
x1 → y1
x2 → y2
...
xT → yT
```

Ví dụ:

```
John   works   at   Google
 ↓       ↓     ↓      ↓
PER      O     O     ORG
```

---

5. BIO Tagging

NER thường sử dụng BIO scheme.

Tag	Meaning
B-X	Beginning of entity X
I-X	Inside entity X

Tag	Meaning
O	Outside entity

Ví dụ:

```
Barack Obama visited New York.
```

```
Barack   B-PER
Obama    I-PER
visited  O
New      B-LOC
York     I-LOC
```

---

6. Calculation Exercise 1 — BIO

Cho:

```
Elon Musk founded SpaceX in California.
```

Giả sử:

```
Elon Musk    → PER
SpaceX       → ORG
California   → LOC
```

Sinh viên phải tự tạo:

```
Elon
Musk
founded
SpaceX
in
California
.
```

và BIO labels tương ứng.

---

7. Calculation Exercise 2 — Entity Boundary

Cho:

```
University of California Berkeley
```

Giả sử toàn bộ cụm là một organization.

Sinh viên phải xác định:

```
University → B-ORG
of         → I-ORG
California → I-ORG
Berkeley   → I-ORG
```

Sau đó trả lời:

Vì sao không thể gán tất cả token là `ORG` nếu muốn biểu diễn ranh giới entity?

Mục tiêu là hiểu rằng NER không chỉ nhận diện **loại entity**, mà còn phải nhận diện **boundary**.

---

8. Subword Tokenization — vấn đề trung tâm

LAB 08 đã giới thiệu:

```
word
 ↓
tokenizer
 ↓
subword tokens
```

LAB 09 phải xử lý hậu quả của việc này.

Ví dụ minh họa:

```
Washington
     ↓
Washington
```

nhưng một từ khác có thể trở thành:

```
playing
   ↓
play
##ing
```

Trong annotation gốc:

```
playing → B-VERB/entity label
```

nhưng tokenizer tạo:

```
play
##ing
```

Vậy label nào được gán cho `##ing`?

Đây là **label alignment problem**.

---

9. Label Alignment

Pipeline:

```
Original words
      ↓
Word-level labels
      ↓
Tokenizer
      ↓
Subword tokens
      ↓
Alignment
      ↓
Token-level labels
```

Sinh viên phải hiểu rằng:

> Dataset NER thường annotation theo word, trong khi Transformer hoạt động trên token IDs.

Đây là một trong những vấn đề kỹ thuật quan trọng nhất của LAB 09.

---

10. Alignment Strategies

Có thể sử dụng một trong các chiến lược:

Strategy A

Gán label cho token đầu tiên:

```
playing
 ↓
play     → B-X
##ing    → IGNORE
```

Strategy B

Lan truyền label:

```
play     → B-X
##ing    → I-X
```

Strategy C

Một số tokenizer/model pipeline có cơ chế alignment riêng.

Trong lab này, sinh viên phải:

1. chọn một strategy;
2. giải thích;
3. áp dụng nhất quán;
4. phân tích ảnh hưởng.

Không yêu cầu so sánh mọi strategy nếu thời gian hạn chế.

---

11. Ignore Index

Nếu sử dụng Strategy A:

```
play     → B-PER
##ing    → IGNORE
```

Các token `IGNORE` không đóng góp vào loss.

Ví dụ:

$$L = -\sum_{i:y_i \neq IGNORE} \log P(y_i|x)$$

Sinh viên phải hiểu:

> IGNORE không có nghĩa token đó không tồn tại; nó chỉ có nghĩa label của token đó không được sử dụng trực tiếp trong loss.

---

12. Prediction Before Experiment

Trước khi chạy model, sinh viên phải dự đoán:

Prediction 1

Nếu sử dụng pretrained Transformer thay vì một classifier đơn giản dựa trên word features, NER sẽ thay đổi như thế nào?

Prediction 2

Các entity dài nhiều token sẽ dễ hay khó hơn entity chỉ có một token?

Ví dụ:

```
Microsoft
```

so với:

```
United Nations Security Council
```

Giải thích.

Prediction 3

Entity hiếm xuất hiện trong training data có khả năng gây lỗi nhiều hơn không?

Phải đưa ra lý do trước khi chạy experiment.

---

13. Baseline

Không bắt đầu ngay bằng Transformer.

Xây dựng baseline đơn giản:

```
Token
 ↓
TF-IDF / token features
 ↓
Logistic Regression
```

hoặc:

```
Token features
 ↓
Linear classifier
 ↓
NER
```

Mục tiêu:

> Có baseline để biết pretrained Transformer thực sự mang lại giá trị gì.

---

14. Transformer Token Classification

Pipeline:

```
Input text
     ↓
Tokenizer
     ↓
Input IDs
     ↓
Pretrained Transformer
     ↓
Hidden representation
     ↓
Linear layer
     ↓
Logits for every token
     ↓
BIO labels
```

Với:

$$H \in \mathbb{R}^{T \times d}$$

classification head:

$$Z = HW + b$$

Trong đó:

$$Z \in \mathbb{R}^{T \times C}$$

với:

- (T): số token;
- (d): hidden dimension;
- (C): số NER labels.

Mỗi token có một vector logits:

$$z_i \in \mathbb{R}^C$$

---

15. Calculation Exercise 3 — Shape

Giả sử:

$$B = 8$$

$$T = 128$$

$$d = 768$$

và:

$$C = 9$$

Sinh viên xác định shape của:

```
hidden states
logits
labels
```

Đáp án cần suy ra:

$$H : 8 \times 128 \times 768$$

$$Z : 8 \times 128 \times 9$$

$$Y : 8 \times 128$$

---

16. Core Implementation

Sinh viên triển khai hoặc hoàn thiện pipeline:

```
tokens = tokenizer(
    words,
    is_split_into_words=True,
    truncation=True,
    padding=True
)
```

Sau đó xây dựng:

```
word_ids
    ↓
alignment
    ↓
token_labels
```

Phần core không nên chỉ gọi một hàm `pipeline("ner")`.

Sinh viên phải nhìn thấy:

```
tokens
input_ids
attention_mask
word_ids
labels
logits
predictions
```

---

17. Experiment 1 — Tokenization Analysis

Chọn tối thiểu 20 câu.

Thống kê:

```
# words
# tokens
# subword splits
```

Tính:

$$R = \frac{\#subword\ tokens}{\#words}$$

So sánh:

- câu ngắn;
- câu dài;
- entity;
- non-entity.

Câu hỏi:

> Những loại từ nào thường bị chia thành nhiều subword?

---

18. Experiment 2 — Baseline vs Transformer

So sánh:

Model	Precision	Recall	F1
Baseline			
Pretrained Transformer			

Phải sử dụng cùng test set.

Không chỉ báo cáo accuracy.

---

19. Experiment 3 — Entity-Level Evaluation

Đây là phần quan trọng.

Ví dụ:

Gold:

```
New York → B-LOC I-LOC
```

Prediction:

```
New York → B-LOC O
```

Token `New` đúng.

Nhưng toàn bộ entity:

```
New York
```

không được nhận diện hoàn chỉnh.

Do đó:

```
token-level correctness
```

khác:

```
entity-level correctness
```

Sinh viên phải tính hoặc sử dụng metric phù hợp cho NER.

---

20. Precision / Recall / F1

Cho entity extraction:

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = \frac{2PR}{P + R}$$

Nhưng `TP`, `FP`, `FN` cần được xác định ở **entity level** khi đánh giá entity-level NER.

---

21. Experiment 4 — Entity Type Analysis

Báo cáo riêng:

Entity	Precision	Recall	F1
PER			
ORG			
LOC			
MISC			

Câu hỏi:

> Vì sao performance giữa các loại entity có thể khác nhau?

Sinh viên phải liên hệ với:

- số lượng training examples;
- lexical patterns;
- ambiguity;
- context;
- entity boundary;
- domain.

---

22. Experiment 5 — Entity Length

Chia entity theo độ dài:

```
1 token
2 tokens
3 tokens
4+ tokens
```

Tính F1 hoặc entity-level performance.

Ví dụ:

Entity length	F1
1	
2	
3	
4+	

Mục tiêu:

Kiểm tra prediction về entity boundary bằng dữ liệu thực nghiệm.

---

23. Experiment 6 — Error Analysis

Sinh viên chọn tối thiểu:

- 5 false positives;
- 5 false negatives;
- 5 boundary errors.

Bảng:

Text	Gold	Prediction	Error type	Explanation

Các loại lỗi gợi ý:

```
wrong entity type
wrong boundary
missing entity
spurious entity
rare entity
ambiguous entity
subword alignment
context-dependent entity
```

---

24. Context Analysis

NER là một bài toán phụ thuộc mạnh vào context.

Ví dụ cùng một token có thể có vai trò khác nhau trong các context khác nhau.

Sinh viên tìm ít nhất 3 ví dụ trong test set mà:

```
same surface form
        ↓
different entity type
```

Sau đó giải thích tại sao contextual representation có lợi thế so với representation tĩnh.

Đây là điểm nối trực tiếp với:

```
LAB03
static embedding
        ↓
LAB08
contextual representation
        ↓
LAB09
token-level contextual prediction
```

---

25. Application — Information Extraction

Sau khi model NER hoạt động, xây dựng một pipeline đơn giản:

```
Raw text
   ↓
NER
   ↓
Entity extraction
   ↓
Structured representation
```

Ví dụ:

```
Barack Obama visited Paris.
```

thành:

```
{
  "PERSON": ["Barack Obama"],
  "LOCATION": ["Paris"]
}
```

Không yêu cầu xây dựng hệ thống IE phức tạp.

Mục tiêu là cho sinh viên thấy:

> NER là bước trung gian để biến unstructured text thành structured data.

---

26. Mini Information Extraction Task

Sinh viên chọn một trong:

Option A — News

Trích xuất:

```
PERSON
ORG
LOCATION
```

Option B — Academic

Trích xuất:

```
PERSON
ORGANIZATION
LOCATION
```

Option C — Domain

Nếu có corpus phù hợp:

```
DISEASE
DRUG
PERSON
ORGANIZATION
```

Option C chỉ là mở rộng; không bắt buộc nếu dataset annotation chưa đủ.

---

27. Evaluation của Information Extraction

Không đánh giá IE bằng:

> "Output nhìn có vẻ đúng."

Phải lấy một tập nhỏ, ví dụ:

```
30 sentences
```

và tạo gold annotations.

Sau đó tính:

$$Precision,\ Recall,\ F1$$

ở entity level.

---

28. AI Usage

Được phép dùng AI cho:

- tokenizer documentation;
- API lookup;
- debugging;
- visualization;
- boilerplate;
- giải thích runtime error.

Không được giao AI làm thay:

- BIO labeling exercise;
- label alignment reasoning;
- prediction;
- metric interpretation;
- error analysis;
- reflection.

Nếu AI hỗ trợ code:

```
AI-assisted code:
What was generated:
```

```
What was modified:
What was verified:
```

---

29. Deliverables

```
lab09/
├── README.md
├── calculations.md
├── prediction.md
├── baseline_ner.py
├── tokenizer_alignment.ipynb
├── ner_finetuning.ipynb
├── results.csv
├── entity_metrics.csv
├── entity_length_analysis.png
├── confusion_matrix.png
├── error_analysis.md
├── information_extraction.py
└── reflection.md
```

---

30. Rubric

Component	Points
Theory & calculation	10
Prediction	10
BIO & label alignment	15
Baseline implementation	10
Transformer NER implementation	15
Tokenization experiment	10
Entity-level evaluation	10
Error analysis	10
Information Extraction application	5
Reflection	5
Total	**100**

---

31. Individual Learning Check

Mỗi sinh viên trả lời ngắn:

1. Sequence classification khác token classification như thế nào?
2. BIO tagging dùng để làm gì?
3. `B-PER` khác `I-PER` như thế nào?
4. Tại sao tokenizer gây ra label alignment problem?
5. `IGNORE` trong loss có ý nghĩa gì?
6. Tại sao NER không nên chỉ đánh giá bằng token accuracy?
7. Entity-level F1 khác token-level F1 như thế nào?
8. Vì sao entity boundary khó?
9. Vì sao contextual representation hữu ích cho NER?
10. NER có thể được sử dụng như thế nào trong Information Extraction?

---

32. Reflection

Viết 300–500 từ trả lời:

> Tại sao cùng một pretrained Transformer có thể được sử dụng cho cả sequence classification và token classification chỉ bằng cách thay đổi phần prediction head?

Phải giải thích được:

```
Pretrained Transformer
        ↓
contextual representation
        ↓
       ┌─────────────────┐
       │                 │
       ↓                 ↓
    [CLS]             every token
       ↓                 ↓
classification      token classifier
       ↓                 ↓
 sequence label       NER labels
```

---

33. Bridge to LAB 10

LAB 09 xử lý:

```
Text
 ↓
Entities
```

Nhưng nhiều hệ thống NLP cần trả lời câu hỏi:

> **Một đoạn văn bản chứa thông tin gì tại một vị trí cụ thể?**

Ví dụ:

```
Context:
Paris is the capital of France.

Question:
What is the capital of France?

Answer:
Paris
```

Đây không còn là:

```
sequence classification
```

và cũng không chỉ là:

```
token classification
```

Mà là:

```
Question + Context
        ↓
```

```
Pretrained Transformer
        ↓
Answer span
```

Do đó LAB 10 chuyển sang:

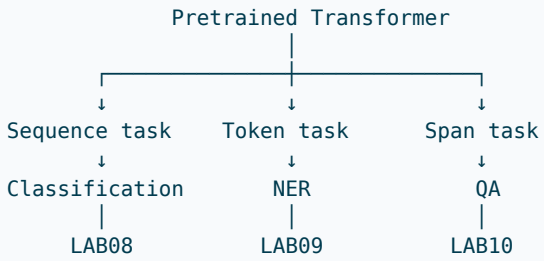
```
LAB 09
NER
 ↓
token-level prediction
 ↓
entity extraction

LAB 10
Question Answering
 ↓
span prediction
 ↓
extractive QA
```

Sinh viên sẽ tiếp tục sử dụng pretrained Transformer nhưng với một prediction head khác:

$$H \rightarrow P_{\text{start}}, P_{\text{end}}$$

Từ đó hình thành một pattern rất quan trọng:



Đây là điểm rất đáng nhấn mạnh trong khóa học: **sinh viên bắt đầu nhìn pretrained Transformer như một backbone tạo contextual representation, còn downstream task được quyết định bởi prediction head và cách định nghĩa output/label.**