


Lịch sử xử lý ngôn ngữ tự nhiên

CS224N/Ling284



Christopher Manning

Bài giảng 1

Christopher D. Manning: Hiểu và suy luận ngôn ngữ của con người

Bốn kỷ nguyên của xử lý ngôn ngữ tự nhiên (NLP).

- 1940-1969: Những cuộc thám hiểm ban đầu
- 1970-1992: Các hệ thống xử lý ngôn ngữ tự nhiên (NLP) ký hiệu
được xây dựng thủ công, với mức độ hình thức hóa ngày càng cao.

- 1993-2012: Thống kê hoặc Xác suất

Xử lý ngôn ngữ tự nhiên (NLP) và sau đó là xử lý có giám sát tổng quát hơn.

Học máy cho xử lý ngôn ngữ tự nhiên


- 2013-nay: Học sâu hay Trí tuệ nhân tạo

Mạng nơ-ron; Không giám sát hoặc tự giám sát

Xử lý ngôn ngữ tự nhiên có giám sát; Học tăng cường

Chỉ là những cánh đồng hơi đan xen nhau.

- Xử lý ngôn ngữ tự nhiên / Ngôn ngữ học tính toán
- Trí tuệ nhân tạo / Mạng thần kinh



Dædalus 151(2): 127-138 (Mùa xuân 2022)

<https://www.amacad.org/publication/human-nghon-ngu-hieu-ly-luan>

1. Những cuộc thám hiểm ban đầu

1940-1969

Dịch máy: Nguồn gốc của xử lý ngôn ngữ tự nhiên/ngôn ngữ học tính toán

“Cũng vì không biết gì chính thức về, nhưng đã phỏng đoán và suy luận khá nhiều về các phương pháp mã hóa tự động mạnh mẽ mới - những phương pháp mà tôi tin là thành công ngay cả khi không biết ngôn ngữ nào đã được mã hóa - người ta tự nhiên tự hỏi liệu vấn đề dịch thuật có thể được coi là một vấn đề trong mật mã học hay không. Khi tôi nhìn vào một bài báo bằng tiếng Nga, tôi nói: 'Bài này thực sự được viết bằng tiếng Anh, nhưng nó đã được mã hóa bằng một số ký hiệu lạ. Bây giờ tôi sẽ tiến hành giải mã.' ”



- Warren Weaver (1955:18, trích dẫn một bức thư ông viết năm 1947)



“Khi tôi đọc một bài báo bằng tiếng Nga, tôi tự nhủ: ‘Bài này thực chất được viết bằng tiếng Anh, nhưng đã được mã hóa bằng một số ký hiệu lạ. Giờ tôi sẽ tiến hành giải mã.’” -
Warren Weaver, tháng 3 năm 1947

Weaver là một nhà toán học và kỹ sư nổi tiếng với vai trò là người tài trợ khoa học tại Quỹ Rockefeller.

Quỹ và OSR&D (Chính phủ Hoa Kỳ)

(nhà tài trợ khoa học thời Thế chiến II)

và đồng tác giả một cuốn sách dễ tiếp cận.

Giới thiệu về Lý thuyết Thông tin với Shannon



“. về vấn đề dịch máy, thành thật mà nói, tôi e rằng ranh giới [ngữ nghĩa] của các từ trong các ngôn ngữ khác nhau quá mơ hồ. khiến cho bất kỳ phương án dịch bán máy nào cũng khó có thể khả thi.”

- Norbert Wiener, tháng 4 năm 1947

Wiener: Người khởi xướng ngành điều

khiển học tại MIT, ngành này tìm cách kết nối

giao tiếp, điều khiển và phản hồi

giữa sinh vật sống và máy tính.

"All the News
That's Fit to Print"

The New York Times.

LATE CITY EDITION

Fair and cold today. Increasing
cloudiness and cold tomorrow.
Temperature Range Today—Max., 35; Min., 22
Temperatures Yesterday—Max., 36; Min., 26
Full U. S. Weather Bureau Report, Page 41

VOL. CIII..No. 35,048.

Entered as Second-Class Matter.
Post Office, New York, N. Y.

Copyright, 1954, by The New York Times Company.

NEW YORK, FRIDAY, JANUARY 8, 1954.

Times Square, New York 36, N. Y.
Telephone LACKAWANNA 4-1000

FIVE CENTS

PIER STRIKE CURB SOUGHT IN COURTS AS TIE-UPS SPREAD

Walkout on Another Brooklyn
Dock Stirs Fear of 'Flash'
Stoppage Throughout Port

VOTE DISPUTE CONTINUES

New Questions Delay Sending
Poll Report to Capital—City
Tightens Its Precautions

By A. H. RASKIN

Shipping employers sought court help yesterday to halt the spread of Brooklyn pier strikes before they exploded into a port-wide shutdown.

The injunction moves came after a second dock had been closed by a work stoppage. The walkout by seventy-five members of the old International Longshoremen's Association stopped loading of the British freighter City of Barcelona at Pier 2, Bush Terminal.

It occurred on the sixth day of a strike by 150 American Federation of Labor dock workers, which has prevented removal of cargo from two Isbrandtsen Line freighters at Pier 29, Brooklyn. Although the walkouts had no apparent connection with one another, shipping executives expressed fear that they might provide the spark for a general tie-up of the strife-ridden harbor.

City Widens Precautions

Mayor Wagner took new steps to perfect the city's preparations for possible violence in the event of a waterfront strike on a broad

White Miners Veto Rhodesia Color Bar

By ALBION ROSS

SPECIAL TO THE NEW YORK TIMES.
JOHANNESBURG, South Africa, Jan. 7—White miners at the American-controlled Roan Antelope Mine in Northern Rhodesia have shaken the mining and industrial world of southern Africa by voting for removal of the color bar.

The mine's white workers, representing roughly one-fourth of the white persons in the Northern Rhodesian copper industry, voted to strike out the first clause of their agreement with the copper producers. The clause limits employment in the higher paid and more skilled jobs to white men.

In the new goldfields of Odendaalsrus, Orange Free State, Gert Lombard, speaking for the white South African Gold Miners Union, now under Nationalist leadership, called on white miners to resist this

Continued on Page 5, Column 5

MRS. LUCE TO RUSH TO ITALY IN CRISIS

Ambassador Cuts Visit to U. S.
by Week to Report Events
—Vatican Backs Pella

SPECIAL TO THE NEW YORK TIMES.

WASHINGTON, Jan. 7—Mrs. Clare Boothe Luce, United States Ambassador to Rome, will return to her post ahead of schedule because of the Italian Government crisis.

Mrs. Luce, who returned to Washington shortly before Jan. 1, plans to leave New York for

MAYOR ASKS STUDY OF STATE TAX SHIFT TO AID CITY INCOME

Urges Dewey to Join Move for
'Proper' Sharing of Levies
as Way to End Problems

Text of address by the Mayor
is printed on Page 14.

By PAUL CROWELL

Mayor Wagner offered last night to join with Governor Dewey in the appointment of a commission to consider the advisability of giving the city a "proper share" of the unlimited taxing powers now exercised by the state.

He said the purpose of such a commission would be to "study all state aid with a view to abolishing it and returning to us the taxing powers from which the money is now obtained."

The Mayor's offer was made in an address on city finances at the annual public-service-awards dinner of the Citizens Budget Commission at the Plaza Hotel. He declared that his proposal looked to a long-range solution of the city-state fiscal problem and could not, in all probability, bear any fruit in time to help the city prepare its 1954-55 budget.

"I said almost a year ago," the Mayor declared, "that I was tired of the city going to Albany for a handout. I said that I agreed with the Governor—and this was in the winter of 1952-53—that the state should get out of the collection agency business. I added that as a substitute for it the state should return to the localities their proper share of the taxing powers themselves; that it should give us a decent share

PRESIDENT WOULD CUT SPENDING, KEEP SECURITY AND PROSPERITY, END CITIZENSHIP OF SUBVERSIVES

'AKIN TO TREASON'

Eisenhower Maps Plan
to Deal With Reds
Guilty of Plots

By W. H. LAWRENCE

SPECIAL TO THE NEW YORK TIMES.
WASHINGTON, Jan. 7—President Eisenhower proposed today to strip United States citizenship from Communists convicted in the future of conspiring to advocate the overthrow of Government by force and violence.

His advocacy of a modern-day "men without a country" status for native-born or naturalized American conspirators surprised and delighted Congress.

The Communist conspiracy, the President said, is "akin to treason" and should be dealt with as such. Any person convicted of conspiring armed overthrow of Government, he proposed, should be "treated as having, by such act, renounced his allegiance to the United States and forfeited his United States citizenship."

This goes well beyond the present deprivation of civil rights suffered by those convicted of a felony. Under Federal law, those convicted of violating the Smith Act ban on conspiracy to advocate overthrow of the Government cannot vote, hold public



THE PRESIDENT REPORTS TO CONGRESS: President Eisenhower as he delivered his annual State of the Union message yesterday at a joint session of Congress. Behind him on the dais are Vice President Richard M. Nixon, left, and Speaker Joseph W. Martin Jr.

MESSAGE ON UNION

Eisenhower Proposes
Amendment to Give
18-Year-Olds Vote

Text of State of Union Message
is printed on Page 10.

By JAMES RESTON

SPECIAL TO THE NEW YORK TIMES.

WASHINGTON, Jan. 7—President Eisenhower, in his second State of the Union Message, today asked the almost evenly divided Eighty-third Congress to moderate but sustain the foreign and welfare policies of the New Deal era.

He proposed to cut the military budget, to cut taxes in relation to Government expenditures, and to reduce the guarantees to farmers very slowly. The cuts, however, were designed to reconcile security and solvency without jeopardizing the collective security or prosperity policies of the past.

The message contained only two surprises.

One was an appeal for a law that would take away the citizenship of any American hereafter convicted in the courts of "conspiring to advocate the overthrow of this Government by force or violence."

Russian Is Turned Into English By a Fast Electronic Translator

By ROBERT K. PLUMB

A public demonstration of what is believed to be the first successful use of a machine to translate meaningful texts from one language to another took place here yesterday afternoon.

This may be the culmination of centuries of search by scholars for "a mechanical translator." So far the system has a vocabulary of only 250 words. But there are no foreseeable limits to the number of words that the device can store or the number of languages it can be directed to translate.

Scholars and scientists who worked on it believe that within a few years the system may greatly increase communication, particularly in technical subjects, by making translation quick, accurate and easy.

The demonstration was at the headquarters of the International Business Machines Corporation, 590 Madison Avenue. It is the result of cooperative research by

scientists of the corporation and scholars of the Georgetown University Institute of Languages and Linguistics in Washington.

The "mechanical" part of the translation system, which is mostly electronic, is a standard commercial model of the largest International Business Machines "stock" computer. This device, called the IBM Type 701 Electronic Data Processing Machine, was put on the market last April. Since then twelve of the machines have been sold to commercial, military and university computation laboratories.

The "literary" part of the system is a mechanical model of language devised at Georgetown by Prof. Leon Dostert and Dr. Paul Garvin. The corporation's share in the project was conducted by Dr. Cuthbert C. Hurd, director of its Division of Applied Science.

In the demonstration, a girl

Continued on Page 5, Column 2

8


Lịch sử ban đầu của NLP: Dịch máy vào những năm 1950




Trí tuệ nhân tạo khởi đầu: Dự án nghiên cứu mùa hè Dartmouth năm 1956



Mạng nơ-ron: Nguồn cảm hứng từ kiến thức về nơ-ron



Warren S. McCulloch



Và

Walter Pitts



- 1898-1969. Nhà thần kinh học (bác sĩ y khoa), bác sĩ tâm thần và nhà điều khiển học, chuyển đến MIT năm 1951 nhưng Wiener đã tách khỏi ông và Pitts vào năm 1952.

- 1923-1969. Nhà logic học tự học* và nhà thần kinh học tính toán, sống lang thang ở Chicago và sau đó tại MIT; qua đời vì chứng nghiện rượu.

Năm 1943, tác phẩm "A Logical Calculus of Ideas Immanent in Nervous Activity" (Một phép tính logic về các ý tưởng ẩn chứa trong hoạt động thần kinh), mô hình toán học đầu tiên về mạng lưới thần kinh, được xuất bản, cho thấy nó có thể thực hiện được một máy Turing.



Nơron McCulloch-Pitts

Bộ khung của nguyên bản


McCulloch & Pitts năm 1943:

$$\begin{aligned} & (\cdot) = \\ & (\cdot > 0) \end{aligned}$$

Hàm này không có độ dốc, do
đó không thể học dựa trên gradient.



Frank Rosenblatt: Perceptron (Phiên bản I)



<https://news.cornell.edu/stories/2019/09/professors-perceptron-paved-way-ai-60-years-too-soon>

Sự cường điệu ban đầu về trí tuệ nhân tạo! Từ New York Times, ngày 8 tháng 7 năm 1958.

THIẾT BỊ MỚI CỦA HẢI QUÂN HỌC HỎI BẰNG CÁCH THỰC HÀNH

Nhà tâm lý học trình bày phôi thai của một máy tính được thiết kế để đọc và phát triển thông minh hơn.

Hôm nay, Hải quân đã tiết lộ phôi của một máy tính điện tử mà họ kỳ vọng sẽ có khả năng đi lại, nói chuyện, nhìn, viết, tự sinh sản và nhận thức được sự tồn tại của chính nó.

Phôi thai-Cục Khí tượng


Máy tính "704" trị giá 2.000.000 đô la đã học cách phân biệt phải và trái sau 50 lần thử trong cuộc trình diễn của Hải quân dành cho các nhà báo.



Hai quan điểm về trí tuệ nhân tạo trong những năm 1950.


Trí tuệ nhân tạo (mang tính biểu tượng)

Minsky, McCarthy, Simon, Newell



Điều khiển học

Wiener, Rosenblatt




Tìm kiếm thông tin: Vannevar Bush

Bush (1945): Như chúng ta có thể nghĩ

"Hãy xem xét một thiết bị trong tương lai dành cho từng cá nhân."

Nó giống như một loại hồ sơ và thư viện cá nhân được cơ giới hóa. Nó cần một cái tên, và để đặt ngẫu nhiên một cái tên, "memex" cũng được. Memex là một thiết bị mà cá nhân lưu trữ tất cả sách, hồ sơ và thông tin liên lạc của mình, và được cơ giới hóa để có thể tra cứu với tốc độ và tính linh hoạt vượt trội. Nó là một phần bổ sung thân mật được mở rộng cho trí nhớ của người đó.

<https://www.theatlantic.com/magazine/archive/1945/07/as-we-may-think/303881/>




Bush đã từ chức Trưởng khoa Kỹ sư tại MIT và chủ tịch Viện Carnegie.

Washington gửi thư cho chủ tịch của Nghiên cứu Quốc phòng Quốc gia


Ủy ban trong Thế chiến II (được cấp kinh phí khổng lồ, chỉ đạo toàn bộ hoạt động khoa học thời chiến, bao gồm cả...)

(Dự án Manhattan)




Cyril Cleverdon giới thiệu về phương pháp so sánh hiệu suất (benchmarking).

- Các cuộc thử nghiệm tại Cranfield (1957-1967)
- Đã định hình ý tưởng về các bài kiểm tra chuẩn mực cho ngôn ngữ, với một bộ sưu tập tài liệu, các câu hỏi và các câu trả lời đúng.
- Ông ấy có câu trả lời đầy đủ về Tính phù hợp của tài liệu trên một tập dữ liệu nhỏ!



Nguồn gốc của Xử lý ngôn ngữ tự nhiên/Ngôn ngữ học tính toán từ những năm 1950



- Các công trình nghiên cứu nền tảng về automata, ngôn ngữ hình thức, mô hình hóa xác suất và lý thuyết thông tin.
- Hệ thống ngôn ngữ đầu tiên (Davis và cộng sự)
- MT được quân đội tài trợ rất nhiều – sự tự tin thái quá
- Nhưng việc sử dụng những cỗ máy kém thông minh hơn cả... máy tính bỏ túi
- Hiểu biết hạn chế về cú pháp, ngữ nghĩa và ngữ dụng.

Tôi lấy những mốc thời gian này từ cuốn "A Short History of Computational Linguistics" của Ruth Camburn. Bà ấy là nghiên cứu sinh ngành Ngôn ngữ học tại Đại học Bang California, Fresno vào khoảng năm 2013.

Thập niên 1960: David Glenn Hays: Người sáng lập ACL và chuyên gia phân tích cú pháp phụ thuộc.




Raj Reddy

(1937-, nghiên cứu sinh tiến sĩ tại Stanford 1963-1966; giảng viên 1966-1969; CMU; giải thưởng Turing)



(Các) Sinh viên được chọn:
James Gosling, Lý Tử Võ,
Roni Rosenfeld, Alex Waibel



Joyce Friedman

(1928-2018; tại Stanford 1965-1968)



cs -109

A COMPUTER SYSTEM FOR WRITING AND TESTING
TRANSFORMATIONAL GRAMMARS

FINAL REPORT

JOYCE FRIEDMAN
PRINCIPAL INVESTIGATOR

This research was supported in part by the United
States Air Force Electronic Systems Division, under
Contract F196828-C-0035.



C. Ray
Perrault

James
Allen

David Scott
Warren




STANFORD UNIVERSITY COMPUTER SCIENCE DEPARTMENT
COMPUTATIONAL LINGUISTICS PROJECT

30 SEPTEMBER 1968



Báo cáo ALPAC (1966):

Chết tiệt, việc này khó thật!



2. Các hệ thống xử lý ngôn ngữ tự nhiên (NLP) minh họa được xây dựng thủ công, với mức độ chính thức hóa ngày càng cao.

1970-1992

Terry Winograd

(1946-, Giảng viên Đại học Stanford 1973-2014; Trí tuệ nhân tạo/Xử lý ngôn ngữ tự nhiên 1973-1984)



Seymour Papert



Terry Winograd



Stuart Shieber



Ngữ pháp hình thức và ngữ pháp dựa trên sự thống nhất cho xử lý ngôn ngữ tự nhiên: Martin Kay



Fernando Pereira




Stuart Shieber



Xây dựng ý nghĩa của ngôn ngữ con người: 1967-2017

- Phân tách câu thành các từ: Quả táo đỏ nằm trên bàn.
- Phân tích nó thành cấu trúc dữ liệu dạng cây hoặc đồ thị (sử dụng ngữ pháp phi ngữ cảnh và hơn thế nữa)
- Xây dựng ý nghĩa của nó bằng cách: (i) tra cứu từ vựng, sau đó (ii) kết hợp ngữ nghĩa, sử dụng quy tắc "từ quy tắc này sang quy tắc cách tiếp cận làm việc theo hướng lên cây (ví dụ, (((táo PP () P(đỏ)), (. bàn ()))



Xử lý ngôn ngữ tự nhiên và biểu diễn tri thức: Norvig (1986) Tiến sĩ.

Luận án của Peter Norvig: Một lý thuyết thống nhất về suy luận để hiểu văn bản (1986)

Ngôn ngữ được phân tích:

Tại một làng chài nghèo nằm trên một hòn đảo không xa bờ biển Trung Quốc, có một cậu bé tên Chang Lee sống cùng người mẹ góa phụ của mình. Mỗi ngày, cậu bé Chang dũng cảm ra khơi với chiếc lưới của mình, hy vọng bắt được vài con cá để bán lấy chút tiền mua bánh mì.

- (a) Có một vùng biển bao quanh hòn đảo, được dân làng sử dụng để đánh bắt cá và là một phần của bờ biển Trung Quốc.
- (b) Chang có ý định dùng lưới của mình để bắt cá. Lưới của anh ta là một loại lưới đánh cá.
- (c) Từ dùng để chỉ con cá
- (d) Từ "họ" ở đây dùng để chỉ Chang và mẹ của anh ấy.

A Unified Theory of Inference for Text Understanding
By
Peter Norvig
B.S. (Brown University) 1978

DISSERTATION
Submitted in partial satisfaction of the requirements for the degree of
DOCTOR OF PHILOSOPHY
in
COMPUTER SCIENCE
in the
GRADUATE DIVISION
OF THE
UNIVERSITY OF CALIFORNIA, BERKELEY



Lý thuyết thống nhất về suy luận

“Như chúng ta vừa thấy, một nền tảng kiến thức phù hợp là điều kiện tiên quyết để đưa ra những suy luận chính xác” (trang 4). Nó được xây dựng để tạo điều kiện cho việc suy luận.

Hệ thống có 6 dạng suy luận tổng quát; 2 cặp, do đó có 4 loại cơ bản:

1. Giải thích chi tiết: Điền vào một vị trí để kết nối hai thực thể.

- John có ống tiết kiệm vì LÝ DO nào đó: có tiền vì LÝ DO nào đó: mua quà

2. Giải quyết tham chiếu: **Này - đó là tham chiếu đồng nhất!!!**

3. Xem ứng dụng: Đội Red Sox đã đánh bại đội Yankees.


- Bị giết không phải là động vật; việc giết chóc được xem là một thất bại.

THUYẾT PHỤC


4. Cụ thể hóa: Suy luận chi tiết hơn.

- DI CHUYỂN bằng Ô TÔ là một ví dụ về

LÁI XE



Xử lý ngôn ngữ tự nhiên (NLP) trong những năm 1970 và 1980




- Các công trình nghiên cứu nền tảng về nhận dạng giọng nói: mô hình hóa ngẫu nhiên, mô hình Markov ẩn, "kênh nhiễu"
- Những ý tưởng từ công trình này sẽ
 Sau này sẽ tạo nên cuộc cách mạng trong xử lý ngôn ngữ thần kinh!
- Lập trình logic, trí tuệ nhân tạo dựa trên quy tắc, thuật toán xác định cho phân tích cú pháp (ví dụ: LFG)
- Sự quan tâm ngày càng tăng đối với khả năng hiểu ngôn ngữ tự nhiên: SHRDLU, LUNAR, CHAT-80
- Nhưng trí tuệ nhân tạo mang tính biểu tượng đã gặp phải trở ngại: "Mùa đông AI"

3. Xử lý ngôn ngữ tự nhiên thống kê hoặc xác suất (“StatNLP”) và sau đó là học máy có giám sát tổng quát hơn cho xử lý ngôn ngữ tự nhiên.


1993-2012

Claude Shannon



Lý thuyết toán học về truyền thông (1948)


Mô hình kênh nhiễu





<https://www.quantamagazine.org/how-claude-shannons-information-theory-invented-the-future-20201222/>

Cuộc cách mạng thống kê: những năm 1990

- Sự du nhập của những ý tưởng mới từ EE & ASR: mô hình hóa xác suất, thống kê ngữ liệu, học có giám sát, đánh giá thực nghiệm
- Các nguồn dữ liệu mới: sự bùng nổ của văn bản có thể đọc được bằng máy; dữ liệu huấn luyện được con người chú thích (ví dụ: Penn Treebank)
- Dữ liệu được chú thích + thuật toán + dự đoán xác suất
- Hạ thấp kỳ vọng: hãy quên đi việc hiểu ngữ nghĩa đầy đủ, chúng ta hãy tập trung vào nhận dạng văn bản, gắn thẻ từ loại, nhận dạng thực thể có tên (NER) và phân tích cú pháp!
- Công cụ: Bộ phân loại Naïve Bayes, HMM, PCFG, CRF (CS228!)



Fred Jelinek



Sửa lỗi chính tả dựa trên xác suất

“Cô ấy là một nữ diễn viên xuất sắc và đa tài , sở hữu sự kết hợp giữa.

Sự tự tin và quyến rũ thu hút mọi người.

Hãy ước tính xác suất của các điều chỉnh nối tiếp nhau.


$$P(\text{nữ diễn viên}|\text{đa năng}) = 0,0019$$

$$P(\text{across}|\text{versatile}) = 0.000092 \quad P(\text{whose}|\text{across}) = 0.000026$$

$$P(\text{whose}|\text{actress}) = 0.0043$$

$$P(\text{“nữ diễn viên đa năng”}) = 0,00019 \times 0,0043 = 817.000 \times 10^{-10}$$

$$P(\text{“đa năng trong nhiều lĩnh vực”}) = 0,000092 \times 0,000026 = 239 \times 10^{-10}$$



Sự trỗi dậy của máy móc: Thập niên 2000

- Có sẵn các máy móc mạnh mẽ hơn nhiều.
- củng cố những thành quả đạt được của cuộc cách mạng thống kê
- Mô hình thống kê và máy móc phức tạp hơn
Các thuật toán học máy: MaxEnt, SVM, Bayes Net, LDA, v.v.
- Dữ liệu khổng lồ: Tốc độ tăng trưởng của web gấp 100 lần, các trung tâm máy chủ khổng lồ.
- Trọng tâm chuyển từ học có giám sát sang học không giám sát
- Khơi dậy sự quan tâm đến các ứng dụng ngữ nghĩa cấp cao hơn



4. Học sâu hoặc mạng nơ-ron nhân tạo cho xử lý ngôn ngữ tự nhiên (NLP)



4a. Xử lý ngôn ngữ tự nhiên thần kinh

2013-2021

Trí tuệ nhân tạo mang tính biểu tượng so với "Điều khiển học"

Stanford, quê hương của "Hệ thống Biểu tượng"

- “Hệ thống biểu tượng” nghiên cứu các hệ thống biểu tượng có ý nghĩa đại diện cho thế giới xung quanh chúng ta—như ngôn ngữ, logic và ngôn ngữ lập trình của con người—và các hệ thống hoạt động với các biểu tượng này—như não bộ, máy tính và các hệ thống xã hội phức tạp.
- Trong khi “khoa học nhận thức” tập trung vào tâm trí và trí thông minh như những hiện tượng tự nhiên, Hệ thống ký hiệu chú trọng ngang nhau đến các hệ thống do con người xây dựng sử dụng ký hiệu để giao tiếp và biểu diễn thông tin.




Jon Barwise
(1942–2000)

Hệ thống ký hiệu so với bộ xử lý của chúng

- Ngôn ngữ là hệ thống biểu tượng ưu việt nhất; chúng ta nên nghiên cứu và sử dụng cấu trúc biểu tượng của nó.
- Điều này không chứng tỏ rằng bộ xử lý chính của các ký hiệu này–não bộ con người–được triển khai dưới dạng một hệ thống ký hiệu vật lý.
- Chúng ta không cần phải thiết kế các hệ thống xử lý ngôn ngữ tự nhiên (NLP) như những hệ thống ký hiệu vật lý.
- Não bộ giống như một mô hình mạng lưới thần kinh hơn.
- Các mô hình mạng nơ-ron nhân tạo có khả năng mở rộng tốt hơn và có thể nắm bắt được thế giới được biểu diễn bởi...
biểu tượng

con mèo




41

Học sâu cho nhận dạng giọng nói

- Nhận dạng giọng nói lần đầu tiên cho thấy sự thành công đột phá của các phương pháp xác suất: HMM và GMM.
- Những kết quả đột phá đầu tiên của “học sâu” trên các tập dữ liệu lớn cũng đã xuất hiện trong lĩnh vực nhận dạng giọng nói.
- George Dahl và cộng sự (2010/2012): Mạng nơ-ron sâu được huấn luyện trước phụ thuộc vào ngữ cảnh để nhận dạng giọng nói với từ vựng lớn

Mô hình âm thanh \ WER	RT03S	FSH	Hub5	SWB
GMM truyền thống (D. et al. 2012)	27.4			23,6
Học sâu (Dahl và cộng sự, 2012)	18,5 (33%)	16,1 (32%)		
Học sâu (Saon và cộng sự, 2017)	8.0 (71%)			5,5 (77%)



“(Mạng thần kinh nhân tạo)” hoặc các mô hình “học sâu” cho ý nghĩa từ ngữ

Chúng ta học cách biểu diễn một từ dưới dạng một vectơ các số.

đa năng =

$$\begin{pmatrix} 0.286 \\ 0.792 \\ 0,177 \\ 0,107 \\ 0.109 \\ 0,542 \\ 0,349 \\ 0.271 \end{pmatrix}$$

Các vectơ tương tự = ý nghĩa tương tự

Tìm hiểu các vectơ thông qua sự tương đồng về phân bố.



Chúng ta học các vectơ từ đó bằng cách nào?

“Bạn sẽ nhận biết một từ qua những từ đi kèm với nó” (JR Firth 1957: 11)

Bất kỳ thiết bị nào có trình duyệt web, từ máy tính xách tay và máy tính bảng đến điện thoại thông minh.
Người dùng có thể tải xuống bản cập nhật này cho máy tính để bàn hoặc máy tính xách tay từ trang web Microsoft Update.


Những từ này sẽ đại diện cho máy tính xách tay

Việc xác định sự tương đồng thông qua phân bố ngữ cảnh trong văn bản là một trong những ý tưởng thành công nhất.
về ngôn ngữ học tính toán hiện đại

Mạng mã hóa-giải mã RNN


Bộ mã hóa

Bộ giải mã



$$h_t = \tanh(W[x_t] + U h_{t-1} + b)$$


Mạng mã hóa-giải mã LSTM [Sutskever et al. 2014]



Nút thắt cổ chai

Tiến trình MT theo thời gian

[Edinburgh En-De WMT newstest2013 Cased BLEU; NMT 2015 từ Đại học Montréal]



Nguồn: http://www.meta-net.eu/events/meta-forum-2016/slides/09_sennrich.pdf


Trên Google Neural MT, xem: <https://www.nytimes.com/2016/12/14/magazine/the-great-ai-awakening.html>

4. Học sâu hoặc mạng nơ-ron nhân tạo cho xử lý ngôn ngữ tự nhiên (NLP)

4b. Mô hình ngôn ngữ quy mô lớn

2022-nay

Sự trỗi dậy của Trí tuệ nhân tạo tạo sinh: Các công ty thuộc S&P 500 đang thảo luận về “Trí tuệ nhân tạo”




| 2024 | 2025

ChatGPT ra mắt

Ngôn ngữ lớn Mô hình

Nguồn: GPT 4o

Một hình ảnh trừu tượng theo phong cách manga màu pastel về một mô hình ngôn ngữ khổng lồ như một cỗ máy lớn tiếp nhận văn bản và tạo ra những bài viết mới trên một cuộn giấy vô tận, được duy trì bởi một số lượng lớn các nhà khoa học và kỹ sư.



Lịch sử các mô hình ngôn ngữ

1913 Andrey A. Markov nghiên cứu xác suất chuyển đổi phụ âm-nguyên âm trong tiểu thuyết Eugene Onegin của Alexander Pushkin , bằng cách phát triển Mô hình Markov.



1948 Claude E. Shannon phát triển Lý thuyết toán học về thông tin;
Nội dung này khám phá các mô hình n-gram ở cấp độ ký tự/từ , entropy và quá trình tạo văn bản.



1975 Nhóm của Frederick Jelinek tại IBM đã định nghĩa và đặt tên cho khái niệm hiện đại về "mô hình ngôn ngữ" (xác suất) để dự đoán từ tiếp theo.
Được sử dụng để sửa lỗi chính tả, nhận dạng giọng nói, dịch máy.



Nhưng công nghệ này không được coi là con đường dẫn đến máy móc có trí tuệ nhân tạo:
Để làm được điều đó, chúng ta cần các mô hình về trí nhớ, biểu diễn tri thức, hệ thống lập kế hoạch và suy luận trên các khái niệm trừu tượng.

Lịch sử của các mô hình ngôn ngữ quy mô lớn

- 1998** Mô hình ngôn ngữ dựa trên cây CPAT với ứng dụng xác thực văn bản tiếng Trung. ROCLing 1998. Lần đầu tiên tôi biết đến việc sử dụng tam âm "LLM"; kho ngữ liệu 200 triệu từ.
- 2000** Mô hình ngôn ngữ xác suất thần kinh. Bengio, Ducharme & Vincent, NIPS 2000
Mô hình ngôn ngữ thần kinh đầu tiên được xây dựng trên kho ngữ liệu 32 triệu từ, 31.000 từ vựng.
- 2007** Các mô hình ngôn ngữ quy mô lớn trong dịch máy. Brants, Popat, Xu, Och và Dean.
EMNLP 2007. Mô hình n-gram với kho ngữ liệu 2 nghìn tỷ token, hỗ trợ tối đa 5-gram.
- 2018** GPT (Radford, Narasimhan, Salimans & Sutskever) và BERT (Devlin, Chang, Lee & Toutanova). Kho dữ liệu 3,3 tỷ token.
- 2020–** Các mô hình ngôn ngữ thần kinh với hơn 100 tỷ tham số được huấn luyện trên hơn 1 nghìn tỷ token:
GPT-3, GPT-4, PaLM 2, Llama 3, Nemotron-4, ..

Lịch sử của các mô hình ngôn ngữ quy mô lớn

- 1998** Mô hình ngôn ngữ dựa trên cây CPAT với ứng dụng xác thực văn bản tiếng Trung. ROCLing 1998. Lần đầu tiên tôi biết đến việc sử dụng tam âm "LLM"; kho ngữ liệu 200 triệu từ.
- 2000** Mô hình ngôn ngữ xác suất thần kinh. Bengio, Ducharme & Vincent, NIPS 2000
 Không đủ sức mạnh xử lý!
 Mô hình ngôn ngữ thần kinh đầu tiên được xây dựng trên kho ngữ liệu 32 triệu từ, 31.000 từ vựng.
- 2007** Các mô hình ngôn ngữ lớn trong dịch máy. Brants, Popat, Xu, Och và sự thiếu linh hoạt của mô hình!
 Dean. EMNLP 2007. Mô hình n-gram với kho ngữ liệu 2 nghìn tỷ token, hỗ trợ tối đa 5-gram.
- 2018** GPT (Radford, Narasimhan, Salimans & Sutskever) và BERT (Devlin, Chang, Không đủ dữ liệu!
 (Lee & Toutanova). Kho dữ liệu 3,3 tỷ token
- 2020-** Các mô hình ngôn ngữ thần kinh với hơn 100 tỷ tham số được huấn luyện trên hơn 1 nghìn tỷ token:
 GPT-3, GPT-4, PaLM 2, Llama 3, Nemotron-4, LLMs hoạt động cực kỳ nhanh!

ChatGPT 4o


Write a sonnet praising Wikipedia in which each line begins with the letter W

Wikipedia: A Sonnet of Wonder

With wisdom vast, it spans the world so wide,
Wielding the wealth of knowledge, free to share.
Words weave through time where curious minds confide,
Whispering truths with patience, just and fair.
Wondrous it stands, a beacon shining bright,
Warding off darkness, doubt, and false pretense.
Wrought by the hands of many, day and night,
Witness to learning's boundless recompense.
Who dares to claim the heights of thought alone?
Whence comes this trove but hearts in concert joined?
While scholars build on stones that others've known,
Waking the past, their voices intertwine.
Wisdom and will sustain this noble dream,
Wikipedia—our light, our endless stream.

Các chuyên gia tư vấn sử dụng GPT-4 đạt hiệu quả cao hơn so với những người không sử dụng.

- Các chuyên gia tư vấn (từ Boston Consulting Group) sử dụng GPT-4 đã hoàn thành trung bình nhiều hơn 12,2% nhiệm vụ, hoàn thành nhiệm vụ nhanh hơn 25,1% và tạo ra kết quả chất lượng cao hơn 40% so với những người không sử dụng AI.
- Việc sử dụng LLM đã cải thiện đáng kể hiệu suất của những người có năng lực thấp hơn
- Kết quả có thể khác nhau tùy thuộc vào nhiệm vụ.
 - Dell'Acqua và cộng sự. 2023; Mollick 2023



Phân bố chất lượng đầu ra trên tất cả các nhiệm vụ. Nhóm xanh dương không sử dụng GPT-4; nhóm xanh lá cây và nhóm đỏ sử dụng GPT-4; nhóm đỏ được đào tạo thêm về cách sử dụng AI.

Liệu GPT-4 có thể viết truyện hư cấu đạt chất lượng tương đương với truyện hư cấu trên tạp chí *New Yorker* không?

Tin tốt! Không! (Ít nhất là vào năm 2023.)

GPT-4 vẫn kém hơn 3-10 lần về khả năng viết sáng tạo!

Art or Artifice? Large Language Models and the False Promise of Creativity

TUHIN CHAKRABARTY, Columbia University, USA

PHILIPPE LABAN, Salesforce AI Research, USA

DIVYANSH AGARWAL, Salesforce AI Research, USA

SMARANDA MURESAN, Columbia University, USA


CHIEN-SHENG WU, Salesforce AI Research, USA

Researchers have argued that large language models (LLMs) exhibit high-quality writing capabilities from blogs to stories. However, evaluating objectively the creativity of a piece of writing is challenging. Inspired by the Torrance Test of Creative Thinking (TTCT) [61], which measures *creativity as a process*, we use the Consensual Assessment Technique [3] and propose *Torrance Test of Creative Writing* (TTCW) to evaluate *creativity as product*. TTCW consists of 14 binary tests organized into the original dimensions of Fluency, Flexibility, Originality, and Elaboration. We recruit 10 creative writers and implement a human assessment of 48 stories written either by professional authors or LLMs using TTCW. Our analysis shows that LLM-generated stories pass 3-10X less TTCW tests than stories written by professionals. In addition, we explore the use of LLMs as assessors to automate the TTCW evaluation, revealing that none of the LLMs positively correlate with the expert assessments.

<https://arxiv.org/abs/2309.14556>

Lịch sử xử lý ngôn ngữ tự nhiên

CS224N/Ling284



Christopher Manning

Bài giảng 1