

BỘ CÂU HỎI TRẮC NGHIỆM & ĐÁP ÁN CHI TIẾT

NLP, TF-IDF & INFORMATION RETRIEVAL (CÂU 1–30)

PHẦN 1: NỘI DUNG CÂU HỎI

Câu 1.

Tại sao thuật toán Okapi BM25 thường cho kết quả xếp hạng vượt trội so với TF-IDF truyền thống trên các hệ thống tìm kiếm tài liệu thực tế?

- BM25 tích hợp sẵn mạng nơ-ron nhúng từ (Word Embeddings) để hiểu ngữ nghĩa chuyên sâu.
- BM25 có cơ chế bão hòa tần suất từ (TF saturation) và tính chỉnh phạt độ dài văn bản linh hoạt thông qua các tham số k_1 và b .
- BM25 không phụ thuộc vào tần suất tài liệu ngược IDF trong quá trình tính toán.
- BM25 hoàn toàn giải quyết được hiện tượng các từ không nằm trong từ điển (OOV).

Câu 2.

Trong chỉ số đánh giá xếp hạng DCG, tại sao vị trí thứ i lại được chia cho hệ số giảm trừ $\log_2(i + 1)$ thay vì chia cho chính i ?

- Để đảm bảo giá trị DCG luôn nằm trong khoảng giới hạn từ 0.0 đến 1.0.
- Để triệt tiêu các giá trị độ liên quan bị âm trong tập dữ liệu.
- Hàm logarit mô phỏng sự suy giảm mức độ chú ý của người dùng theo thứ hạng một cách từ tốn hơn so với sự suy giảm tuyến tính $1/i$.
- Tránh hiện tượng số nguyên bị tràn bộ nhớ khi tính toán với danh sách dài.

Câu 3.

Tại sao trong công thức Sublinear TF scaling

$$\text{tf}(t, d) = 1 + \log(\text{tf}(t, d)),$$

người ta lại bắt buộc phải cộng thêm 1 vào giá trị logarit của tần suất?

- Để tránh lỗi chia cho 0 khi tính toán đại số tuyến tính.
- Để đảm bảo khi từ xuất hiện đúng 1 lần ($\text{tf} = 1$), giá trị $\text{tf}_{\text{scaled}} = 1$, tạo sự chuyển tiếp liên tục mượt mà với $\text{tf} = 0$.
- Để ép tất cả các trọng số TF-IDF thu được luôn nằm trong khoảng $[0, 1]$.
- Để làm cho ma trận TF-IDF luôn có tổng các hàng bằng 1.0.

Câu 4.

Khi xử lý dữ liệu tiếng Việt thu thập từ nhiều nguồn web khác nhau, hiện tượng từ “hòa” biểu diễn bằng mã định sẵn (NFC) không khớp với mã tổ hợp (NFD) gây ra lỗi phân tách từ điển. Bước chuẩn hóa nào bắt buộc phải thực hiện đầu tiên?

- Chuyển đổi văn bản sang dạng mảng mã ASCII.
- Áp dụng ngay thuật toán Stemming Snowball.
- Tăng giá trị tham số `sublinear_tf=True`.
- Chuẩn hóa chuỗi Unicode về cùng một dạng (ưu tiên NFC) bằng thư viện `unicodedata`.

Câu 5.

Bạn xây dựng mô hình phân loại rác truyền thông với tập dữ liệu gồm 99% tin bình thường và 1% tin độc hại. Sau khi trích xuất TF-IDF, nếu đánh giá mô hình bằng chỉ số Accuracy trên tập dữ liệu gốc này, nguy cơ nào sau đây chắc chắn xảy ra?

- a. Độ đo Cosine giữa hai văn bản bất kỳ thuộc lớp thiểu số luôn bằng 0.
- b. Mô hình ngây thơ dự đoán tất cả là tin bình thường vẫn đạt Accuracy 99% nhưng hoàn toàn vô dụng trong việc bắt tin độc hại.
- c. Ma trận TF-IDF sẽ tự động loại bỏ toàn bộ 1% lớp thiểu số do vi phạm quy tắc ma trận vuông.
- d. Giá trị IDF của các từ thuộc lớp độc hại sẽ bị đẩy xuống âm do xuất hiện ít.

Câu 6.

Trong đối tượng `sklearn.pipeline.Pipeline`, bước tiền xử lý văn bản `TfidfVectorizer` bắt buộc phải đóng vai trò là một thành phần như thế nào?

- a. Là một **Estimator** cuối cùng chỉ triển khai phương thức `predict()`.
- b. Là một đối tượng xử lý bất đồng bộ bắt buộc chạy trên GPU.
- c. Là một **Transformer** triển khai đầy đủ hai phương thức `fit()` và `transform()`.
- d. Là một hàm Python thuần túy truyền vào tham số **function**.

Câu 7.

Trong công thức IDF có smoothing: $idf(t) = \ln\left(\frac{1+N}{1+df(t)}\right) + 1$. Kỹ thuật cộng 1 vào mẫu số $1 + df(t)$ có tác dụng kỹ thuật trực tiếp nào?

- a. Biến đổi vector biểu diễn văn bản thành vector đặc.
- b. Tránh lỗi chia cho 0 (Zero Division) khi gặp từ mới chưa từng xuất hiện trong tập huấn luyện ($df(t) = 0$).
- c. Làm cho ma trận TF-IDF luôn luôn có thể nghịch đảo được.
- d. Đảm bảo giá trị IDF luôn nằm trong khoảng $[-1, 1]$.

Câu 8.

Khi xây dựng hệ thống phát hiện ngôn ngữ (Language Identification) hoặc xử lý các ngôn ngữ dính liền không có khoảng trắng rõ ràng, phương pháp trích xuất đặc trưng nào tỏ ra vượt trội?

- a. Word-level Unigrams kết hợp với danh sách từ dừng mở rộng.
- b. Mô hình TF-IDF thuần túy chỉ giữ lại các ký tự số và dấu câu.
- c. Chỉ sử dụng các số liệu thống kê về độ dài trung bình của câu.
- d. N-grams ở cấp độ ký tự (Character-level N-grams).

Câu 9.

Hai văn bản d_1 và d_2 không chứa bất kỳ từ nào chung trong từ điển. Giá trị độ tương đồng Cosine giữa hai vector biểu diễn TF-IDF của chúng là bao nhiêu?

- a. 0.0
- b. 1.0
- c. 0.5
- d. -1.0

Câu 10.

Một hệ thống tìm kiếm nội bộ doanh nghiệp gặp hiện tượng Recall cực kỳ thấp: người dùng tìm “báo cáo tài chính” nhưng không thấy các tài liệu chứa “bản kê khai tài chính” hay “báo cáo thu chi”. Kỹ thuật nào giúp khắc phục triệt để vấn đề này?

- a. Tăng ngưỡng `min_df` lên để loại bỏ bớt từ xuất hiện ít.
- b. Chuyển toàn bộ văn bản sang dạng mã hóa Base64 trước khi trích xuất đặc trưng.
- c. Mở rộng truy vấn (Query Expansion) bằng từ điển đồng nghĩa (Thesaurus) hoặc mô hình Semantic Search.
- d. Bỏ qua chuẩn hóa vector để giữ nguyên giá trị độ dài tuyệt đối.

Câu 11.

So sánh giữa biểu diễn TF-IDF (Sparse) và biểu diễn Nhúng từ/văn bản (Dense Embeddings như BERT, Word2Vec), phát biểu nào sau đây phản ánh ĐÚNG bản chất?

- a. TF-IDF có khả năng học ngữ cảnh đảo ngược của từ nhờ cơ chế Attention.
- b. TF-IDF luôn tốn dung lượng bộ nhớ hơn Dense Embeddings trong mọi trường hợp.
- c. Dense Embeddings bị giới hạn bởi không thể biểu diễn được các từ mới chưa từng xuất hiện.
- d. TF-IDF mạnh về khớp chính xác từ khóa (Lexical Matching), trong khi Dense Embeddings mạnh về bắt ngữ nghĩa đồng nghĩa (Semantic Matching).

Câu 12.

Khi từ điển V tăng lên 500.000 từ, mô hình Logistic Regression sử dụng TF-IDF bắt đầu bị suy giảm hiệu năng do “Lời nguyền chiều dữ liệu” (Curse of Dimensionality). Kỹ thuật giảm chiều nào giữ được tính dễ giải thích (Interpretability) của từ vựng gốc?

- a. Chiếu ma trận sang không gian mới bằng kỹ thuật TruncatedSVD / LSA.
- b. Gộp tất cả các văn bản thành một chuỗi duy nhất rồi chia lại theo độ dài cố định.
- c. Áp dụng thuật toán t-SNE để giảm chiều về 2D.
- d. Lựa chọn đặc trưng dựa trên kiểm định Chi-square (χ^2) hoặc Mutual Information.

Câu 13.

Một hệ thống trả về 10 tài liệu cho một truy vấn. Biết rằng trong cơ sở dữ liệu có tổng cộng 5 tài liệu thực sự liên quan. Trong Top 10 tài liệu trả về, chỉ có các tài liệu tại vị trí thứ 1, 3, 5 là liên quan. Giá trị Precision@5 và Recall@10 lần lượt là bao nhiêu?

- a. Precision@5 = 0.50; Recall@10 = 0.50
- b. Precision@5 = 0.30; Recall@10 = 0.30
- c. Precision@5 = 0.60; Recall@10 = 0.60
- d. Precision@5 = 0.60; Recall@10 = 1.00

Câu 14.

Một tài liệu D_1 chứa câu “AI làm thay đổi thế giới”. Tài liệu D_2 được tạo ra bằng cách lặp lại câu đó 10 lần: “AI làm thay đổi thế giới. AI làm thay đổi thế giới...”. Độ tương đồng Cosine giữa D_1 và D_2 khi sử dụng TF-IDF chuẩn hóa L_2 bằng bao nhiêu?

- a. 0.0
- b. 0.1

- c. 0.5
- d. 1.0

Câu 15.

Trong bài toán Phân loại Ý định người dùng (Intent Classification) cho trợ lý ảo chatbot, câu “Tôi muốn chuyển khoản từ tài khoản A sang tài khoản B” nếu loại bỏ từ dừng (“từ”, “sang”) sẽ gây tác hại gì?

- a. Làm tăng số lượng từ vựng trong từ điển lên gấp hai lần.
- b. Khiến chatbot không thể nhận diện được tên riêng của hai tài khoản A và B.
- c. Khiến cho phép tính Cosine Similarity luôn bị âm.
- d. Làm mất mối quan hệ hướng của giao dịch (đầu là nguồn, đầu là đích), khiến chatbot nhầm lẫn hai tài khoản.

Câu 16.

Trong một hệ thống phân tích văn bản y tế, quy trình tách từ (Tokenization) đơn giản bằng khoảng trắng biến các thuật ngữ như “U.S.A.”, “COVID-19”, và “e-mail” thành các mảnh độc lập hoặc sai lệch. Phương pháp nào giải quyết hiệu quả triệt để vấn đề này?

- a. Xóa toàn bộ các ký tự đặc biệt và dấu câu trước khi áp dụng tách từ theo khoảng trắng.
- b. Chuyển đổi toàn bộ văn bản sang dạng mã hóa Unicode NFD để tự động phân tách dấu câu.
- c. Áp dụng thuật toán Stemming Porter để đưa các thuật ngữ phức tạp về dạng gốc trước khi tách.
- d. Sử dụng bộ tách từ dựa trên biểu thức chính quy (Regex Tokenizer) kết hợp danh sách ngoại lệ được cấu hình sẵn.

Câu 17.

Khi áp dụng mô hình TF-IDF cho tập dữ liệu bao gồm các câu phản hồi ngắn của khách hàng (1–5 từ/câu), hiện tượng tiêu cực nào sau đây thường xuyên xảy ra nhất?

- a. Tràn bộ nhớ RAM do kích thước từ điển bùng nổ vượt giới hạn.
- b. Thời gian tính toán tích vô hướng tăng lên theo quy mô lũy thừa.
- c. Giá trị IDF của tất cả các từ đồng loạt nhận giá trị bằng 0.
- d. Ma trận cực kỳ thưa và hầu hết các cặp văn bản đều có Cosine Similarity bằng 0 do không có từ trùng lặp.

Câu 18.

Một hệ thống tìm kiếm thông tin được đánh giá trên 3 truy vấn Q_1, Q_2, Q_3 . Kết quả vị trí của tài liệu liên quan đầu tiên thu được lần lượt là: Q_1 tìm thấy ở vị trí thứ 1; Q_2 không có tài liệu liên quan trong Top-10 ($r_q \rightarrow \infty$); Q_3 tìm thấy ở vị trí thứ 4. Chỉ số MRR (Mean Reciprocal Rank) của hệ thống là bao nhiêu?

- a. 0.333
- b. 0.417
- c. 0.250
- d. 0.625

Câu 19.

Một kỹ sư đang triển khai tìm kiếm văn bản bằng Scikit-Learn với cơ sở dữ liệu gồm $N = 10$ tài liệu. Trong đó, thuật ngữ t xuất hiện ở đúng 3 tài liệu. Kỹ sư này cần tính giá trị TF-IDF (chưa chuẩn hóa L_2) của thuật ngữ t đối với một văn bản D có độ dài 5 từ, chứa t đúng 2 lần. Công thức IDF smoothing được áp dụng là:

$$idf(t) = \log_e \left(\frac{1 + N}{1 + df(t)} \right) + 1$$

Giá trị thu được sau khi làm tròn 3 chữ số thập phân là bao nhiêu?

- a. 2.012
- b. 0.805
- c. 0.405
- d. 1.006

Câu 20.

Trình tự thực hiện các bước tiền xử lý văn bản nào sau đây là CHUẨN KỸ THUẬT nhất trong một Pipeline NLP truyền thống?

- a. Loại bỏ từ dừng → Stemming → Làm sạch văn bản thô → Tách từ → TF-IDF.
- b. Lemmatization → Tách từ → Loại bỏ từ dừng → Hạ chữ thường → Làm sạch văn bản thô → TF-IDF.
- c. Trích xuất TF-IDF → Tách từ → Loại bỏ từ dừng → Hạ chữ thường → Làm sạch văn bản thô.
- d. Làm sạch văn bản thô (HTML/Ký tự đặc biệt) → Hạ chữ thường → Tách từ (Tokenization) → Loại bỏ từ dừng → Lemmatization/Stemming → Trích xuất TF-IDF.

Câu 21.

Trong một tập dữ liệu hồ sơ bệnh án, chuỗi “phủ định: không ho, không sốt” nếu áp dụng Bag-of-Words Unigram thông thường sẽ biến thành tập hợp các từ ["không", "ho", "sốt"]. Nguy cơ nào xảy ra khi huấn luyện mô hình chẩn đoán?

- a. Thời gian huấn luyện mô hình bị tăng lên gấp 10 lần.
- b. Tất cả các triệu chứng sẽ nhận giá trị trọng số IDF bằng 0.
- c. Ma trận biểu diễn bị rơi vào trạng thái suy biến không thể nghịch đảo.
- d. Mô hình dự đoán sai bệnh nhân bị ho và sốt do mất liên kết giữa từ phủ định “không” và các triệu chứng đi kèm.

Câu 22.

Trong một bài toán phân loại email rác, bạn nhận thấy mô hình Naive Bayes kết hợp TF-IDF đạt độ chính xác 98% trên tập Train nhưng chỉ đạt 65% trên tập Validation. Phương án xử lý tiền xử lý nào phù hợp nhất để khắc phục?

- a. Tắt toàn bộ tính năng lọc từ dừng và giữ lại các ký tự đặc biệt.
- b. Bỏ bước fit trên tập Train và chuyển sang fit trên tập Validation.
- c. Chuyển từ `ngram_range=(1,1)` sang `ngram_range=(1,5)` để mô hình học thuộc ngữ cảnh tốt hơn.
- d. Giảm bớt số lượng đặc trưng bằng cách tăng `min_df`, loại bỏ N-gram quá dài, hoặc áp dụng L2 Regularization.

Câu 23.

Nếu ta nhân tất cả các giá trị trong vector biểu diễn TF-IDF của một văn bản d với một hằng số dương c (ví dụ: nhân đôi tần suất xuất hiện bằng cách nối hai văn bản giống hệt nhau), giá trị Cosine Similarity giữa d và truy vấn q sẽ thay đổi như thế nào?

- a. Giảm đi c lần.
- b. Hoàn toàn không thay đổi.
- c. Tăng lên theo bình phương hằng số c .
- d. Tăng lên gấp c lần.

Câu 24.

Sau khi áp dụng chuẩn hóa L_2 cho các vector hàng biểu diễn tài liệu trong ma trận TF-IDF, thuộc tính hình học nào sau đây của các vector tài liệu sẽ luôn được đảm bảo?

- a. Giá trị lớn nhất trong mỗi vector tài liệu luôn bằng 1.0.
- b. Độ dài Euclid (Euclidean norm) của mỗi vector tài liệu luôn bằng 1.0.
- c. Tổng giá trị các phần tử trong mỗi vector tài liệu luôn bằng 1.0.
- d. Tất cả các phần tử nhỏ hơn 0 sẽ tự động bị quy về giá trị 0.0.

Câu 25.

Một thư viện lập trình cung cấp hàm tính `cosine_distance(u, v)`. Mối quan hệ toán học giữa Cosine Distance và Cosine Similarity là gì?

- a. $\text{Cosine Distance} = \frac{1}{\text{Cosine Similarity}}$
- b. $\text{Cosine Distance} = \sqrt{1 - \text{Cosine Similarity}^2}$
- c. $\text{Cosine Distance} = -\log(\text{Cosine Similarity})$
- d. $\text{Cosine Distance} = 1 - \text{Cosine Similarity}$

Câu 26.

Một trang tin tức áp dụng truy vấn khớp chính xác tất cả các từ (AND query). Người dùng gõ “chính sách thuế thu nhập cá nhân 2026” và nhận được 0 kết quả. Giải pháp tiền xử lý/truy vấn nào giúp trả về các bài viết liên quan phù hợp nhất?

- a. Áp dụng thuật toán mã hóa âm thanh Soundex cho từ khóa.
- b. Ép buộc bộ từ điển loại bỏ các từ có tần suất xuất hiện nhỏ hơn 100.
- c. Xóa bỏ tất cả các con số trong từ khóa truy vấn của người dùng.
- d. Chuyển đổi sang truy vấn nối lỏng (OR query) kết hợp xếp hạng điểm TF-IDF hoặc BM25 từ cao xuống thấp.

Câu 27.

Một trang web thương mại điện tử muốn người dùng khi gõ “điện thoại iphone” sẽ thấy các sản phẩm có nhãn “iPhone 15 Pro”, “iPhone 14” được xếp lên đầu. Yếu tố tiền xử lý nào quyết định việc ghép nối này?

- a. Tắt tính năng tính IDF để các từ xuất hiện bình đẳng.
- b. Sử dụng phép đo khoảng cách Manhattan thay vì Cosine.

- c. Chuyển chữ thường (Lowercasing) và Stemming/Lemmatization để bỏ qua sự khác biệt viết hoa/thường của tên thương hiệu.
- d. Loại bỏ toàn bộ các con số như “15”, “14” ra khỏi tên sản phẩm.

Câu 28.

Một công ty thương mại điện tử muốn đánh giá hệ thống gợi ý sản phẩm. Họ quan tâm đến việc các sản phẩm thực sự liên quan phải xuất hiện càng cao càng tốt trên trang nhất (Top 5 kết quả). Độ đo đánh giá nào phản ánh chính xác nhất yêu cầu thứ tự này?

- a. Recall@100.
- b. Simple Accuracy Index.
- c. Mean Average Precision (MAP) hoặc NDCG@5.
- d. Precision@5 thuần túy.

Câu 29.

Tại sao thiết lập `ngram_range=(2,2)` (chỉ sử dụng Bigram) đôi khi cho ra kết quả phân loại tốt hơn `ngram_range=(1,2)` (kết hợp cả Unigram và Bigram)?

- a. Loại bỏ nhiều từ các từ đơn đứng riêng lẻ và tập trung hoàn toàn vào các cấu trúc cụm từ ghép có ý nghĩa rõ ràng.
- b. Giúp ma trận biểu diễn chuyển đổi thành ma trận vuông.
- c. Tự động khắc phục triệt để lỗi OOV trên tập Test.
- d. Làm giảm thời gian tính toán về 0 giây.

Câu 30.

Định luật Zipf khẳng định tần suất $f(r)$ của từ có thứ hạng r trong tập văn bản tuân theo tỷ lệ nghịch nào sau đây?

- a. $f(r) \propto \log(r)$
- b. $f(r) \propto r^2$
- c. $f(r) \propto e^{-r}$
- d. $f(r) \propto \frac{1}{r^\alpha}$ (với $\alpha \approx 1$).

PHẦN 2: ĐÁP ÁN VÀ LỜI GIẢI CHI TIẾT (CÂU 1–30)

1. Bảng Tổng Hợp Đáp Án Nhanh

Câu	Đáp án	Câu	Đáp án	Câu	Đáp án
Câu 1	b	Câu 11	d	Câu 21	d
Câu 2	c	Câu 12	d	Câu 22	d
Câu 3	b	Câu 13	c	Câu 23	b
Câu 4	d	Câu 14	d	Câu 24	b
Câu 5	b	Câu 15	d	Câu 25	d
Câu 6	c	Câu 16	d	Câu 26	d
Câu 7	b	Câu 17	d	Câu 27	c
Câu 8	d	Câu 18	b	Câu 28	c
Câu 9	a	Câu 19	b	Câu 29	a
Câu 10	c	Câu 20	d	Câu 30	d

2. Lời Giải Thích Chi Tiết Từng Câu Hỏi

- Câu 1:** **Chọn b.** Okapi BM25 khắc phục sự tăng điểm tuyến tính quá đà của TF-IDF bằng cơ chế trần bão hòa (TF saturation không chế bởi tham số k_1) và cơ chế chuẩn hóa phạt độ dài văn bản linh hoạt thông qua tham số b .
- Câu 2:** **Chọn c.** Mẫu số giảm trừ theo hàm $\log_2(i+1)$ phản ánh đúng hành vi người dùng trong thực tế: sự chú ý giảm dần theo thứ hạng nhưng không giảm đột ngột quá gắt như hàm tuyến tính $1/i$.
- Câu 3:** **Chọn b.** Khi $tf = 1$, giá trị $\log(1) = 0$. Phép cộng thêm 1 bảo đảm $1 + \log(1) = 1$, giúp giữ nguyên giá trị 1 và tạo sự chuyển tiếp liên tục mượt mà với trường hợp từ không xuất hiện ($tf = 0$).
- Câu 4:** **Chọn d.** Lỗi mã hóa Unicode (NFC dựng sẵn so với NFD tổ hợp) khiến cùng một từ trông giống hệt nhau nhưng có chuỗi byte khác nhau. Chuẩn hóa về NFC thông qua `unicodedata.normalize('NFC', ...)` là bước bắt buộc trước khi đưa vào từ điển.
- Câu 5:** **Chọn b.** Hiện tượng Accuracy Paradox khi dữ liệu mất cân bằng nghiêm trọng (99:1): Một mô hình chỉ cần dự đoán tất cả là tin bình thường thì Accuracy đã đạt 99%, nhưng hoàn toàn vô dụng vì Recall của lớp tin độc hại bằng 0%.
- Câu 6:** **Chọn c.** Trong Pipeline Scikit-Learn, tất cả các bước biến đổi dữ liệu trước bước estimator cuối cùng bắt buộc phải là một *Transformer* cài đặt đủ 2 hàm `fit()` và `transform()`.
- Câu 7:** **Chọn b.** Khi gặp từ khóa mới chưa từng xuất hiện trong tập huấn luyện ($df(t) = 0$), nếu không cộng thêm 1 vào mẫu số thì phép chia $\frac{1+N}{df(t)}$ sẽ gây lỗi ZeroDivisionError.
- Câu 8:** **Chọn d.** Character-level N-grams (N-gram ký tự) không cần biết ranh giới từ nên xử lý xuất sắc các ngôn ngữ viết dính liền (tiếng Trung, Nhật, Thái) hoặc bài toán phát hiện ngôn ngữ dựa trên hình thái ký tự.
- Câu 9:** **Chọn a.** Hai văn bản không chứa bất kỳ từ nào chung đồng nghĩa với tích vô hướng của hai vector bằng 0. Do đó, Cosine Similarity bằng 0.0.
- Câu 10:** **Chọn c.** Hiện tượng từ đồng nghĩa hoặc cách dùng từ khác nhau (Vocabulary Mismatch) làm giảm Recall. Mở rộng truy vấn (Query Expansion) hoặc tìm kiếm ngữ nghĩa (Semantic Search) giúp giải quyết triệt để vấn đề này.

Câu 11: **Chọn d.** TF-IDF hoạt động dựa trên so khớp chính xác mặt chữ (Lexical Matching), trong khi Dense Embeddings biểu diễn ngữ nghĩa trong không gian liên tục (Semantic Matching).

Câu 12: **Chọn d.** Kiểm định Chi-square (χ^2) hoặc Mutual Information là các phương pháp Feature Selection (lựa chọn đặc trưng), giữ lại nguyên vẹn các từ vựng có tính phân loại cao nhất nên bảo toàn 100% tính dễ giải thích so với các phép biến đổi không gian như SVD hay t-SNE.

Câu 13: **Chọn c.**

$$\text{Precision@5} = \frac{\text{Số tài liệu đúng trong Top 5}}{5} = \frac{3}{5} = 0.60 \text{ (tài liệu tại rank 1, 3, 5)}.$$

$$\text{Recall@10} = \frac{\text{Số tài liệu đúng lấy được}}{\text{Tổng số tài liệu thực sự đúng}} = \frac{3}{5} = 0.60.$$

Câu 14: **Chọn d.** Tài liệu D_2 lặp lại toàn bộ các từ của D_1 với cùng tỷ lệ tần suất, nên vector TF-IDF của D_2 cùng phương với D_1 ($v_2 = 10 \cdot v_1$). Khi áp dụng chuẩn hóa L_2 , hai vector đơn vị thu được giống hệt nhau, góc giữa chúng bằng $0^\circ \implies \text{Cosine} = 1.0$.

Câu 15: **Chọn d.** Các hư từ như “từ”, “sang” biểu diễn hướng di chuyển của dòng tiền (nguồn và đích). Xóa chúng đi khiến mô hình mất ngữ cảnh định hướng giao dịch.

Câu 16: **Chọn d.** Các thuật ngữ có dấu chấm, gạch nối cần dùng Regex Tokenizer đi kèm bảng từ điển ngoại lệ (Exceptions/Whitelist) để không bị xé vụn từ.

Câu 17: **Chọn d.** Câu quá ngắn (1–5 từ) chứa rất ít từ vựng, dẫn đến xác suất hai câu bất kỳ có từ trùng nhau là cực kỳ thấp. Hệ quả là ma trận cực thưa và phần lớn điểm Cosine Similarity giữa các câu đều bằng 0.

Câu 18: **Chọn b.** Mean Reciprocal Rank (MRR):

$$\text{MRR} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i} = \frac{1}{3} \left(\frac{1}{1} + 0 + \frac{1}{4} \right) = \frac{1}{3} \times \frac{5}{4} = \frac{5}{12} \approx 0.417.$$

Câu 19: **Chọn b.** Tính toán cụ thể:

$$tf(t, D) = \frac{2}{5} = 0.4,$$

$$idf(t) = \log_e \left(\frac{1+10}{1+3} \right) + 1 = \log_e(2.75) + 1 \approx 1.0116 + 1 = 2.0116,$$

$$\text{TF-IDF} = 0.4 \times 2.0116 \approx 0.805.$$

Câu 20: **Chọn d.** Pipeline chuẩn: Làm sạch ký tự lạ/HTML $\rightarrow$ Hạ chữ thường $\rightarrow$ Tách từ (Tokenization) $\rightarrow$ Loại bỏ từ dừng $\rightarrow$ Lemmatization/Stemming $\rightarrow$ Trích xuất vector TF-IDF.

Câu 21: **Chọn d.** Túi từ đơn (Unigram) phá vỡ tính liên kết giữa từ phủ định “không” và hai triệu chứng “ho”, “sốt”, khiến mô hình học nhầm là bệnh nhân đang có triệu chứng.

Câu 22: **Chọn d.** Mô hình đạt 98% trên Train nhưng chỉ 65% trên Validation là dấu hiệu điển hình của Overfitting. Cần giảm số lượng đặc trưng bằng cách tăng `min_df`, loại bỏ N-gram quá dài hoặc áp dụng điều chuẩn (Regularization).

Câu 23: **Chọn b.** Cosine Similarity có tính chất bất biến với phép nhân vô hướng dương ($c > 0$): $\cos(c \cdot d, q) = \cos(d, q)$.

- Câu 24:** **Chọn b.** Chuẩn hóa L_2 chia vector cho độ dài Euclid của chính nó ($v' = v/\|v\|_2$), do đó độ dài Euclid của vector chuẩn hóa luôn bằng đúng 1.0.
- Câu 25:** **Chọn d.** Khoảng cách Cosine và độ tương đồng Cosine liên hệ trực tiếp qua công thức: $\text{Cosine Distance} = 1 - \text{Cosine Similarity}$.
- Câu 26:** **Chọn d.** Truy vấn AND quá khắt khe khiến chỉ cần thiếu một từ là trả về 0 kết quả. Nói lỏng sang OR kết hợp thuật toán xếp hạng BM25/TF-IDF sẽ ưu tiên đưa các bài chứa nhiều từ khóa lên đầu.
- Câu 27:** **Chọn c.** Lowercasing giúp đồng nhất “iPhone”, “iphone” và “IPHONE” về cùng một biểu diễn, giúp thuật toán so khớp chính xác tên thương hiệu.
- Câu 28:** **Chọn c.** NDCG@5 (Normalized Discounted Cumulative Gain) và MAP là các chỉ số đánh giá có tính đến thứ tự xếp hạng (tài liệu liên quan càng ở trên cao thì điểm thưởng càng lớn), rất phù hợp cho Top 5.
- Câu 29:** **Chọn a.** Thiết lập chỉ dùng Bigram loại bỏ các từ đơn lẻ có độ nhiều cao, chỉ tập trung vào các kết hợp cụm 2 từ liên kề có ngữ nghĩa chuyên biệt (ví dụ “trí tuệ nhân tạo”, “máy tính”).
- Câu 30:** **Chọn d.** Định luật Zipf trong ngôn ngữ học thực nghiệm khẳng định tần suất xuất hiện của từ tỷ lệ nghịch với thứ hạng của nó theo phân phối lũy thừa: $f(r) \propto \frac{1}{r^\alpha}$ với $\alpha \approx 1$.