

PHẦN 1: NỘI DUNG CÂU HỎI (CÂU 31–50)

- Câu 31:** Tại sao khi xử lý tập dữ liệu các bài báo nghiên cứu Y học, từ “patient” (bệnh nhân) nên được xem xét thêm vào danh sách Stopwords riêng của miền ứng dụng (Domain-specific Stopwords)?
- Vì từ “patient” bắt buộc phải được thay thế bằng danh từ riêng của bác sĩ.
 - Vì từ “patient” là từ gõ sai chính tả của từ “patents”.
 - Vì từ “patient” làm cho công thức logarit IDF bị lỗi số âm.
 - Vì từ “patient” xuất hiện ở hầu hết mọi bài báo Y học (tần suất tài liệu cực cao), làm mất khả năng phân biệt giữa các bệnh lý cụ thể.
- Câu 32:** Trong các hệ thống tìm kiếm công nghiệp (như Elasticsearch, Lucene), cấu trúc dữ liệu Chỉ mục đảo (Inverted Index) được sử dụng thay cho ma trận tài liệu–từ vựng nhằm mục đích chính nào?
- Loại bỏ hoàn toàn bước tiền xử lý như tách từ và chuyển đổi chữ thường.
 - Bỏ qua các tài liệu không chứa từ trong truy vấn, giúp thời gian truy vấn chỉ phụ thuộc vào số tài liệu khớp thay vì toàn bộ tập dữ liệu.
 - Đảm bảo quá trình tính toán Cosine similarity luôn cho ra kết quả nằm trong khoảng từ -1.0 đến 1.0 .
 - Tự động nén ma trận biểu diễn để giảm độ phức tạp không gian lưu trữ về đúng một tài liệu.
- Câu 33:** Một tài liệu D chứa từ t với tần suất thô $tf(t, D) = 100$. Nếu áp dụng công thức Sublinear TF scaling $tf_{\text{scaled}} = 1 + \ln(tf)$, giá trị TF mới thu được (làm tròn 2 chữ số thập phân) là bao nhiêu?
- 5.61
 - 101.00
 - 4.61
 - 3.00
- Câu 34:** Khi huấn luyện mô hình Trích xuất Chủ đề LDA (Latent Dirichlet Allocation), dạng ma trận biểu diễn đầu vào nào được khuyến nghị chuẩn kỹ thuật nhất?
- Ma trận Tần suất từ thô (Raw Count Matrix từ `CountVectorizer`) chứa các số nguyên không âm.
 - Ma trận khoảng cách Cosine giữa các văn bản.
 - Ma trận TF-IDF đã qua chuẩn hóa.
 - Ma trận nhị phân Binary (chỉ chứa 0 và 1).
- Câu 35:** Hiện tượng “Overstemming” trong quá trình xử lý ngôn ngữ tự nhiên được mô tả qua ví dụ nào sau đây?
- Tự động thêm hậu tố vào cuối từ để tạo ra một danh từ mới.
 - Hai từ là biến thể của nhau như “running” và “runs” không thể đưa được về cùng một từ gốc.
 - Hai từ mang ý nghĩa hoàn toàn khác nhau như “experiment” và “experience” bị gộp giữa thành cùng một gốc “exper”.
 - Chuyển đổi một từ gõ sai chính tả về dạng từ điển đúng.

- Câu 36:** Người dùng phàn nàn rằng khi tìm kiếm từ khóa “máy tính xách tay”, hệ thống TF-IDF trả về cả các tài liệu chỉ có từ “máy”, “tính” hoặc “xách” nằm rải rác ở các đoạn khác nhau. Làm thế nào để cải thiện độ chính xác tìm kiếm cụm từ này?
- Áp dụng chuẩn hóa cho vector truy vấn của người dùng.
 - Tăng giá trị tham số `min_df` của mô hình lên mức tối đa.
 - Chuyển sang sử dụng phép đo khoảng cách Manhattan thay cho Cosine.
 - Bổ sung Bigram và Trigram vào bộ trích xuất đặc trưng (`ngram_range=(1,3)`).
- Câu 37:** Trong bài toán phân loại email rác, các ký tự như `ấấếếấấ!!!` là tín hiệu dự báo email rác rất mạnh. Cấu hình nào của `TfidfVectorizer` giúp giữ lại các tín hiệu này?
- Bật tham số `lowercase=True`.
 - Tùy chỉnh biểu thức chính quy `token_pattern` để không bỏ qua các ký tự đặc biệt.
 - Đặt `use_idf=False` để chỉ tính tần suất từ thô.
 - Tăng giá trị `max_features`.
- Câu 38:** Khi thực hiện K-Fold Cross-Validation cho một bài toán phân loại văn bản, cách làm nào sau đây đảm bảo **không bị Data Leakage**?
- Trong mỗi Fold, chỉ gọi `fit_transform()` trên tập Train-Fold, sau đó gọi `transform()` trên Validation-Fold.
 - Thực hiện `fit_transform()` trên toàn bộ tập dữ liệu trước, rồi mới chia K-Fold.
 - Bỏ qua bước `fit()` và chỉ gọi `transform()` trên cả hai tập.
 - Gọi `fit_transform()` trên Validation-Fold để cập nhật IDF cho tập Train-Fold.
- Câu 39:** Một truy vấn có 3 tài liệu liên quan trong toàn bộ hệ thống. Danh sách trả về xếp hạng 5 kết quả đầu tiên có trạng thái liên quan lần lượt là (R, N, R, N, N) , trong đó R là liên quan và N là không liên quan. Giá trị Average Precision (AP) của danh sách này là bao nhiêu?
- 0.833
 - 0.667
 - 0.400
 - 0.556
- Câu 40:** Giả định cốt lõi nào của Mô hình Không gian Vector (Vector Space Model) truyền thống bị coi là hạn chế lớn nhất khi biểu diễn ngôn ngữ tự nhiên?
- Giả định tần suất từ xuất hiện phải tuân theo phân bố chuẩn Gaussian.
 - Giả định mỗi tài liệu chỉ được phép gán duy nhất một nhãn phân loại.
 - Giả định độ dài các văn bản bắt buộc phải bằng nhau trước khi tính toán.
 - Giả định các từ/chiều trong không gian độc lập tuyến tính (Trực giao) với nhau.
- Câu 41:** So với Word N-grams, ưu điểm lớn nhất của Character N-grams khi xử lý văn bản trên mạng xã hội (chứa nhiều từ lóng, teencode, gõ sai chính tả) là gì?
- Tự động xóa bỏ toàn bộ các biểu tượng cảm xúc Emoji.
 - Hiểu được ngữ nghĩa cấu trúc câu phức tạp tốt hơn Word N-grams.
 - Khả năng chống chịu nhiễu chính tả cao nhờ vẫn giữ lại được các đoạn chuỗi con trùng khớp với từ gốc.
 - Tạo ra kích thước từ điển nhỏ hơn đáng kể so với Word N-grams.

- Câu 42:** Trong thuật toán xếp hạng BM25, tham số k_1 (thường chọn khoảng 1.2–2.0) có vai trò kỹ thuật chính là gì?
- Giới hạn ngưỡng bão hòa tần suất từ cực đại.
 - Điều chỉnh mức độ phạt độ dài văn bản (Document Length Normalization) so với độ dài trung bình toàn tập.
 - Thêm từ dừng tự động vào danh sách tra cứu.
 - Chuyển đổi điểm số về dạng xác suất từ 0.0 đến 1.0.
- Câu 43:** Trong quá trình phân tích lỗi hệ thống tìm kiếm, bạn nhận thấy một văn bản chứa lỗi chính tả “helthcare” được xếp hạng cao bất thường cho truy vấn chứa từ này, vượt qua các tài liệu chứa từ đúng “healthcare”. Cơ chế nào của TF-IDF dẫn đến lỗi này?
- Từ sai chính tả có số lượng tài liệu chứa từ rất nhỏ nên nhận giá trị IDF rất cao, làm đẩy điểm TF-IDF lên mức quá lớn.
 - Hệ thống tự động thay thế từ sai chính tả thành một vector đặc khiến phép tính tích vô hướng thu được kết quả bằng 1.0.
 - Bộ chuẩn hóa không thể tính toán chính xác độ dài Euclid cho các vector chứa thuật ngữ không nằm trong danh sách từ điển chuẩn.
 - Tần suất xuất hiện của từ sai chính tả được tự động nhân thêm hệ số ưu tiên trong các thư viện xử lý ngôn ngữ tự nhiên.
- Câu 44:** Tại sao thuật toán TF-IDF không thể giải quyết bài toán Định hướng nghĩa của từ (Word Sense Disambiguation – WSD)?
- Vì TF-IDF gán cố định một chỉ số duy nhất trong từ điển cho mỗi chuỗi ký tự, bất chấp ngữ cảnh xuất hiện.
 - Vì TF-IDF bắt buộc văn bản phải được viết bằng tiếng Anh.
 - Vì công thức IDF loại bỏ toàn bộ các từ có nhiều hơn hai nét nghĩa.
 - Vì ma trận TF-IDF không cho phép thực hiện chuẩn hóa vector.
- Câu 45:** Các thuật toán tách từ cấp độ từ con (Subword Tokenization) như Byte-Pair Encoding (BPE) hay WordPiece giải quyết hạn chế cốt lõi nào của phương pháp tách từ dựa trên khoảng trắng cổ điển?
- Loại bỏ triệt để nhu cầu sử dụng các mạng nơ-ron phức tạp trong xử lý ngôn ngữ.
 - Chuyển đổi hoàn toàn các biểu diễn văn bản thưa thành các vector ma trận đặc.
 - Tự động sửa lỗi chính tả ngữ pháp trong văn bản trước khi đưa vào mô hình.
 - Cân bằng giữa kích thước từ điển và khả năng biểu diễn từ mới/hiếm bằng cách chia từ lạ thành các mảnh từ con đã biết.
- Câu 46:** Khi thiết lập `TfidfVectorizer(max_features=5000)`, tiêu chí nào được sử dụng để chọn ra 5000 thuộc tính giữ lại?
- Chọn 5000 từ xuất hiện đầu tiên theo thứ tự bảng chữ cái Alpha-B.
 - Chọn ngẫu nhiên 5000 từ từ danh sách từ điển thu được.
 - Chọn Top 5000 từ có giá trị IDF cao nhất.
 - Chọn Top 5000 từ có Tần suất xuất hiện (Term Frequency) cao nhất trên toàn bộ tập dữ liệu.
- Câu 47:** Nếu người dùng nhập một truy vấn tìm kiếm q mà toàn bộ các từ trong q đều là từ mới (OOV – không xuất hiện trong từ điển đã học của TF-IDF), vector biểu diễn của q sẽ là gì và Cosine Similarity với các tài liệu bằng bao nhiêu?

- a. Vector q là vector toàn số 0; điểm Cosine Similarity với mọi tài liệu đều bằng 0.0 (hoặc không xác định do chia cho 0).
- b. Mô hình tự động chọn ngẫu nhiên một tài liệu để gán điểm 1.0.
- c. Vector q nhận giá trị IDF của từ xuất hiện ít nhất trong tập dữ liệu.
- d. Vector q là vector toàn số 1; điểm Cosine Similarity với mọi tài liệu bằng 1.0.

Câu 48: Biểu thức chính quy (Regular Expression) nào sau đây loại bỏ chính xác toàn bộ các thẻ HTML (ví dụ `<p>`, `</p>`) ra khỏi chuỗi văn bản thô?

- a. `<.*>`
- b. `< >`
- c. `<[>]+>`
- d. `\d+`

Câu 49: Khi triển khai mô hình TF-IDF đã huấn luyện lên hệ thống thực tế (Production), một truy vấn người dùng chứa các từ hoàn toàn mới (Out-Of-Vocabulary – OOV). Khung xử lý Scikit-Learn sẽ xử lý các từ OOV này như thế nào trong hàm `transform()`?

- a. Bỏ qua các từ OOV và chỉ tính toán trọng số cho các từ đã tồn tại trong từ điển `vocabulary_`.
- b. Tự động mở rộng kích thước từ điển và gán cho từ mới giá trị IDF bằng 0.
- c. Báo lỗi `ValueError` và dừng toàn bộ tiến trình xử lý truy vấn của người dùng.
- d. Gán từ OOV vào một chỉ số cố định đại diện cho từ hiếm và tính IDF bình thường.

Câu 50: Một mô hình trích xuất thông tin đạt độ chính xác $Precision = 0.80$ và độ bao phủ $Recall = 0.50$. Giá trị F1-Score của mô hình là bao nhiêu?

- a. 0.400
- b. 0.300
- c. 0.650
- d. 0.615

PHẦN 2: ĐÁP ÁN VÀ LỜI GIẢI CHI TIẾT (CÂU 31–50)

1. Bảng Tổng Hợp Đáp Án Nhanh

Câu	Đáp án	Câu	Đáp án	Câu	Đáp án	Câu	Đáp án
Câu 31	d	Câu 36	d	Câu 41	c	Câu 46	d
Câu 32	b	Câu 37	b	Câu 42	a	Câu 47	a
Câu 33	a	Câu 38	a	Câu 43	a	Câu 48	c
Câu 34	a	Câu 39	d	Câu 44	a	Câu 49	a
Câu 35	c	Câu 40	d	Câu 45	d	Câu 50	d

2. Lời Giải Thích Chi Tiết Từng Câu Hỏi

Câu 31: Chọn d. Trong ngữ liệu chuyên ngành Y học, từ “patient” xuất hiện ở hầu hết mọi nghiên cứu ($df \approx N$), làm giá trị IDF tiệm cận 0 và không mang ý nghĩa phân loại hay xếp hạng chủ đề bệnh lý. Vì vậy, từ này được xếp vào nhóm Stopwords đặc thù theo miền (Domain-specific Stopwords).

Câu 32: Chọn b. Inverted Index ánh xạ mỗi thuật ngữ tới danh sách các tài liệu chứa thuật ngữ đó (Postings List). Khi nhận truy vấn, hệ thống chỉ cần duyệt qua danh sách tài liệu liên quan đến các từ khóa trong truy vấn thay vì quét toàn bộ kho dữ liệu hàng triệu văn bản.

Câu 33: Chọn a. Áp dụng công thức biến đổi logarit cho tần suất từ:

$$tf_{\text{scaled}} = 1 + \ln(100) \approx 1 + 4.60517 = 5.60517 \approx 5.61.$$

Câu 34: Chọn a. LDA là mô hình sinh xác suất dựa trên phân phối Dirichlet–Multinomial, mô phỏng quá trình sinh ra các từ rời rạc thông qua số lần đếm thực tế. Do đó, ma trận đầu vào bắt buộc là ma trận đếm số nguyên thô (CountVectorizer), không chuẩn hóa qua TF-IDF.

Câu 35: Chọn c. Overstemming là hiện tượng thuật toán cắt gọt quá đà, làm cho hai từ có gốc nghĩa và khái niệm hoàn toàn khác nhau bị đưa về cùng một dạng gốc giả định (ví dụ “experiment” và “experience” đều bị gọt thành “exper”).

Câu 36: Chọn d. Việc chỉ dùng Unigram khiến các từ bị xé lẻ và đối sánh độc lập. Khi mở rộng sang Bigram và Trigram (`ngram_range=(1,3)`), cụm từ “máy tính xách tay” được bảo toàn nguyên khối như một đặc trưng duy nhất, giúp hệ thống lọc đúng tài liệu chứa trọn vẹn cả cụm từ.

Câu 37: Chọn b. Mặc định `TfidfVectorizer` dùng biểu thức chính quy `(?u)\b\w\w+\b` chỉ giữ lại các từ có 2 ký tự chữ cái trở lên và bỏ qua dấu câu/ký tự đặc biệt. Để bắt được dấu cảm thán hoặc chuỗi ký tự lạ, cần tùy biến tham số `token_pattern`.

Câu 38: Chọn a. Nguyên tắc chống rò rỉ dữ liệu (Data Leakage): việc học từ điển và tính giá trị thống kê df/idf chỉ được phép diễn ra trên tập huấn luyện của từng Fold (`fit_transform()`), sau đó chiếu tập Validation vào không gian đã học bằng `transform()`.

Câu 39: Chọn d. Danh sách trạng thái liên quan là (R, N, R, N, N) với tổng số tài liệu liên quan trong hệ thống là 3.

- Vị trí 1 (R): $\text{Precision@1} = 1/1 = 1.0$.
- Vị trí 3 (R): $\text{Precision@3} = 2/3 \approx 0.667$.

Giá trị Average Precision:

$$AP = \frac{1 + \frac{2}{3}}{3} = \frac{5}{9} \approx 0.556.$$

- Câu 40:** **Chọn d.** Giả định trực giao (Orthogonal Assumption) coi mỗi từ là một chiều độc lập tuyến tính trong không gian vector. Điều này làm mất mối liên hệ tương đồng ngữ nghĩa giữa các từ đồng nghĩa (ví dụ: “bác sĩ” và “thầy thuốc” bị xem như hai chiều vuông góc hoàn toàn).
- Câu 41:** **Chọn c.** Trên mạng xã hội, người dùng hay viết sai hoặc biến thể từ (teencode). Character N-grams chia nhỏ từ thành các chuỗi ký tự liên kề (ví dụ “ngươi” → “ng”, “gu”, “uo”, “oi”), giúp mô hình vẫn nhận diện được sự tương đồng nhờ các đoạn ký tự con trùng khớp dù từ gốc bị gõ lỗi.
- Câu 42:** **Chọn a.** Tham số k_1 trong thuật toán Okapi BM25 đóng vai trò điều tiết mức độ bão hòa của tần suất từ (TF saturation). Khi tf tăng cao, điểm số sẽ tiệm cận một ngưỡng cực đại được kiểm soát bởi k_1 thay vì tăng tuyến tính không giới hạn như TF-IDF chuẩn.
- Câu 43:** **Chọn a.** Do lỗi chính tả, từ “helthcare” xuất hiện rất ít trong kho ngữ liệu (df cực nhỏ). Công thức nghịch đảo $idf = \log(N/df)$ khiến từ sai chính tả này nhận điểm trọng số IDF cực lớn, đẩy điểm số TF-IDF của tài liệu lên cao bất thường khi có người tìm kiếm từ này.
- Câu 44:** **Chọn a.** TF-IDF gán cố định một token mặt chữ vào một cột duy nhất trong ma trận từ điển, bỏ qua cấu trúc ngữ pháp và ngữ cảnh xung quanh nên không thể phân biệt được các nghĩa khác nhau của cùng một từ đa nghĩa (Polysemy).
- Câu 45:** **Chọn d.** Subword Tokenization chia nhỏ từ chưa từng thấy thành các đơn vị con (subwords) có tần suất cao hoặc các ký tự đơn đã có trong từ điển, vừa giữ cho kích thước từ điển ở mức vừa phải, vừa triệt tiêu được lỗi từ ngoài từ điển (OOV).
- Câu 46:** **Chọn d.** Theo tài liệu kỹ thuật của Scikit-Learn, khi truyền `max_features=K`, mô hình sẽ sắp xếp tất cả các từ theo tổng số lần xuất hiện (Term Frequency) trên toàn bộ kho tài liệu và chỉ giữ lại Top K từ có tần suất cao nhất.
- Câu 47:** **Chọn a.** Nếu tất cả các từ trong truy vấn đều không nằm trong từ điển đã học (`vocabulary_`), vector đặc trưng tạo ra sẽ toàn là các phần tử bằng 0. Khi đó tích vô hướng với mọi tài liệu đều bằng 0, độ đo Cosine Similarity trả về 0.0 (hoặc không xác định do chia cho 0).
- Câu 48:** **Chọn c.** Biểu thức `<[~>]+>` khớp với ký tự bắt đầu `<`, theo sau bởi một hoặc nhiều ký tự bất kỳ khác dấu đóng `>`, và kết thúc bởi `>`. Cách này loại bỏ gọn từng cặp thẻ mà không gây hiện tượng quét lần văn bản (greedy match).
- Câu 49:** **Chọn a.** Khi gọi hàm `transform()`, Scikit-Learn chỉ so khớp các từ nằm trong từ điển đã học từ bước `fit()`. Các từ OOV hoàn toàn bị bỏ qua một cách âm thầm và không làm thay đổi cấu trúc vector đầu ra.
- Câu 50:** **Chọn d.** Công thức tính điểm điều hòa F_1 -Score:

$$F_1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} = 2 \times \frac{0.80 \times 0.50}{0.80 + 0.50} = \frac{0.80}{1.30} \approx 0.615.$$