

BỘ CÂU HỎI TRẮC NGHIỆM & ĐÁP ÁN CHI TIẾT XỬ LÝ NGÔN NGỮ TỰ NHIÊN & TRUY XUẤT THÔNG TIN

Hệ Thống Trợ Giúp Học Tập

Ngày 17 tháng 9 năm 2026

PHẦN 1: NỘI DUNG CÂU HỎI

Câu 1: Tại sao thuật toán Okapi BM25 thường cho kết quả xếp hạng vượt trội so với TF-IDF truyền thống trên các hệ thống tìm kiếm tài liệu thực tế?

- a. BM25 không phụ thuộc vào tần suất tài liệu ngược IDF trong quá trình tính toán.
- b. BM25 có cơ chế bão hòa tần suất từ (TF saturation) và tính chỉnh phạt độ dài văn bản linh hoạt thông qua các tham số k_1 và b .
- c. BM25 tích hợp sẵn mạng nơ-ron nhúng từ (Word Embeddings) để hiểu ngữ nghĩa chuyên sâu.
- d. BM25 hoàn toàn giải quyết được hiện tượng các từ không nằm trong từ điển (OOV).

Câu 2: Trong thuật toán xếp hạng BM25, tham số b (thường chọn $b \approx 0.75$) có vai trò kỹ thuật chính là gì?

- a. Điều chỉnh mức độ phạt độ dài văn bản (Document Length Normalization) so với độ dài trung bình toàn tập.
- b. Giới hạn ngưỡng bão hòa tần suất từ cực đại.
- c. Thêm từ dừng tự động vào danh sách tra cứu.
- d. Chuyển đổi điểm số về dạng xác suất từ 0.0 đến 1.0.

Câu 3: Cho ma trận tài liệu - từ vệt kích thước 1000×10000 . Biết rằng trung bình mỗi tài liệu chứa 50 từ DUY NHẤT. Tổng số lượng phần tử KHÁC 0 trong ma trận thưa này là bao nhiêu?

- a. 10.000.000
- b. 500.000
- c. 5.000
- d. 50.000

Câu 4: Một hệ thống tìm kiếm nội bộ doanh nghiệp gặp hiện tượng Recall cực kỳ thấp: người dùng tìm “báo cáo tài chính” nhưng không thấy các tài liệu chứa “bản kê khai tài chính” hay “báo cáo thu chi”. Kỹ thuật nào giúp khắc phục triệt để vấn đề này?

- a. Chuyển toàn bộ văn bản sang dạng mã hóa Base64 trước khi trích xuất đặc trưng.
- b. Bỏ qua chuẩn hóa vector L_2 để giữ nguyên giá trị độ dài tuyệt đối.
- c. Mở rộng truy vấn (Query Expansion) bằng từ điển đồng nghĩa (Thesaurus) hoặc mô hình Semantic Search.
- d. Tăng ngưỡng `min_df` lên để loại bỏ bớt từ xuất hiện ít.

Câu 5: Một kỹ sư nhận thấy ma trận TF-IDF của mình có độ thưa (sparsity) đạt 99.9%. Kỹ sư này lo lắng và tìm cách giảm độ thưa này xuống. Nhận định nào sau đây là ĐÚNG về mặt kỹ thuật?

- a. Độ thưa cao báo hiệu quy trình tiền xử lý tách từ đã bị lỗi nghiêm trọng.
- b. Cần phải điền các giá trị trung bình cột vào các ô bằng 0 để mô hình học máy hoạt động.
- c. Độ thưa cao làm cho phép tính tích vô hướng hai vector luôn luôn bằng 1.0.
- d. Độ thưa cao là đặc tính hoàn toàn tự nhiên và mong muốn của mô hình Bag-of-Words đối với tập từ vựng lớn.

Câu 6: Khi huấn luyện mô hình Trích xuất Chủ đề LDA (Latent Dirichlet Allocation), dạng ma trận biểu diễn đầu vào nào được khuyến nghị chuẩn kỹ thuật nhất?

- a. Ma trận nhị phân Binary (chỉ chứa 0 và 1).
- b. Ma trận Tần suất từ thô (Raw Count Matrix từ `CountVectorizer`) chứa các số nguyên không âm.
- c. Ma trận TF-IDF đã qua chuẩn hóa L_2 .
- d. Ma trận khoảng cách Cosine giữa các văn bản.

Câu 7: Trong một ứng dụng tìm kiếm tin tức, một bài báo dài lặp lại từ khóa “AI” 100 lần, trong khi một bài báo ngắn xuất sắc chỉ nhắc tới “AI” 10 lần. Để giảm sự chênh lệch điểm quá lớn do tần suất thô gây ra mà không làm mất đi thứ hạng của bài báo phù hợp, kỹ thuật biến đổi TF nào sau đây nên được áp dụng?

- a. Nhân thêm trọng số hằng số bằng độ dài trung bình của toàn bộ các tài liệu trong tập dữ liệu.
- b. Áp dụng Sublinear TF scaling với công thức $1 + \log(tf)$ cho các trường hợp $tf > 0$.
- c. Áp dụng chuẩn hóa L_1 trên toàn bộ ma trận tần suất để đưa tổng điểm về 1.0.
- d. Chuyển đổi tần suất từ thô về dạng nhị phân (Binary TF: 1 nếu xuất hiện, 0 nếu không).

Câu 8: Biểu thức chính quy (Regular Expression) nào sau đây loại bỏ chính xác toàn bộ các thẻ HTML (ví dụ `<html>`, `<div class=“...”>`) ra khỏi chuỗi văn bản thô?

- a. `<?.*?>`
- b. `<.*?>`
- c. `<[>]+>`
- d. `\d+`

Câu 9: Giả định cốt lõi nào của Mô hình Không gian Vector (Vector Space Model) truyền thống bị coi là hạn chế lớn nhất khi biểu diễn ngôn ngữ tự nhiên?

- a. Giả định các từ/chiều trong không gian độc lập tuyến tính (Trực giao) với nhau.
- b. Giả định tần suất từ xuất hiện phải tuân theo phân bố chuẩn Gaussian.
- c. Giả định mỗi tài liệu chỉ được phép gán duy nhất một nhãn phân loại.
- d. Giả định độ dài các văn bản bắt buộc phải bằng nhau trước khi tính toán.

Câu 10: Khi xây dựng một hệ thống phân loại văn bản dựa trên mô hình TF-IDF, kỹ sư cần thực hiện bước chuẩn hóa dữ liệu trên hai tập Train và Test. Quy trình nào sau đây đảm bảo đúng nguyên tắc kỹ thuật để tránh rò rỉ dữ liệu (Data Leakage)?

- a. Gộp chung hai tập Train và Test lại để thực hiện `fit_transform()`, sau đó mới chia lại thành hai tập để đánh giá.
- b. Áp dụng phương thức `fit_transform()` trên tập Train, sau đó chỉ áp dụng phương thức `transform()` trên tập Test.

- c. Áp dụng phương thức `fit_transform()` độc lập trên tập Train và tiếp tục `fit_transform()` độc lập trên tập Test.
- d. Thực hiện `fit()` trên tập Test để cập nhật danh sách từ mới, sau đó mới dùng `transform()` cho toàn bộ dữ liệu.

Câu 11: Khi xây dựng hệ thống phát hiện ngôn ngữ (Language Identification) hoặc xử lý các ngôn ngữ dính liền không có khoảng trắng rõ ràng, phương pháp trích xuất đặc trưng nào tỏ ra vượt trội?

- a. Chỉ sử dụng các số liệu thống kê về độ dài trung bình của câu.
- b. Word-level Unigrams kết hợp với danh sách từ dừng mở rộng.
- c. N-grams ở cấp độ ký tự (Character-level N-grams).
- d. Mô hình TF-IDF thuần túy chỉ giữ lại các ký tự số và dấu câu.

Câu 12: Khi so sánh độ tương đồng ngữ nghĩa giữa truy vấn tìm kiếm và tài liệu bằng mô hình không gian vector, tại sao khoảng cách Euclid (Euclidean Distance) lại ít được ưa chuộng hơn so với độ đo Cosine (Cosine Similarity)?

- a. Khoảng cách Euclid không thể thực hiện được trên các ma trận thưa chứa nhiều phần tử bằng 0.
- b. Độ đo Cosine tự động loại bỏ được các từ dừng Stopwords mà không cần qua bước tiền xử lý.
- c. Khoảng cách Euclid bị ảnh hưởng mạnh bởi độ dài văn bản, làm hai văn bản có cùng tỷ lệ từ vựng vẫn bị tính khoảng cách xa nhau.
- d. Độ đo Cosine có độ phức tạp tính toán là $O(1)$ trong khi khoảng cách Euclid yêu cầu độ phức tạp $O(V^2)$.

Câu 13: Một hệ thống tìm kiếm sản phẩm bị phàn nàn do trả về quá nhiều kết quả không liên quan khi truy vấn chứa nhiều từ (ví dụ “áo sơ mi nam trắng dài tay”). Kỹ thuật điều chỉnh tham số TF-IDF / BM25 nào giúp cải thiện ngay tình trạng này?

- a. Chuyển đổi toàn bộ từ vựng sang mã Hash nhị phân.
- b. Yêu cầu ngưỡng trùng khớp tối thiểu (Minimum Should Match - ví dụ bắt buộc khớp ít nhất 75% số từ truy vấn).
- c. Gán trọng số IDF của tất cả các từ trong truy vấn bằng nhau và bằng 1.0.
- d. Tắt toàn bộ tính năng chuẩn hóa độ dài văn bản.

Câu 14: So sánh giữa biểu diễn TF-IDF (Sparse) và biểu diễn Nhúng từ/văn bản (Dense Embeddings như BERT, Word2Vec), phát biểu nào sau đây phản ánh ĐÚNG bản chất?

- a. TF-IDF mạnh về khớp chính xác từ khóa (Lexical Matching), trong khi Dense Embeddings mạnh về bắt ngữ nghĩa đồng nghĩa (Semantic Matching).
- b. Dense Embeddings bị giới hạn bởi không thể biểu diễn được các từ mới chưa từng xuất hiện.
- c. TF-IDF có khả năng học ngữ cảnh đảo ngược của từ nhờ cơ chế Attention.
- d. TF-IDF luôn tốn dung lượng bộ nhớ hơn Dense Embeddings trong mọi trường hợp.

Câu 15: Một hệ thống tìm kiếm thông tin được đánh giá trên 3 truy vấn Q_1, Q_2, Q_3 . Kết quả vị trí của tài liệu liên quan đầu tiên thu được lần lượt là: Q_1 tìm thấy ở vị trí thứ 1; Q_2 không có tài liệu liên quan trong Top-10 ($r_q \rightarrow \infty$); Q_3 tìm thấy ở vị trí thứ 4. Chỉ số MRR (Mean Reciprocal Rank) của hệ thống là bao nhiêu?

- a. 0.333

- b. 0.625
- c. 0.250
- d. 0.417

Câu 16: Người dùng nhập truy vấn “bank interest rate” để tìm tài liệu tài chính. Tuy nhiên, hệ thống tìm kiếm TF-IDF lại xếp một tài liệu nói về “river bank erosion” lên vị trí hàng đầu. Phân tích nguyên nhân kỹ thuật cốt lõi gây ra hiện tượng này?

- a. Thuật toán Stemming đã cắt gọt sai các từ trong truy vấn khiến tần suất từ tf của các từ trong văn bản bị tính toán sai lệch.
- b. Do tài liệu nói về bờ sông có độ dài ngắn hơn nên nhận được lợi thế lớn sau khi thực hiện chuẩn hóa độ dài vector L_2 .
- c. Mô hình biểu diễn thưa coi các chiều từ vựng hoàn toàn độc lập nên gộp chung các nét nghĩa khác nhau của từ đa nghĩa vào cùng một vị trí vector.
- d. Do trọng số IDF của thuật ngữ “bank” bị triệt tiêu về giá trị 0 trong quá trình tính toán tần suất trên toàn bộ tập dữ liệu.

Câu 17: Bạn được giao nhiệm vụ xây dựng công cụ tìm kiếm mã nguồn (Source Code Search). Quy trình tiền xử lý văn bản thông thường (như loại bỏ dấu câu, hạ chữ thường, xóa từ dừng tiếng Anh) có phù hợp không?

- a. Không phù hợp, vì dấu câu (như ., (), ->) và từ khóa (như for, if, class) mang ý nghĩa cú pháp quyết định trong lập trình.
- b. Chỉ cần xóa bỏ các dòng comment còn giữ nguyên toàn bộ các phần khác.
- c. Phù hợp nhưng cần bổ sung thêm bước chuyển đổi mã nguồn về dạng cây cú pháp trừu tượng AST trước khi hạ chữ thường.
- d. Hoàn toàn phù hợp, vì mã nguồn về bản chất cũng là văn bản tự nhiên.

Câu 18: Tại sao thuật toán TF-IDF không thể giải quyết bài toán Định hướng nghĩa của từ (Word Sense Disambiguation - WSD)?

- a. Vì TF-IDF gán cố định một chỉ số duy nhất trong từ điển cho mỗi chuỗi ký tự, bất chấp ngữ cảnh xuất hiện.
- b. Vì ma trận TF-IDF không cho phép thực hiện chuẩn hóa vector L_2 .
- c. Vì công thức IDF loại bỏ toàn bộ các từ có nhiều hơn hai nét nghĩa.
- d. Vì TF-IDF bắt buộc văn bản phải được viết bằng tiếng Anh.

Câu 19: Hai văn bản D_1 và D_2 không chứa bất kỳ từ nào chung trong từ điển. Giá trị độ tương đồng Cosine giữa hai vector biểu diễn TF-IDF của chúng là bao nhiêu?

- a. 0.5
- b. 1.0
- c. 0.0
- d. -1.0

Câu 20: Bạn xây dựng mô hình phân loại văn bản đa ngôn ngữ (chứa cả tiếng Anh và tiếng Pháp). Nếu bạn áp dụng danh sách Stopwords tiếng Anh mặc định `stop_words='english'`, tác động nào sẽ xảy ra với các văn bản tiếng Pháp?

- a. Mô hình ném ra lỗi `UnicodeDecodeError` khi gặp ký tự tiếng Pháp.
- b. Giá trị IDF của các từ tiếng Pháp tự động bị gán về 0.
- c. Tất cả văn bản tiếng Pháp sẽ bị tự động dịch sang tiếng Anh.

- d. Các từ dừng tiếng Pháp (như “le”, “la”, “de”) không bị loại bỏ, trở thành các đặc trưng xuất hiện nhiều trong ma trận.

Câu 21: Một trang web thương mại điện tử muốn người dùng khi gõ “điện thoại iphone” sẽ thấy các sản phẩm có nhãn “iPhone 15 Pro”, “iPhone 14” được xếp lên đầu. Yếu tố tiền xử lý nào quyết định việc ghép nối này?

- a. Sử dụng phép đo khoảng cách Manhattan thay vì Cosine.
- b. Chuyển chữ thường (Lowercasing) và Stemming/Lemmatization để bỏ qua sự khác biệt viết hoa/thường của tên thương hiệu.
- c. Loại bỏ toàn bộ các con số như “15”, “14” ra khỏi tên sản phẩm.
- d. Tắt tính năng tính IDF để các từ xuất hiện bình đẳng.

Câu 22: Trong đối tượng `sklearn.pipeline.Pipeline`, bước tiền xử lý văn bản `TfidfVectorizer` bắt buộc phải đóng vai trò là một thành phần như thế nào?

- a. Là một hàm Python thuần túy truyền vào tham số `function`.
- b. Là một **Transformer** triển khai đầy đủ hai phương thức `fit()` và `transform()`.
- c. Là một **Estimator** cuối cùng chỉ triển khai phương thức `predict()`.
- d. Là một đối tượng xử lý bất đồng bộ bắt buộc chạy trên GPU.

Câu 23: Nếu ta nhân tất cả các giá trị trong vector biểu diễn TF-IDF của một văn bản D với một hằng số dương $c > 0$ (ví dụ: nhân đôi tần suất xuất hiện bằng cách nối hai văn bản giống hệt nhau), giá trị Cosine Similarity giữa D và truy vấn Q sẽ thay đổi như thế nào?

- a. Tăng lên theo bình phương hằng số c^2 .
- b. Giảm đi c lần.
- c. Hoàn toàn không thay đổi.
- d. Tăng lên gấp c lần.

Câu 24: Cấu hình `TfidfVectorizer(binary=True)` đặt tất cả các tần suất từ khác 0 về 1. Kỹ thuật này phù hợp nhất với loại văn bản nào?

- a. Các tiểu thuyết dài tập cần phân tích tần suất xuất hiện của nhân vật.
- b. Bài toán trích xuất từ khóa tự động trong các bài báo khoa học.
- c. Các văn bản rất ngắn (như tiêu đề bài báo, đoạn tweet) nơi việc lặp lại từ ít xảy ra và không mang nhiều ý nghĩa bổ sung.
- d. Các ma trận đặc tính cần đưa về dạng số thực âm để chạy thuật toán SVM.

Câu 25: Sau khi áp dụng TruncatedSVD lên ma trận TF-IDF (kỹ thuật Latent Semantic Analysis - LSA), lợi ích cốt lõi thu được đối với các truy vấn tìm kiếm là gì?

- a. Đảm bảo ma trận đầu ra chứa hoàn toàn các số nguyên không âm để dễ truy vấn.
- b. Khớp được các tài liệu liên quan về mặt chủ đề ẩn ngay cả khi chúng không chứa chính xác từ khóa trong truy vấn (giải quyết Synonymy).
- c. Giúp khôi phục lại thứ tự chính xác của các từ trong câu ban đầu.
- d. Tăng số lượng chiều của ma trận biểu diễn để tăng độ chính xác phân loại.

Câu 26: Cho một tập dữ liệu gồm $N = 1000$ tài liệu. Nếu một từ t xuất hiện trong tất cả 1000 tài liệu, tính giá trị $idf(t)$ theo công thức chuẩn không smoothing: $idf(t) = \log_e \left(\frac{N}{df(t)} \right)$.

- a. 1.0
- b. Vô cùng (∞)

- c. 0.0
- d. 6.908

Câu 27: Một vector TF-IDF chưa chuẩn hóa của văn bản D đối với từ điển 3 từ là $v = [3, 0, 4]$. Sau khi áp dụng chuẩn hóa L_2 , vector chuẩn hóa v' thu được là bao nhiêu?

- a. $[0.6, 0.0, 0.8]$
- b. $[0.75, 0.0, 1.0]$
- c. $[0.429, 0.0, 0.571]$
- d. $[1.0, 0.0, 1.0]$

Câu 28: Cho vector tần suất từ $v = [1, 2, 1, 4]$. Sau khi thực hiện chuẩn hóa L_1 , tổng các giá trị trong vector mới v' bằng bao nhiêu?

- a. 0.0
- b. 2.828
- c. 1.0
- d. 8.0

Câu 29: Bạn xây dựng mô hình phân loại rác truyền thông với tập dữ liệu gồm 99% tin bình thường và 1% tin độc hại. Sau khi trích xuất TF-IDF, nếu đánh giá mô hình bằng chỉ số Accuracy trên tập dữ liệu gốc này, nguy cơ nào sau đây chắc chắn xảy ra?

- a. Mô hình ngây thơ dự đoán tất cả là tin bình thường vẫn đạt Accuracy 99% nhưng hoàn toàn vô dụng trong việc bắt tin độc hại.
- b. Giá trị IDF của các từ thuộc lớp độc hại sẽ bị đẩy xuống âm do xuất hiện ít.
- c. Độ đo Cosine giữa hai văn bản bất kỳ thuộc lớp thiểu số luôn bằng 0.
- d. Ma trận TF-IDF sẽ tự động loại bỏ toàn bộ 1% lớp thiểu số do vi phạm quy tắc ma trận vuông.

Câu 30: Giả sử hai văn bản D_1 và D_2 cùng chứa từ khóa Q với tần suất thô $tf = 5$. D_1 có độ dài 50 từ, D_2 có độ dài 500 từ. Khi áp dụng chuẩn hóa độ dài vector L_2 cho TF-IDF, văn bản nào sẽ có điểm giá trị trọng số của từ Q cao hơn?

- a. Cả hai văn bản có giá trị trọng số bằng nhau.
- b. Không so sánh được nếu chưa biết điểm IDF của từ Q .
- c. Văn bản D_2 .
- d. Văn bản D_1 .

PHẦN 2: ĐÁP ÁN VÀ LỜI GIẢI CHI TIẾT CHO TẤT CẢ CÁC CÂU HỎI

1. Bảng Tổng Hợp Đáp Án Nhanh

Câu	Đáp án	Câu	Đáp án	Câu	Đáp án
Câu 1	b	Câu 11	c	Câu 21	b
Câu 2	a	Câu 12	c	Câu 22	b
Câu 3	d	Câu 13	b	Câu 23	c
Câu 4	c	Câu 14	a	Câu 24	c
Câu 5	d	Câu 15	d	Câu 25	b
Câu 6	b	Câu 16	c	Câu 26	c
Câu 7	b	Câu 17	a	Câu 27	a
Câu 8	c	Câu 18	a	Câu 28	c
Câu 9	a	Câu 19	c	Câu 29	a
Câu 10	b	Câu 20	d	Câu 30	d

2. Lời Giải Thích Chi Tiết 30 Câu

Câu 1: **Chọn b.** Thuật toán BM25 cải tiến hai điểm mấu chốt so với TF-IDF cổ điển: (1) Không chế sự tăng điểm vô hạn bằng hàm bão hòa tần suất (TF saturation) được điều tiết bởi tham số k_1 ; (2) Phạt độ dài tài liệu linh hoạt bằng tham số b .

Câu 2: **Chọn a.** Tham số $b \in [0, 1]$ quy định mức độ phạt độ dài văn bản so với độ dài trung bình toàn tập tài liệu:

$$B = (1 - b) + b \cdot \frac{|D|}{\text{avgdl}}$$

Với $b = 1$, mô hình phạt toàn phần theo tỷ lệ độ dài; với $b = 0$, việc chuẩn hóa độ dài hoàn toàn bị triệt tiêu.

Câu 3: **Chọn d.** Mỗi văn bản có trung bình 50 từ duy nhất, tương ứng với đúng 50 vị trí khác 0 trên mỗi hàng. Với 1000 hàng (tài liệu):

$$\text{Tổng phần tử khác 0} = 1000 \times 50 = 50.000$$

Câu 4: **Chọn c.** Đây là vấn đề bất đồng từ vựng (Vocabulary Mismatch) do sử dụng từ đồng nghĩa. Giải pháp triệt để là Mở rộng truy vấn (Query Expansion) bằng từ điển đồng nghĩa (Thesaurus) hoặc chuyển sang tìm kiếm ngữ nghĩa (Semantic Search/Dense Retrieval).

Câu 5: **Chọn d.** Không gian từ vựng thường chứa hàng chục đến hàng trăm nghìn từ, trong khi một văn bản chỉ chứa vài chục đến vài trăm từ. Do đó ma trận có độ thưa trên 99% là hoàn toàn tự nhiên và được tối ưu bằng các cấu trúc dữ liệu thưa (Sparse Matrix).

Câu 6: **Chọn b.** LDA là mô hình sinh xác suất giả định dữ liệu đếm rời rạc tuân theo phân phối Multinomial/Dirichlet. Do đó, đầu vào chuẩn kỹ thuật bắt buộc phải là ma trận số đếm nguyên thô (CountVectorizer), không dùng TF-IDF hay số thực chuẩn hóa.

Câu 7: **Chọn b.** Kỹ thuật Sublinear TF scaling thay thế tf bằng $1 + \log(tf)$ khi $tf > 0$, giúp làm dịu đà tăng trưởng của tần suất thô, ngăn không cho một bài viết lặp từ quá nhiều lần áp đảo hoàn toàn các bài viết ngắn chất lượng.

Câu 8: **Chọn c.** Biểu thức $<[\sim]>+$ đại diện cho chuỗi bắt đầu bằng $<$, theo sau là một hoặc nhiều ký tự khác $>$, và kết thúc bởi $>$. Cách viết này bắt chính xác từng thẻ mà không bị lỗi greedy quét gộp văn bản như $<.*?>$.

- Câu 9:** **Chọn a.** Giả định trực giao (orthogonal) xem mỗi từ là một chiều độc lập tuyến tính, hoàn toàn không có mối liên hệ ngữ nghĩa với các từ khác (ví dụ: vector của “xe hơi” và “ô tô” hoàn toàn vuông góc với nhau).
- Câu 10:** **Chọn b.** Nguyên tắc chống rò rỉ dữ liệu (Data Leakage): chỉ dùng `fit_transform()` trên tập Train để xây dựng bộ từ điển và tính giá trị IDF; tập Test phải được coi như dữ liệu chưa biết và chỉ dùng `transform()`.
- Câu 11:** **Chọn c.** Character-level N-grams (n-gram ký tự) trích xuất được đặc trưng hình thái học, gốc từ và tiền/hậu tố mà không phụ thuộc vào ranh giới từ (word boundary), đặc biệt hiệu quả với ngôn ngữ viết dính liền hoặc phân loại ngôn ngữ.
- Câu 12:** **Chọn c.** Khoảng cách Euclid đo khoảng cách hình học tuyệt đối nên hai văn bản có chung tỷ lệ phân bố từ vựng nhưng khác nhau nhiều về độ dài sẽ bị đẩy ra rất xa nhau. Cosine Similarity chuẩn hóa độ dài và chỉ xét góc định hướng.
- Câu 13:** **Chọn b.** Tham số *Minimum Should Match* (ví dụ: bắt buộc trùng khớp ít nhất 75% số từ) loại bỏ ngay các văn bản chỉ chứa 1 hoặc 2 từ phụ trong một truy vấn dài, tăng độ chính xác (Precision) rõ rệt.
- Câu 14:** **Chọn a.** TF-IDF dựa trên khớp từ vựng chính xác (Lexical Matching) trên các chiều rời rạc; trong khi Dense Embeddings biểu diễn văn bản trong không gian vector liên tục giúp nhận diện sự tương đồng về ngữ nghĩa (Semantic Matching).
- Câu 15:** **Chọn d.** Chỉ số MRR (Mean Reciprocal Rank):

$$\text{MRR} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i} = \frac{1}{3} \left(\frac{1}{1} + 0 + \frac{1}{4} \right) = \frac{1}{3} \times \frac{5}{4} = \frac{5}{12} \approx 0.417$$

- Câu 16:** **Chọn c.** Mô hình không gian vector truyền thống gán một từ duy nhất vào một chiều cố định, dẫn đến hiện tượng gộp chung các nét nghĩa khác nhau của từ đa nghĩa (Polysemy), không phân biệt được “bank” tài chính và “river bank”.
- Câu 17:** **Chọn a.** Trong mã nguồn, các ký tự dấu câu (., ->, ()) và các từ khóa điều khiển (`for`, `if`, `class`) đóng vai trò then chốt xác định cú pháp và logic. Quy trình tiền xử lý văn bản tự nhiên thông thường sẽ làm mất toàn bộ cấu trúc này.
- Câu 18:** **Chọn a.** TF-IDF ánh xạ mỗi chuỗi ký tự cố định vào duy nhất một chỉ số cột trong ma trận và chỉ đếm tần suất, không mô hình hóa được ngữ cảnh xung quanh từ đó.
- Câu 19:** **Chọn c.** Vì hai vector không có bất kỳ đặc trưng từ vựng chung nào, tích vô hướng của chúng bằng 0, dẫn tới Cosine Similarity bằng 0:

$$\text{Cosine}(D_1, D_2) = \frac{D_1 \cdot D_2}{\|D_1\| \|D_2\|} = \frac{0}{\|D_1\| \|D_2\|} = 0.0$$

- Câu 20:** **Chọn d.** Bộ lọc dừng tiếng Anh không chứa các từ chức năng tiếng Pháp, do đó các từ như “le”, “la”, “de” không bị loại và sẽ trở thành các đặc trưng có tần suất xuất hiện rất cao nhưng mang ít giá trị phân loại.
- Câu 21:** **Chọn b.** Thao tác hạ chữ thường (Lowercasing) đưa “iPhone”, “iphone” và “IPHONE” về cùng một dạng chuẩn duy nhất, giúp hệ thống so khớp chính xác từ khóa tìm kiếm.
- Câu 22:** **Chọn b.** Trong Scikit-Learn Pipeline, mọi bước trung gian biến đổi dữ liệu bắt buộc phải kế thừa lớp `TransformerMixin` và hiện thực hóa đầy đủ hai phương thức `fit()` và `transform()`.

Câu 23: **Chọn c.** Độ đo Cosine Similarity có tính bất biến theo phép co giãn tỷ lệ bằng một hằng số dương $c > 0$:

$$\text{Cosine}(c \cdot D, Q) = \frac{(c \cdot D) \cdot Q}{\|c \cdot D\| \|Q\|} = \frac{c(D \cdot Q)}{c\|D\| \|Q\|} = \text{Cosine}(D, Q)$$

Câu 24: **Chọn c.** Với các văn bản rất ngắn (như tin nhắn, tweet, tiêu đề), các từ hâu như chỉ xuất hiện tối đa 1 lần. Chế độ nhị phân (**binary=True**) tập trung vào sự hiện diện của từ thay vì tần suất, giúp giảm nhiễu hiệu quả.

Câu 25: **Chọn b.** LSA sử dụng phân tích suy biến SVD để giảm chiều ma trận TF-IDF xuống không gian chủ đề ẩn (Latent Semantic Space), gom các từ đồng nghĩa (thường xuyên đồng xuất hiện) về gần nhau.

Câu 26: **Chọn c.** Áp dụng công thức chuẩn không làm mịn (no smoothing):

$$\text{idf}(t) = \log_e \left(\frac{N}{\text{df}(t)} \right) = \log_e \left(\frac{1000}{1000} \right) = \log_e(1) = 0.0$$

Câu 27: **Chọn a.** Chuẩn L_2 (độ dài Euclid) của vector $v = [3, 0, 4]$ là:

$$\|v\|_2 = \sqrt{3^2 + 0^2 + 4^2} = \sqrt{25} = 5$$

Vector chuẩn hóa:

$$v' = \left[\frac{3}{5}, \frac{0}{5}, \frac{4}{5} \right] = [0.6, 0.0, 0.8]$$

Câu 28: **Chọn c.** Chuẩn hóa L_1 chia mỗi phần tử cho tổng giá trị tuyệt đối của toàn vector:

$$\|v\|_1 = |1| + |2| + |1| + |4| = 8 \implies v' = \left[\frac{1}{8}, \frac{2}{8}, \frac{1}{8}, \frac{4}{8} \right] \implies \sum v'_i = 1.0$$

Câu 29: **Chọn a.** Hiện tượng nghịch lý độ chính xác (Accuracy Paradox): Với tập dữ liệu mất cân bằng 99:1, một mô hình phân loại dự đoán tất cả là lớp đa số sẽ đạt ngay Accuracy 99% nhưng hoàn toàn vô dụng vì không phát hiện được mẫu độc hại nào.

Câu 30: **Chọn d.** Văn bản D_2 dài gấp 10 lần nên tổng bình phương các giá trị trong vector sẽ lớn hơn rất nhiều, dẫn đến độ dài chuẩn hóa $\|D_2\|_2$ lớn hơn. Khi chia cho chuẩn này, trọng số của từ khóa Q trong D_1 sẽ giữ được giá trị lớn hơn rõ rệt so với trong D_2 .