


Xử lý ngôn ngữ tự nhiên với học sâu

CS224N/Ling284



Địch Y Dương

Bài giảng 2: Vectơ từ

Kế hoạch bài giảng

Bài giảng 2: Vectơ từ

1. Tổ chức khóa học (3 phút)
2. Giới thiệu về Word2vec (15 phút)
3. Độ dốc của hàm mục tiêu Word2vec (25 phút)
4. Khái niệm cơ bản về tối ưu hóa (5 phút)
5. Liệu chúng ta có thể nắm bắt được bản chất ý nghĩa của từ một cách hiệu quả hơn bằng cách đếm không? (10 điểm)
6. Đánh giá vectơ từ (10 phút)

Mục tiêu chính: Hiểu được ý nghĩa của từ có thể được biểu diễn bằng một vectơ đa chiều gồm các số thực và có thể đọc hiểu các bài báo về nhúng từ (word embeddings) vào cuối khóa học.

1. Tổ chức khóa học

- Đăng ký dự thính/

Danh sách chờ • Đối với các câu hỏi khác, vui lòng gửi email đến cs224n-win2526-staff@lists.stanford.edu

- Hãy đến giờ tư vấn/buổi hỗ trợ! • Các buổi

này đã bắt đầu từ hôm

nay • Hãy đến để thảo luận về ý tưởng dự án cuối kỳ cũng như các bài tập •

Cố gắng đến sớm, thường xuyên và ngoài giờ hành chính!

- Giờ làm việc của trợ giảng: Mỗi ca 3 tiếng, từ thứ Hai đến thứ Bảy, với sự tham gia của nhiều trợ giảng.

- Chỉ cần đến! Đội ngũ giảng viên thân thiện của chúng tôi sẽ có mặt để hỗ trợ bạn! •

https://web.stanford.edu/class/cs224n/office_hours.html

- Giờ làm việc của giảng viên (mặc định là trực tiếp):

- Diyi: Thứ Ba 3:30-4:30 chiều •

Yejin: Thứ Sáu 4:30-5:30 chiều

2. Chúng ta thể hiện ý nghĩa của một từ như thế nào?

Định nghĩa: nghĩa (Từ điển Webster)

- Ý tưởng được thể hiện bằng một từ, cụm từ, v.v.
- Ý tưởng mà một người muốn thể hiện bằng lời nói, dấu hiệu, v.v.
- Ý tưởng được thể hiện trong một tác phẩm văn học, nghệ thuật, v.v.

Cách tư duy ngôn ngữ phổ biến nhất về ý nghĩa:

Ký hiệu (biểu tượng) ý nghĩa (ý tưởng hoặc sự vật)

= ngữ nghĩa biểu thị

cây

{



,



,



,

. }

Làm thế nào chúng ta có thể tạo ra ý nghĩa hữu ích trong máy tính?

Giải pháp xử lý ngôn ngữ tự nhiên (NLP) phổ biến trước đây: Sử dụng, ví dụ, **WordNet**, một từ điển đồng nghĩa chứa danh sách các tập hợp từ đồng nghĩa và từ loại cao hơn (mối quan hệ “là một”) , ví

Ví dụ: các tập hợp từ đồng nghĩa chứa từ “good”:

```
from nltk.corpus import wordnet as wn
poses = { 'n': 'danh từ', 'v': 'động từ', 's': 'tính từ (số ít)', 'a': 'tính từ', 'r': 'trạng từ' }
for synset in wn.synsets("good"):
    print("{}: {}".format(poses[synset.pos()],
        ", ".join([l.name() for l in synset.lemmas()])))
```

```
danh từ: tốt
danh từ: tốt, sự tốt lành
danh từ: tốt, sự tốt lành
danh từ: hàng hóa, hàng hóa thương mại, tốt
tính từ:
tốt tính từ (bảo hòa): đầy
đủ, tốt
tính từ: tốt tính từ (bảo hòa): đáng kính, tốt, đáng trọng, đáng
tôn trọng tính từ (bảo hòa): có lợi,
tốt tính từ (bảo
hòa): tốt tính từ (bảo hòa): tốt, công bằng, chính trực
.
trạng từ: tốt, ổn trạng
từ: hoàn toàn, vững chắc, tốt
```

dụ: từ loại cao hơn của “gấu trúc”:

```
from nltk.corpus import wordnet as wn
panda = wn.synset("panda.n.01")
hyper = lambda s: s.hypernyms()
danh sách(panda.closure(hyper))
```

```
[Synset('procyonid.n.01'),
Synset('carnivore.n.01'),
Synset('placental.n.01'),
Synset('mammal.n.01'),
Synset('vertebrate.n.01'),
Synset('chordate.n.01'),
Synset('animal.n.01'),
Synset('organism.n.01'),
Synset('living_thing.n.01'),
Synset('whole.n.02'),
Synset('object.n.01'),
Synset('physical_entity.n.01'),
Synset('entity.n.01')]
```

Các vấn đề với các nguồn tài nguyên như WordNet

- Một nguồn tài liệu hữu ích nhưng thiếu đi sự tinh tế:
 - Ví dụ, "thành thạo" được liệt kê là từ đồng nghĩa với "giỏi".
Điều này chỉ đúng trong một số trường hợp nhất định.
 - Ngoài ra, WordNet liệt kê các từ đồng nghĩa mang tính xúc phạm trong một số bộ từ đồng nghĩa mà không đề cập đến ý nghĩa hàm chứa hoặc tính phù hợp của từ.
- Thiếu các nghĩa mới của từ: ví dụ:
 - wicked, badass, nifty, wizard, genius, ninja, bombest
 - Không thể cập nhật liên tục!
 - Mang tính chủ quan
- Cần sự lao động của con người để tạo ra và điều chỉnh
- Không thể được sử dụng để tính toán chính xác sự tương đồng giữa các từ (xem các slide tiếp theo)

Biểu diễn từ ngữ dưới dạng các ký hiệu riêng biệt

Trong xử lý ngôn ngữ tự nhiên truyền thống, chúng ta coi từ ngữ như những ký hiệu riêng biệt:

khách sạn, hội nghị, nhà nghỉ - một cách diễn đạt mang tính địa phương.

Có nghĩa là một số 1, phần còn lại là 0.



Các ký hiệu như vậy cho các từ có thể được biểu diễn bằng các vectơ one-hot :

motel = [0 0 0 0 0 0 0 0 0 0 1 0 0 0 0]

khách sạn = [0 0 0 0 0 0 0 1 0 0 0 0 0 0 0]

Kích thước vectơ = số lượng từ trong từ vựng (ví dụ: 500.000+)

Vấn đề với từ ngữ dưới dạng các ký hiệu riêng biệt

Ví dụ: trong tìm kiếm trên web, nếu người dùng tìm kiếm "nhà nghỉ ở Seattle", chúng tôi muốn hiển thị các kết quả có chứa cụm từ "khách sạn ở Seattle".

```
motel = [0 0 0 0 0 0 0 0 0 0 0 1 0 0 0 0] hotel  
= [0 0 0 0 0 0 0 1 0 0 0 0 0 0 0 0]
```

Nhưng hai vectơ này vuông góc với nhau. Không có

khái niệm tự nhiên nào về sự tương đồng đối với các vectơ one-hot!

Giải pháp:

- Có thể thử dựa vào danh sách từ đồng nghĩa của WordNet để tìm độ tương đồng không? •

Nhưng phương pháp này nổi tiếng là dễ thất bại: thiếu thông tin đầy đủ, v.v.

- Thay vào đó: hãy học cách mã hóa sự tương đồng trong chính các vectơ.

Biểu diễn từ ngữ dựa trên ngữ cảnh của chúng.



- **Ngữ nghĩa phân phối**: Ý nghĩa của một từ được xác định.
bằng những từ thường xuyên xuất hiện gần đó
 - “Bạn sẽ nhận biết một từ qua những từ đi kèm với nó” (JR Firth 1957: 11)
 - Một trong những ý tưởng thành công nhất của xử lý ngôn ngữ tự nhiên thống kê hiện đại!
- Khi một từ w xuất hiện trong văn bản, **ngữ cảnh** của nó là tập hợp các từ xuất hiện gần đó.
(trong một cửa sổ có kích thước cố định).
- Chúng ta sử dụng nhiều ngữ cảnh của w để xây dựng nên một biểu diễn của w .

.các vấn đề nợ công của chính phủ đang biến thành	ngân hàng	khủng hoảng như xảy ra vào năm 2009.
nhất. cho rằng châu Âu cần các quy định ^{thêm} hàng để thay thế		tình trạng hỗn loạn hiện nay.
Ấn Độ vừa đưa ra tuyên bố của mình.	hệ thống ngân hàng	bị bán vào tay.



Những từ ngữ cảnh này sẽ đại diện cho lĩnh vực ngân hàng.

Vector chữ

Chúng ta sẽ xây dựng một vectơ dày đặc cho mỗi từ, được chọn sao cho nó tương tự với các vectơ của những từ xuất hiện trong các ngữ cảnh tương tự, đo lường sự tương đồng bằng **tích vô hướng** (**tích scalar**) của vectơ.

$$\text{ngân hàng} = \begin{pmatrix} 0.286 \\ 0.792 \\ -0.177 \\ -0.107 \\ 0.109 \\ 0.542 \\ 0.349 \\ 0.271 \end{pmatrix}$$

$$\text{tiền tệ} = \begin{pmatrix} 0.413 \\ 0.582 \\ -0.007 \\ 0.247 \\ 0.216 \\ 0.718 \\ 0.147 \\ 0.051 \end{pmatrix}$$

Lưu ý: **các vectơ từ** cũng được gọi là **(từ) nhúng** hoặc **(biểu diễn) từ thần kinh**
 Chúng là một biểu diễn **phân tán**


3. Word2vec: Tổng quan

Word2vec là một framework để học các vectơ từ.

(Mikolov và cộng sự, 2013)

Ý tưởng:


- Chúng ta có một kho ngữ liệu lớn ("nội dung") gồm văn bản: một danh sách dài các từ.
- Mỗi từ trong một từ vựng cố định được biểu diễn bằng một vectơ.
- Xem xét từng vị trí t trong văn bản, vị trí nào có tâm?
từ c và ngữ cảnh ("bên ngoài") các từ o
- Sử dụng độ tương đồng của các vectơ từ cho c và o để tính toán
Xác suất của o khi biết c (hoặc ngược lại)
- Tiếp tục điều chỉnh các vectơ từ để tối đa hóa xác suất này.



Mô hình Skip-gram
(Mikolov và cộng sự 2013)

Tổng quan về Word2Vec


Ví dụ về cửa sổ và quy trình tính toán $(\quad + \quad | \quad)$



Tổng quan về Word2Vec

Ví dụ về cửa sổ và quy trình tính toán

(+ |)



Word2Vec: hàm mục tiêu

Với mỗi vị trí $i = 1, \dots, m$, hãy dự đoán các từ ngữ cảnh trong một cửa sổ có kích thước cố định m , cho trước từ trung tâm. Xác suất dữ liệu:

$$\text{Xác suất} = P(\mathbf{c} | \mathbf{t}) = \prod_{i=1}^m P(c_i | t)$$

tất cả các biến
số cần được tối ưu hóa

đôi khi được gọi là hàm chi phí hoặc hàm tổn thất.

Hàm mục tiêu

$J(\theta)$ là logarit xác suất âm (trung bình):

$$J(\theta) = -\frac{1}{n} \log P(\mathbf{c} | \mathbf{t}) = -\frac{1}{n} \sum_{i=1}^m \log P(c_i | t)$$

Giảm thiểu hàm mục tiêu Tối đa hóa độ chính xác dự đoán

Word2Vec: hàm mục tiêu

- Chúng ta muốn tối thiểu hóa hàm mục tiêu:

$$J(\theta) = \frac{1}{n} \sum_{i=1}^n \sum_{(w, w') \in \text{nhật ký}} \ell(\theta; w, w')$$

- Câu hỏi: Làm thế nào để tính toán $\ell(\theta; w, w')$?
- Câu trả lời: Chúng ta sẽ sử dụng hai vectơ cho mỗi từ w :
 - khi w là từ trung tâm
 - khi w là một từ ngữ cảnh
- Sau đó, với từ trung tâm c và từ ngữ cảnh o :

$$p(o|c) = \frac{\exp(\theta_o^T \theta_c)}{\sum_{o'} \exp(\theta_o^T \theta_c)}$$

Word2Vec: chức năng dự đoán

Phép lũy thừa làm cho bất cứ thứ gì cũng trở thành số dương

Tích vô hướng so sánh độ tương đồng giữa o và c.

$$= \sigma = 1$$

Tích vô hướng càng lớn = xác suất càng lớn

$$(\mid) = \frac{\sigma}{\sum \exp(\exp(\mid))}$$

Chuẩn hóa trên toàn bộ từ vựng để có được phân phối xác suất

- Đây là một ví dụ về hàm softmax $\mathbb{R} \rightarrow (0,1)$

$$\text{softmax} \Rightarrow \frac{\exp(x)}{\sum_{\sigma=1} \exp(x)} =$$
- Hàm softmax ánh xạ các giá trị tùy ý đến một phân bố xác suất.

Khu vực mở

- "max" vì nó khuếch đại xác suất của giá trị lớn nhất
- "soft" vì vẫn gán một số xác suất cho giá trị nhỏ hơn
- Thường được sử dụng trong Học sâu


Nhưng cái tên hơi kỳ lạ.
Bởi vì nó trả về một phân phối!

Để huấn luyện mô hình: Tối ưu hóa giá trị các tham số để giảm thiểu tổn thất.

Để huấn luyện một mô hình, chúng ta điều chỉnh dần các tham số để giảm thiểu tổn thất.

- Nhớ lại: biểu thị **tất cả** các tham số của mô hình, trong một vectơ dài
- Trong trường hợp của chúng tôi, với các vectơ d chiều và V -nhiều từ, chúng ta có
- Hãy nhớ: mỗi từ đều có hai vectơ

$$\theta = \begin{bmatrix} v_{aardvark} \\ v_a \\ \vdots \\ v_{zebra} \\ u_{aardvark} \\ u_a \\ \vdots \\ u_{zebra} \end{bmatrix} \in \mathbb{R}^{2dV}$$



- Chúng tôi tối ưu hóa các tham số này bằng cách đi xuống theo đường dốc (xem hình bên phải)
- Chúng tôi tính toán **tất cả** các đạo hàm vectơ!

Buổi thảo luận tương tác!


- $$P(\mathbf{c}) = \prod_{i=1}^n \sum_{o_i} P(o_i | c_i)$$

- Với từ trung tâm c và từ ngữ cảnh o :

$$P(o | c) = \frac{\exp(\mathbf{w}^T \mathbf{c} + \mathbf{u}^T \mathbf{o})}{\sum_{o'} \exp(\mathbf{w}^T \mathbf{c} + \mathbf{u}^T \mathbf{o'})}$$

4. Tối ưu hóa: Phương pháp giảm độ dốc (Gradient Descent)

- Chúng ta có một hàm chi phí () chúng ta muốn giảm thiểu
- Thuật toán Gradient Descent là thuật toán tối ()
- Ý tưởng: cho giá trị hiện tại của , tối ưu hóa độ dốc bằng (), sau đó hãy tiến từng bước nhỏ theo hướng đó cách tính toán độ dốc âm. Lặp lại.



Lưu ý: Mục

tiêu của chúng tôi
có thể
không lỗi
như thế này

Nhưng cuộc sống lại thay đổi.

Sẽ ổn thôi

Giảm độ dốc

- Cập nhật phương trình (dưới dạng ma trận):

$$\theta^{new} = \theta^{old} - \alpha \nabla_{\theta} J(\theta)$$

= bước nhảy hoặc tốc độ học

- Cập nhật phương trình (cho tham số đơn):

$$\theta_j^{new} = \theta_j^{old} - \alpha \frac{\partial}{\partial \theta_j^{old}} J(\theta)$$

- Thuật toán:

```
while True:
    theta_grad = evaluate_gradient(J, corpus, theta)
    theta = theta - alpha * theta_grad
```

Thuật toán giảm độ dốc ngẫu nhiên (Stochastic Gradient Descent)

- Vấn đề: $J(\theta)$ Đây là một hàm của **tất cả** các cửa sổ trong kho dữ liệu (có thể lên đến hàng tỷ cửa sổ!).
 - Vì thế $\nabla_{\theta} J(\theta)$ **việc tính toán rất tốn kém**.
- Bạn sẽ phải chờ rất lâu trước khi thực hiện bất kỳ bản cập nhật nào!
- Đó là một ý tưởng **rất tồi** đối với hầu hết các mạng nơ-ron!
- Giải pháp: **Thuật toán giảm độ dốc ngẫu nhiên (SGD)**
 - Lấy mẫu các cửa sổ nhiều lần và cập nhật sau mỗi lần lấy mẫu.
- Thuật toán:


Mẻ nhỏ

Giảm độ dốc


```
while True:
    window = sample_window(corpus)
    theta_grad = evaluate_gradient(J, window, theta)
    theta = theta - alpha * theta_grad
```

Các tham số Word2vec .


và các phép tính




U
ngoài



V
trung tâm



4



softmax(4)


xác suất tích vô hướng

Mô hình "Túi từ"!

Mô hình đưa ra cùng một dự đoán ở mỗi vị trí.

Chúng ta cần một mô hình đưa ra ước tính xác suất tương đối cao cho tất cả các từ xuất hiện trong ngữ cảnh (thường xuyên).

Word2vec tối đa hóa hàm mục tiêu bằng cách đặt các từ tương tự gần nhau trong không gian.



Họ thuật toán Word2vec (Mikolov et al. 2013): Chi tiết hơn

Tại sao lại cần hai vectơ? Để tối ưu hóa dễ dàng hơn. Tính trung bình cả hai vectơ ở bước cuối.

- Nhưng có thể triển khai thuật toán chỉ với một vectơ cho mỗi từ. và điều đó giúp ích được phần nào.

Hai biến thể mô hình:

1. Skip-grams (SG)

Dự đoán các từ ngữ cảnh ("bên ngoài") (không phụ thuộc vào vị trí) khi biết từ trung tâm.

2. Phương pháp Túi Từ Liên tục (CBOW)

Dự đoán từ trung tâm từ (tập hợp) các từ ngữ cảnh

Chúng tôi đã trình bày: Mô hình Skip-gram

Các hàm mất mát dùng trong huấn luyện:

1. Naïve softmax (hàm mất mát đơn giản nhưng tốn kém, khi có nhiều lớp đầu ra)
2. Các biến thể được tối ưu hóa hơn như softmax phân cấp
3. Lấy mẫu

âm Cho đến nay, chúng ta đã

giải thích về softmax đơn giản

Mô hình skip-gram với lấy mẫu âm

- Thuật ngữ chuẩn hóa tốn nhiều tài nguyên tính toán (khi có nhiều lớp đầu ra):

$$\bullet \quad \left(\begin{array}{c} | \\ \end{array} \right) = \frac{\exp(\dots)}{\sigma \exp(\dots)}$$

Một khoản tiền lớn hơn nhiều so với lời nói

- Do đó, word2vec tiêu chuẩn triển khai mô hình skip-gram với lấy mẫu âm.
- Ý tưởng chính: huấn luyện mô hình hồi quy logistic nhị phân để phân biệt một cặp từ thực sự (từ trung tâm và một từ trong cửa sổ ngữ cảnh của nó) với một số cặp từ "nhiều" (từ trung tâm được ghép với một từ ngẫu nhiên).

Mô hình skip-gram với lấy mẫu âm (Mikolov et al. 2013)


- Chúng ta lấy k mẫu âm tính (sử dụng xác suất từ)
- Tối đa hóa khả năng xuất hiện từ ngữ thực bên ngoài;
giảm thiểu xác suất các từ ngẫu nhiên xuất hiện xung quanh từ trung tâm
- Sử dụng ký hiệu nhất quán với lớp học này, chúng ta tối thiểu hóa:

$$J(\theta) = - \sum_{(w, w')} \log \left(\sum_{w''} \exp(\theta_w \cdot \theta_{w''}) \right) \quad \log \left(\sum_{w''} \exp(\theta_w \cdot \theta_{w''}) \right)$$

hàm sigmoid thay vì hàm softmax

- Hàm logistic/sigmoid:

(Chúng ta sẽ sớm trở thành bạn tốt của nhau thôi)



- Lấy mẫu với $P(w) = U(w)^{3/4} / Z$, phân phối unigram $U(w)$ được nâng lên lũy thừa 3/4
 - Tính năng này giúp các từ ít xuất hiện hơn được lấy mẫu thường xuyên hơn.

Độ dốc ngẫu nhiên với lấy mẫu âm [bên lề]

- Chúng tôi lặp lại việc lấy đạo hàm tại mỗi cửa sổ cho


SGD • Trong mỗi cửa sổ, chúng tôi chỉ có tối đa $2m + 1$ từ cộng với $2km$ số âm các từ có lấy mẫu âm, vì vậy () rất thưa thớt!

$$\nabla_{\theta} J_t(\theta) = \begin{bmatrix} 0 \\ \vdots \\ \nabla_{v_{like}} \\ \vdots \\ 0 \\ \nabla_{u_I} \\ \vdots \\ \nabla_{u_{learning}} \\ \vdots \end{bmatrix} \in \mathbb{R}^{2dV}$$

Độ dốc ngẫu nhiên với lấy mẫu âm [bên lề]

- Chúng ta có thể chỉ cập nhật các vectơ từ ngữ thực sự xuất hiện!
- Giải pháp: hoặc bạn cần các thao tác cập nhật ma trận thưa để chỉ cập nhật một **số hàng** nhất định của ma trận nhúng đầy đủ U và V, hoặc bạn cần giữ lại một hàm băm cho các vectơ từ.

Trong các gói DL thực tế, hàng chữ không phải cột!



- Nếu bạn có hàng triệu vectơ từ và thực hiện điện toán phân tán, điều quan trọng là không phải gửi các bản cập nhật khổng lồ đi khắp nơi!

5. Tại sao không thu thập trực tiếp số lần xuất hiện đồng thời?

Việc lặp lại toàn bộ kho ngữ liệu (có thể nhiều lần) nghe có vẻ kỳ lạ; tại sao chúng ta không thu thập tất cả số liệu thống kê về những từ xuất hiện gần nhau?

Xây dựng ma trận đồng xuất hiện X

- 2 tùy chọn: cửa sổ so với toàn bộ tài liệu
- Cửa sổ: Tương tự như word2vec, sử dụng cửa sổ xung quanh mỗi từ nắm bắt một số thông tin cú pháp và ngữ nghĩa ("không gian từ")
- Ma trận đồng xuất hiện từ ngữ trong tài liệu sẽ cung cấp các chủ đề chung (tất cả các thuật ngữ thể thao sẽ có các mục tương tự) dẫn đến "Phân tích ngữ nghĩa tiềm ẩn" ("không gian tài liệu").

Ví dụ: Ma trận đồng xuất hiện dựa trên cửa sổ

- Chiều dài cửa sổ 1 (thường gặp hơn: 5-10)
- Đối xứng (không phụ thuộc vào ngữ cảnh bên trái hay bên phải)

- Ví dụ về kho ngữ liệu:

- Tôi thích học sâu.

- Tôi thích NLP (Xử lý ngôn ngữ tự nhiên)

- Tôi thích bay

đếm tôi		giống	Tận hưởng việc học sâu về xử lý ngôn ngữ tự nhiên (NLP) và bay lượn.					
.	0	2	1	0	0	0	0	0
giống	2	0	0	1	0	1	0	0
thường thức	1	0	0	0	0	0	1	0
sâu	0	1	0	0	1	0	0	0
học tập	0	0	0	1	0	0	0	1
Xử lý ngôn ngữ tự nhiên	0	1	0	0	0	0	0	1
bay	0	0	1	0	0	0	0	1
.	0	0	0	0	1	1	1	0

Các vectơ đồng xuất hiện

- Vectơ đồng xuất hiện đếm đơn giản

- Kích thước vectơ tăng theo số lượng từ vựng •

Có chiều rất cao: yêu cầu nhiều bộ nhớ (mặc dù thừa thớt) • Các mô hình phân

loại tiếp theo gặp vấn đề về tính thừa thớt Mô hình kém mạnh mẽ hơn

- Các vectơ có chiều thấp

- Ý tưởng: lưu trữ “hầu hết” thông tin quan trọng trong một số lượng nhỏ các vùng nhớ cố định.
kích thước: một vectơ dày đặc

- Thường có từ 25 đến 1000 chiều, tương tự như word2vec • Làm

thế nào để giảm số chiều?

Phương pháp cổ điển: Giảm chiều dữ liệu trên X (Bài tập về nhà 1)

Phân tích giá trị đơn lẻ của ma trận đồng xuất hiện X

Phân tích X thành $U\Sigma V^T$, trong đó U và V là các vectơ trực chuẩn (vectơ đơn vị và vuông góc với nhau).

$$\underbrace{\begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \end{bmatrix}}_{X^k} = \underbrace{\begin{bmatrix} * & * & * \\ * & * & * \\ * & * & * \end{bmatrix}}_U \underbrace{\begin{bmatrix} \text{pink circle} & & \\ & \text{pink circle} & \\ \text{blue L-shape} & & \text{yellow rectangle} \end{bmatrix}}_{\Sigma} \underbrace{\begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ \text{blue row} & & & & \\ \text{yellow rows} & & & & \end{bmatrix}}_{V^T}$$

Chỉ giữ lại k giá trị riêng để khái quát hóa.

là phép xấp xỉ hạng k tốt nhất cho X , xét về phương pháp bình phương tối thiểu.

Một kết quả kinh điển của đại số tuyến tính. Tồn kém chi phí tính toán đối với ma trận lớn.


Thủ thuật X

- Việc chạy thuật toán SVD trên số liệu thô không mang lại kết quả tốt!!!
- Việc chia tỷ lệ số liệu trong các ô có thể giúp ích rất nhiều.
 - Vấn đề: các từ chức năng (the, he, has) xuất hiện quá thường xuyên cú pháp quá phức tạp.

Tác động. Một số giải pháp khắc phục:

- ghi lại tần số
- $\min(X, t)$, với $t \approx 100$
- Bỏ qua các từ chức năng
- Cửa sổ dọc ưu tiên hiển thị các từ ở gần hơn so với các từ ở xa.
- Sử dụng hệ số tương quan thay vì số lượng, sau đó đặt các giá trị âm thành 0.
- Vân vân.

Các mô hình ngữ nghĩa thú vị xuất hiện trong các vectơ được thu phóng.



Mô hình COALS từ

Rohde và cộng sự, bản thảo, 2005. Một mô hình cải tiến về sự tương đồng ngữ nghĩa dựa trên sự xuất hiện đồng thời của từ vựng.

GloVe [Pennington, Socher, và Manning, EMNLP 2014]:

Mã hóa các thành phần ý nghĩa trong sự khác biệt giữa các vectơ

Hỏi: Làm thế nào chúng ta có thể nắm bắt tỷ lệ xác suất đồng xuất hiện dưới dạng các thành phần ý nghĩa tuyến tính trong không gian vectơ từ?

GloVe [Pennington, Socher, và Manning, EMNLP 2014]:

Mã hóa các thành phần ý nghĩa trong sự khác biệt giữa các vectơ

Hỏi: Làm thế nào chúng ta có thể nắm bắt tỷ lệ xác suất đồng xuất hiện dưới dạng các thành phần ý nghĩa tuyến tính trong không gian vectơ từ?

A: Mô hình log-song tuyến tính:

$$w_i \cdot w_j = \log P(i|j)$$

với sự khác biệt về vectơ


$$w_x \cdot (w_a - w_b) = \log \frac{P(x|a)}{P(x|b)}$$

Sự mất mát:

$$J = \sum_{i,j=1}^V f(X_{ij}) \left(w_i^T \tilde{w}_j + b_i + \tilde{b}_j - \log X_{ij} \right)^2$$

- Đào tạo nhanh
- Có khả năng mở rộng đến các tập dữ liệu khổng lồ

$f \sim$



6. Làm thế nào để đánh giá các vectơ từ?

- Liên quan đến đánh giá tổng quát trong xử lý ngôn ngữ tự nhiên: Nội tại so với ngoại tại

- Nội tại:

- Đánh giá về một nhiệm vụ phụ cụ thể/trung gian

- Tính toán nhanh • Giúp

hiểu rõ hệ thống • Chưa rõ liệu có hữu ích hay

không trừ khi có sự tương quan với nhiệm vụ thực tế

- Yếu tố bên ngoài:

- Đánh giá dựa trên nhiệm vụ thực tế

- Có thể mất nhiều thời gian để tính toán độ chính xác •

Không rõ vấn đề nằm ở hệ thống con, sự tương tác giữa các hệ thống con hay các hệ thống con khác • Nếu việc

thay thế chính xác một hệ thống con bằng một hệ thống con khác giúp cải thiện độ chính xác Thành công!

Đánh giá vectơ từ nội tại


- Phép tương tự vectơ từ

a:b :: c:?


đàn ông:phụ nữ :: vua:?

$$d = \arg \max_i \frac{(x_b - x_a + x_c)^T x_i}{\|x_b - x_a + x_c\|}$$

- Đánh giá các vectơ từ bằng cách xem khoảng cách cosin của chúng sau phép cộng có thể nắm bắt được sự tương đồng về ngữ nghĩa và cú pháp một cách trực quan hay không.
- Loại bỏ các từ khóa đầu vào khỏi kết quả tìm kiếm (!)
- Vấn đề: Điều gì sẽ xảy ra nếu thông tin có sẵn nhưng...
Không tuyến tính?



GloVe Visualization



Độ tương đồng về ý nghĩa: Một đánh giá vectơ từ nội tại khác.

- Khoảng cách vectơ từ và mối tương quan của chúng với đánh giá của con người

- Ví dụ về bộ dữ liệu: WordSim353

<http://www.cs.technion.ac.il/~gabr/resources/data/wordsim353/>

Từ 1	Từ 2	Con người (trung bình)
cuốn	con mèo	7,35
sách	con hổ	10
hổ hổ	giấy	7,46
máy tính internet		7.58
máy bay	xe hơi	5.77
giáo sư tiến sĩ cổ		6,62
phiếu điện thoại		1.62
Cổ phần	CD	1.31
Cổ phần	báo đốm	0,92

Đánh giá tương quan

- Khoảng cách vectơ từ và mối tương quan của chúng với đánh giá của con người

Model	Size	WS353	MC	RG	SCWS	RW
SVD	6B	35.3	35.1	42.5	38.3	25.6
SVD-S	6B	56.5	71.5	71.0	53.6	34.7
SVD-L	6B	65.7	<u>72.7</u>	75.1	56.5	37.0
CBOW [†]	6B	57.2	65.6	68.2	57.0	32.5
SG [†]	6B	62.8	65.2	69.7	<u>58.1</u>	37.2
GloVe	6B	<u>65.8</u>	<u>72.7</u>	<u>77.8</u>	53.9	<u>38.1</u>
SVD-L	42B	74.0	76.4	74.1	58.3	39.9
GloVe	42B	<u>75.9</u>	<u>83.6</u>	<u>82.9</u>	<u>59.6</u>	<u>47.8</u>
CBOW*	100B	68.4	79.6	75.4	59.4	45.5

Đánh giá vectơ từ ngoại lai

- Một ví dụ cho thấy các vectơ từ tốt có thể hỗ trợ trực tiếp: **nhận dạng thực thể được đặt tên**: xác định các tham chiếu đến một người, tổ chức hoặc địa điểm: **Chris Manning** sống ở **Palo Alto**.

Model	Dev	Test	ACE	MUC7
Discrete	91.0	85.4	77.4	73.4
SVD	90.8	85.7	77.3	73.7
SVD-S	91.0	85.5	77.6	74.3
SVD-L	90.5	84.8	73.6	71.5
HPCA	92.6	88.7	81.7	80.7
HSMN	90.5	85.7	78.7	74.7
CW	92.2	87.4	81.7	80.2
CBOW	93.1	88.2	82.2	81.1
GloVe	93.2	88.3	82.9	82.2

Kế hoạch bài giảng

Bài giảng 2: Vectơ từ

1. Tổ chức khóa học (3 phút)
2. Giới thiệu về Word2vec (15 phút)
3. Độ dốc của hàm mục tiêu Word2vec (25 phút)
4. Khái niệm cơ bản về tối ưu hóa (5 phút)
5. Liệu chúng ta có thể nắm bắt được bản chất ý nghĩa của từ một cách hiệu quả hơn bằng cách đếm không? (10 điểm)
6. Đánh giá vectơ từ (10 phút)

Mục tiêu chính: Hiểu được ý nghĩa của từ có thể được biểu diễn bằng một vectơ đa chiều gồm các số thực và có thể đọc hiểu các bài báo về nhúng từ (word embeddings) vào cuối khóa học.